

从众性感知的因果去偏新闻推荐方法

鲍纪敏¹⁾ 张 琨^{1),2)} 吴 乐^{1),2)} 洪日昌^{1),2)} 汪 萌^{1),2)}

¹⁾(合肥工业大学计算机与信息学院 合肥 230027)

²⁾(大数据知识工程重点实验室(合肥工业大学) 合肥 230027)

摘 要 基于神经网络的新闻推荐算法能够从纷繁复杂的新闻中筛选出符合用户偏好的新闻,对于提升用户获取信息的效率以及阅读新闻的体验具有重要的意义. 现有的新闻推荐方法不仅在用户偏好的准确建模方面取得了显著的效果,同时通过识别新闻数据中的虚假关联(例如用户性别与特定新闻类别之间的联系)开展了无偏新闻推荐的初步尝试. 然而用户的新闻点击行为是一系列复杂认知行为相互作用之后的决策结果,仅对有偏信息进行直接建模,简化了有偏信息和用户行为之间的复杂交互关系,忽略了用户行为背后的复杂认知因素的影响,导致无偏推荐效果难以满足实际需求. 为了解决该问题,本文提出一种全新的从众性感知的因果去偏新闻推荐方法 CADNN (Conformity-Aware Debaised Neural News Recommendation). 具体而言,本文提出用户的点击行为包括以下三方面:用户偏好与新闻的匹配度,新闻的流行度,以及用户的从众性特质共同决定的观点. 用户的从众性越低,新闻的流行度越小,相对应的点击行为越能反映出用户的真实偏好. 基于该观点,本文首先对用户的历史点击数据进行了详细的统计分析,从中提取出反映用户行为的关键特征,根据统计分析结果构建能够描述用户偏好、新闻流行度和从众性特质之间关系的因果图模型,通过因果图模型更准确地理解和描述用户点击行为背后的驱动因素. 在此基础上,本文提出一种全新的从众性建模方法,同时从用户的从众性特质和新闻的流行度两个角度进行更符合实际情况的从众性建模;与此同时本文利用现有的新闻推荐方法计算用户偏好和新闻内容的匹配度. 最终在对三方面因素充分建模的情况下,实现更高质量的无偏新闻推荐. 最后,本文在公开的数据集 MIND 上进行了充分的实验验证,并构建了一个用于无偏测试的挑战集,旨在评估推荐系统在无偏环境中的鲁棒性,与已有的最先进的基准方法相比,本文提出的 CADNN 方法在 AUC、MRR、NDCG@5 和 NDCG@10 四个指标上分别平均提高了 1.76%、2.37%、3.06% 和 2.16%,充分证明了 CADNN 方法的有效性. 本文同时提供了 CADNN 的实现代码及相关数据,用于支持推动相关领域的研究.

关键词 新闻推荐;从众性偏差;因果推断;去偏表征;点击预测

中图法分类号 TP18

DOI号 10.11897/SP.J.1016.2024.02333

Conformity-Aware Debaised Neural News Recommendation with Causal Reasoning

BAO Ji-Min¹⁾ ZHANG Kun^{1),2)} WU Le^{1),2)} HONG Ri-Chang^{1),2)} WANG Meng^{1),2)}

¹⁾(College of Computer and Information, Hefei University of Technology, Hefei 230027)

²⁾(Key Laboratory of Knowledge Engineering with Big Data (Hefei University of Technology), Hefei 230027)

Abstract Neural news recommendation algorithms can filter out the news that meets the users' preference from the complicated news, which is important for improving the efficiency of the users' access to information and the news reading experience. It is of great significance to improve the efficiency of users' information access and news reading experience. Existing news recommendation methods have not only achieved remarkable results in accurately modeling users' preferences, but

收稿日期:2023-12-25;在线发布日期:2024-06-24. 本课题得到新一代人工智能国家科技重大专项(2021ZD0111802)、国家自然科学基金区域创新发展联合基金(U22A2094)、国家自然科学基金(62376086,72188101)资助. 鲍纪敏,硕士研究生,中国计算机学会(CCF)会员,主要研究方向为推荐系统. E-mail: baojimin@mail.hfut.edu.cn. 张 琨(通信作者),博士,副教授,主要研究领域为大模型微调、推荐系统. E-mail: zhang1028kun@gmail.com. 吴 乐,博士,教授,主要研究领域为用户建模、推荐系统. 洪日昌,博士,教授,青年长江学者,国家优秀青年科学基金获得者,主要研究领域为多媒体信息处理. 汪 萌,博士,教授,国家杰出青年科学基金获得者,青年长江学者,中组部青年拔尖人才,IEEE Fellow,IAAPR Fellow,主要研究领域为人工智能、模式识别、多媒体信息处理.

also carried out preliminary attempts of unbiased news recommendation by identifying spurious correlations in news data (e. g. the association between user gender and specific news categories). However, user clicking behavior is the result of a series of complex cognitive factors. Directly modeling biased information oversimplifies the complex interaction between biased information and user behavior, disregarding the impact of complex cognitive factors behind the user behavior, which indicates the challenging achievement of unbiased recommendation effectiveness and difficulty makes it hard to meet actual requirements. To address the issue, we propose a novel method named CADNN (Conformity-Aware Debiased Neural News recommendation) to realize higher quality unbiased news recommendation. Specifically, we argue that user clicking behavior is determined by the following three factors: the match score between user preference and news, news popularity, and user conformity level. The lower the user conformity level and news popularity are, the more the corresponding clicking behavior reflects the user real preference. Based on this viewpoint, this paper first conducts a detailed statistical analysis of users' historical clicking data, extracting key features that reflect user behaviors. These features are used to construct a causal diagram model, which describes the intricate relationships between user preferences, news popularity, and user conformity level. The causal diagram provides a comprehensive framework for understanding how these factors interact to influence user clicks. Building upon this model, we propose a novel crowd modeling method that realistically incorporates both users' conformity level and the popularity of news. This method aims to differentiate between clicks driven by genuine user interest and those influenced by the popularity of the news, thereby addressing the bias in traditional recommendation systems. We can better capture users' true interests by calculating the match between user preferences and news content using existing recommendation techniques. To achieve unbiased news recommendations, we ensure thorough modeling of the three factors—user preferences, news popularity, and user conformity level. This multifaceted approach leverages causal intervention to provide higher-quality recommendations that reflect users' genuine interests more accurately. Our method is rigorously validated through extensive experiments on the publicly available MIND dataset. Additionally, we constructed a challenge dataset specifically designed for unbiased testing to evaluate the robustness of our recommender system in various scenarios. The results show that our CADNN method significantly outperforms existing state-of-the-art benchmark methods. Specifically, CADNN improves the average of four key metrics: *AUC*, *MRR*, *NDCG@5*, and *NDCG@10* by 1.76%, 2.37%, 3.06%, and 2.16%, respectively. These improvements underscore the effectiveness of CADNN and its potential for practical applications. Furthermore, this paper provides the implementation code and related data for CADNN, making it accessible for further research and application in related fields.

Keywords news recommendation; conformity bias; causal inference; debiased representation; click prediction

1 引 言

个性化新闻推荐技术能够帮助用户从纷繁复杂的新闻中找到用户感兴趣的新闻,对提升新闻网站的服务水平以及用户的阅读体验都有着极其重要的意义. 有大量的研究工作通过从用户的新闻历

史点击记录中挖掘用户偏好,实现准确的用户偏好建模和新闻推荐^[1-4]. 文献[1]使用门控循环网络 GRU(Gate Recurrent Unit)建模用户的历史浏览记录,用于生成用户偏好表征,进而为用户推荐合适的新闻. 文献[2]提出一种深度知识感知网络 DKN (Deep Knowledge-aware Network),通过计算候选新闻和用户历史浏览新闻的相似度进行新闻推荐.

该网络使用了注意力机制 (Attention Mechanism) 来表示用户历史点击的不同新闻对推荐结果的影响,该方法也启发了后续的很多工作,通过采用注意力机制决定不同历史点击新闻对用户偏好的重要性^[3-7]. 文献[3]提出 NAML(News recommendation with Attentive Multi-view Learning)方法,从类别、标题、内容等多角度对用户偏好进行建模,同时利用注意力机制计算不同因素对用户偏好的重要性程度,以此实现更精准的用户表征. 除了对用户进行表征之外,新闻语义的准确表示对个性化新闻推荐也十分重要,文献[4]提出了 NRMS(News Recommendation with Multi-head Self-attention)方法,使用多头注意力机制对新闻标题中的单词以及新闻标题之间的相互关系进行准确分析,实现了更准确的新闻表征与个性化新闻推荐.

除了对推荐准确性的持续研究,研究人员也发现已有的新闻推荐方法存在对有偏信息过度依赖的问题. 现有的新闻推荐模型通常是使用用户和系统

的历史交互数据进行训练,并且假定每一条日志数据 (u, i, y) 都能够无偏地反应出用户 u 对于新闻 i 的偏好 y . 但在现实世界中,用户与系统的交互数据通常是被混淆因素 (confounder) 影响,比如位置偏差、选择偏差和流行度偏差等^[8-9]. 例如文献[9]指出用户的点击行为会受到新闻流行度偏差的影响,未能反映其真实偏好. 如图 1 所示,即使用户 U_a 对新闻 N_2 并不感兴趣,但由于新闻 N_2 具有较高的热度和流行度,用户 U_a 仍然会对新闻 N_2 进行点击. 如果不加区分地基于该点击历史进行用户偏好建模,就无法准确获取用户的真实偏好,进而影响最终的推荐效果. 为了缓解有偏信息对新闻推荐方法的影响,各类去偏的方法被提出来,解耦表征学习^[10-12]、对抗学习^[13-16]、因果推断等^[8,17-20]. 其中融合因果推断方法实现无偏推荐是一个非常有潜力的研究方向,通过利用因果推断技术区分出观测数据中的虚假关联^[17],模型能够更关注反映用户偏好的真实原因,从而实现无偏推荐.

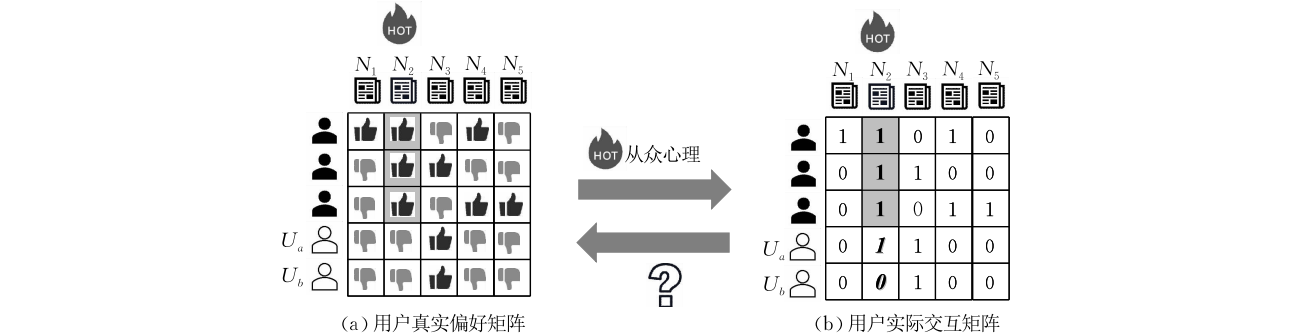


图 1 新闻推荐中的从众性偏差

目前,流行度偏差感知(考虑产品流行度对推荐结果产生的影响)的因果去偏技术主要有重加权^[21]、干预^[22-24]和反事实^[21,25]等,基于这些技术涌现了大量的研究工作,主流的方法如 MACR^[18]、PDA^[22]、DICE^[23]和 TIDE^[24]等,前期工作主要使用反事实或者使用无偏差的统一数据指导模型学习去偏表征,直接消除模型中的流行度偏差,但后续的工作认为推荐系统应该有选择地消除流行度偏差,盲目地消除流行度的影响会失去数据中隐含的重要信号,因此对流行度进行建模,从中分离出有害的从众性效应和良性的产品质量效应,再利用干预对有害的效应进行消除,并保留由产品质量引起的良性的流行度影响. 此外,有针对曝光偏差、位置偏差等偏差问题的重加权去偏方法^[21]. 这些方法都在去除推荐偏差,提升用户体验方面取得了显著效果.

但本文发现,虽然现有的因果去偏推荐方法能

够在一定程度上提升去偏的性能,但是仍然存在以下不足:大多数方法只是对有偏信息(如流行度偏差)进行直接建模,简化了有偏信息与用户行为之间的复杂关联,简单认为用户行为受到了某种偏差的影响,未从用户角度对隐藏在其点击行为背后的复杂认知因素进行准确分析. 实际上,用户的点击行为是一系列复杂认知行为相互影响之后的决策结果^[21]. 如图 1 所示,同样是面对热点流行新闻 N_2 ,用户 U_a 和用户 U_b 在用户点击行为展示上表现出了完全不同的结果. 用户 U_a 可能会因为从众心理比较强,受公众环境影响点击了自己不感兴趣的新闻,而用户 U_b 则因为从众心理比较弱,不受该情况的影响,仍然根据自己的偏好决定点击行为. 与此同时,本文也从真实数据中观测到了类似的现象. 如图 2 所示,通过对公开数据集 MIND 中的历史新闻主题分布及不同用户的历史点击记录进行分析,可以发

现用户 U4985 的历史点击主题分布与整体的新闻主题分布有比较高的重合度,说明了热点流行新闻对该用户有比较大的影响;而用户 U2206 的历史点击主题分布则比较稳定,能够从该记录中分析出该用户的偏好主题更偏向于 $\{fooddrink, lifestyle\}$ 等.同时也说明了热点流行新闻对该用户的影响程度较小.基于以上发现,可以总结出用户的点击行为是由用户偏好、用户自身特质、新闻特点等多种因素共同决定的,仅分析其中一种无法准确实现用户偏好的无偏表示学习,进而无法实现高质量的无偏推荐.




图2 MIND数据集上整体点击和用户点击新闻主题频率

基于以上发现,本文提出用户的新闻点击行为主要由以下三方面因素共同决定:用户偏好与新闻的匹配度、新闻的流行度以及用户的从众性特质,因此如何根据观测到的有偏历史点击行为数据预测出用户的真实偏好,从而进行高质量的无偏推荐成为一个极具挑战的问题.针对该挑战,本文接着提出了一种全新的从众性感知的因果去偏新闻推荐方法CADNN,该方法能够根据有偏观测数据,在考虑用户从众性特质的前提下实现高质量的无偏新闻推荐.具体而言,本文首先基于从数据中观测到的现象(图2)以及所提出的观点构建因果图,实现对影响用户点击行为的不同因素及影响关系的准确描述.基于所构建的因果图,本文分别对不同影响因素进行建模;针对用户偏好和新闻的匹配度建模,本文充分利用已有的新闻推荐方法;针对新闻的流行度衡量,受文献[26]启发,本文选择使用历史数据中新闻的点击率进行表示;针对用户的从众性建模,本文提出一种全新的基于KL(Kullback-Leibler)散度的度量方法,通过分析用户的历史点击分布与整个数据集中的新闻的被点击分布相似程度,实现了对用户的从众性的准确性分析和建模.在此基础上,对所得到的三种不同因素的结果进行融合,最终对用户的点击行为进行预测,实现用户偏好建模和无偏新闻

推荐.最后,本文在一个真实世界的公开新闻数据集MIND(MIcrosoft News Dataset)上对CADNN进行充分的实验验证,实验结果证明了CADNN方法的有效性.同时,本文基于已有数据集构建并公开更具挑战的无偏新闻推荐测试集,用于支撑无偏新闻推荐等相关方向的研究.

归纳起来,本文的主要贡献包括3个方面:

(1) 本文通过对用户新闻点击历史数据分析归纳,提出用户的点击行为是由用户偏好与新闻的匹配度、新闻的流行度以及用户的从众性特质共同决定的全新观点.

(2) 本文提出了一种全新的从众性感知的因果去偏新闻推荐方法CADNN,在新闻推荐过程中同时考虑新闻流行度和用户的从众性特质,实现了更高质量的去偏新闻推荐.

(3) 本文在公开的新闻数据集MIND上进行充分的实验,实验结果证明了本文所提出的CADNN方法的有效性.更进一步,本文构建并公开了更具挑战的无偏新闻推荐测试集,不仅证明CADNN在OOD(Out-Of-Distribution)环境下表现出强大的鲁棒性,同时能够支持相关方向的研究.

2 相关工作

本节介绍了与本文相关的研究工作,主要包括新闻推荐算法、去偏新闻推荐以及基于因果推断的推荐方法.

2.1 新闻推荐算法

新闻推荐算法是减轻信息过载和帮助用户找到自己感兴趣的新闻的重要手段,其关键在于学习准确的新闻和用户表征^[27].传统的新闻推荐方法是基于人工特征工程来学习新闻和用户表征^[28-29],但 these 方法不仅需要大量的先验知识,同时无法对新闻的上下文和序列信息进行全面建模,而这些对于理解新闻语义和用户建模都是非常重要的.伴随着深度学习的迅速发展,研究人员将深度学习中的降噪自编码器^[1]、卷积网络^[2]等相关技术应用到新闻推荐中,用于解决上述问题.为了进一步提高个性化新闻推荐的质量,后续研究引入注意力机制来选择重要新闻信息和用户特征^[3-6].文献[3]在此基础上考虑了不同类型的新闻信息,如新闻标题、类型和主体内容,并基于多视角的注意力实现利用不同类型的新闻信息来学习新闻和用户表征.为了进一步获取单词和新闻间的交互,文献[4]使用多头自注意力机

制建模新闻标题中的单词之间的相互影响,再使用注意力机制学习不同单词的重要性来进行新闻表征.随着图神经网络技术在节点和图结构表征方面表现出巨大的优势,这种技术也在新闻推荐中得到一定应用,大大提升了表征建模能力,能够学习到更准确的新闻和用户表征^[30-32].例如文献[30]提出 CNE(Collaborative News Encoding)-SUE(Structural User Encoding)框架,CNE 利用标题-内容语义交互增强新闻编码,同时 SUE 基于层次聚类的图结构表征用户兴趣以增强用户编码.文献[31]通过利用基于注意力机制的图卷积网络从用户的社交信息中建模动态用户偏好,学习动态用户表征,同时通过注意力机制联合优化新闻标题和内容来改进新闻表征.这些方法都在提高推荐准确率方面发挥了一定作用,但是过分关注准确率可能会导致推荐结果缺乏多样性,进而使用户陷入“信息茧房”,降低了用户的使用体验.

2.2 去偏新闻推荐

除了通过提升推荐准确率来改善推荐服务质量,研究人员也发现,用户的历史交互记录中是存在各类有偏信息的,例如流行度偏差、位置偏差、曝光偏差等^[10,33].这些有偏信息不仅会掩盖用户的真实偏好,同时还会被模型当作捷径进行错误学习,导致模型的泛化性能变差,最终影响实际应用效果.为此,研究人员提出了多种去偏方法^[10,33-34],用于缓解有偏信息对新闻推荐算法的影响,包括对抗学习、解耦表征学习等.对抗学习主要通过引入对抗性成分来平衡或抵消数据中的偏差,从而获得更公平和无偏的模型^[3,14,35].文献[13]和文献[14]考虑了特定敏感属性导致的推荐不公平性,利用对抗学习学习候选感知的用户表征和候选不变的用户表征进行缓解.解耦表征学习旨在分离表征与偏差相关因素,使模型更关注于任务相关特征,减少偏差影响^[36-37].例如文献[36]从产品属性表征中解耦出产品属性表征和流行度表征,通过调整流行度表征的分布缓解流行度偏差.文献[37]利用差异损失分离兴趣和从众性表征,以消除会话推荐中的流行度偏差.其他的方法如正则化^[38]、知识蒸馏^[39-40]等也被广泛用来处理推荐中的流行度偏差、曝光偏差等偏差问题^[10].

这些方法更多的是利用对抗性训练或无偏数据增强等对某种偏差进行建模,进而减少该类型偏差所造成的影响.在实际应用中,训练数据中混合的可能是不同类型的偏差,这使得为某一个偏差设计一个专用的去偏算法是不切实际的.与这些方法不同,

本文从新颖的因果推断的角度关注多种偏差效应,并利用因果关系深入分析偏差产生的原因.

2.3 基于因果推断的推荐方法

因果推断是系统分析因果关系的科学,广泛应用于医学研究^[41]、认知科学^[42]、生命科学^[43]等领域.在近几年逐渐被研究人员应用到机器学习任务中,如自然语言处理^[44]、多模态学习^[45-47]、信息检索^[48]和推荐系统^[18,22-25,49]等.融合因果推断方法目前在去偏推荐领域展现出了更大的发展潜力.一般的去偏方法无法处理潜在的混淆变量,且只能针对性地去除某种偏差,缺乏一定的泛化性,因果推断的核心是识别变量之间的不同关系,从观测数据中抽取特定变量之间的因果关系,消除变量之间存在的虚假关联,以更好地识别和控制不同的混淆变量,从而增强模型的鲁棒性和公平性^[17].

反事实推理和因果干预是因果推断中具有代表性的两类方法,两者都可以利用因果图对偏差进行建模,然后估计因果效应将偏差从用户偏好中分离,达到去偏和可解释目的^[50].反事实推理^[18,25,51-54]首先构建一个假设(反事实世界)的情况,通过比较实际观察到的情况和假设的情况,来识别因果关系并进行推断,然后从实际预测分数中扣除假设预测分数(混淆变量产生的因果效应)消除偏差的影响.例如文献[18]提出的 MACR(Model-Agnostic Counterfactual Reasoning)算法通过假设反事实情况,即排名分数是否仅使用产品属性,并基于因果图建模用户从众性、产品流行度与排名分数之间的因果关系,利用反事实推理估计产品属性对排名分数的直接效应减少流行度偏差的影响.因果干预^[22-24,49]通过主动操纵或改变某些变量推断出其中的因果关系,并通过评估这种干预对结果产生的效应进行去偏.文献[49]明确建模用户表征对预测分数的因果关系,利用后门调整估计用户历史分布这一混杂因素对最终预测分数的影响.文献[24]直接建模流行度、用户-产品匹配度与预测分数之间的因果关系,并利用时间信息从流行度中识别出良性的产品质量和有害的从众性,通过在推理阶段将从众性设为定值,消除有害流行度对结果的影响.

尽管这些方法在去偏推荐方法取得了显著效果,然而大多数方法都只是利用因果关系对有偏信息直接进行建模,利用反事实推理或干预对因果效应进行预估,忽略了有偏信息产生的原因,未深入挖掘有偏信息和用户点击行为之间的复杂关联,因而导致无偏推荐效果未有提升.相对于现有工作,本文

通过对用户历史点击数据进行观测,并深入分析用户点击行为产生的原因,提出了用户的点击行为是由用户偏好与新闻的匹配度、新闻的流行度以及用户从众性特质三种因素共同决定的观点,并基于该观点设计了一种全新的从众性感知的因果去偏新闻推荐方法,该方法通过对影响用户点击行为的不同因素的准确建模和高效融合,实现了更高质量的去偏新闻推荐。

3 CADNN 方法

在本节中,本文首先介绍了因果推断相关的预备知识,然后介绍了基于用户新闻历史点击记录分析结果的因果图构建方法;在此基础上,本文详细介绍了所提出的从众性感知的因果去偏新闻推荐方法 CADNN。

3.1 预备知识

定义 1. 因果图. 因果图是用于更好的描述数据中不同变量之间关系的一种有向无环图(Directed Acyclic Graph, DAG)表示 $\mathcal{G}=\langle V, \epsilon \rangle$, 图中的节点 V 表示变量,有向边 ϵ 表示变量之间的关系. 如图 3(a) 所示,其中 X, M, Y 分别表示因果变量、中介变量以及结果变量, $X \rightarrow Y$ 表示变量 X 对变量 Y 产生了直接效应, $X \rightarrow M \rightarrow Y$ 表示变量 X 通过中介变量 M 对变量 Y 产生了间接效应. 以新闻推荐为例, X, M, Y 可具体表示用户-新闻对、流行度特征(可包括用户流行度和产品流行度)和交互标签, $X \rightarrow M$ 表示用户-新闻对 X 决定新流行度特征 M , $X \rightarrow Y \leftarrow M$ 表示交互标签 Y 是基于用户-新闻对 X 和流行度特征 M ^[55]. 根据图 3(a) 的因果图,如果设置用户-新闻对 $X=x=(u, i)$ 表示特定的用户和新闻表征,那么流行度特征 M 的值为 $M_x=M(X=x)$ 表示特定情况下产生的流行度分布,则 Y 的值计算为

$$Y_{x,m}=Y(X=x, M=m=M_x) \quad (1)$$

其中 $Y(\cdot), M(\cdot)$ 分别表示 Y 和 M 的价值函数,在实际应用中,可以将 $Y(\cdot)$ 和 $M(\cdot)$ 实例化为神经算子(如全连接层),从而通过输入 X 预测 Y 的值.




图 3 因果图示例

定义 2. 因果效应计算. 因果效应是对同一个变量给予两种不同操作的潜在结果的比较. 根据

图 3(a) 和式(1),在治疗(即 $M=M_x=M(X=x)$)的情况下,用户-新闻对 $X=x=(u, i)$ 表示特定的用户和新闻表征,则 $Y_{x,m}$ 表示治疗产生的潜在结果;根据图 3(b),在不治疗(即 $M=M_{x^*}=M(X=x^*)$)的条件下,用户-新闻对 X 会从 x 变为 $x^*=\phi$,则 Y_{x^*,m^*} 表示不治疗产生的潜在结果,那么因果效应可以定义为两种潜在结果之间存在的差异:

$$\begin{aligned} CE &= Y_{x,M_x} - Y_{x^*,M_{x^*}} \\ &= P(y|do(X=x)) - P(y|do(X=x^*)) \quad (2) \end{aligned}$$

其中 $do(X=x)$ 和 $do(X=x^*)$ 表示对用户-新闻对 X 是否进行干预,通过将 X 设置为特定值 x 或 x^* ,从而估计治疗或者不治疗对结果 Y 的影响. 具体计算和推理过程请参见附录 I.

定义 3. 反事实推理. 反事实推理是假设在所有其他条件都不变的条件下,仅有因果变量发生变化时,推断结果变量可能出现的结果^[17]. 在实际中, $Y_{x,m}$ 通过设置用户-新闻对 X 为 $x=(u, i)$,自然会得到 $M_x=m=(p_u, p_i)$,在反事实中,根据图 3(c) 因果图, $Y_{x,M_x^*}=Y_{X=x, M=M_x^*}$ 表示将 X 设为 x 和 M 设置为当 $X=x^*$ 时的值,其实就是一个反事实推理,因为它需要相同变量 X 在不同的路径上设置不同的值,从而得到不同的结果.

本文针对目前因果去偏推荐方法中简化了有偏信息和用户行为之间的复杂关联,未从用户角度对隐藏在用户行为背后的复杂认知因素进行准确分析的问题,基于真实用户点击数据分析归纳出新闻的流行度和用户的从众性特质也会对用户的点击行为产生影响. 用户自身的从众性特质越低,新闻的流行度越低,用户偏好与新闻的匹配度就更能代表最终预测的用户行为,也意味着用户的点击行为更接近于用户真实的偏好. 为了进一步探究用户偏好与新闻的匹配度、新闻流行度和用户的从众性特质对用户点击行为的影响,本文提出利用因果图建模它们之间的因果关系,挖掘有偏信息与用户行为之间的复杂关联,并提出了一种全新的从众性感知的因果去偏新闻推荐方法,对不同的影响因素进行准确建模,基于反事实推理和因果效应计算因果图中每条路径产生的因果效应,在训练阶段利用观测数据学习不同路径的因果效应计算方法,并通过融合不同路径的因果效应实现用户行为预测;在推理阶段通过对新闻的流行度和用户的从众性特质进行干预,实现用户点击行为的无偏预测,保证最终的预测更接近于用户的真实偏好.

3.2 因果图构建

正如第 1 节引言中所描述的,在面对同一流行度的新闻时,偏好相似的两个用户会因为自身从众性特质的不同而表现出完全不同的点击行为. 因此,本文提出用户所展现的新闻点击行为是新闻内容与用户偏好的匹配程度、新闻的流行度以及用户的从众性特质所共同决定的观点. 基于该观点,本文构建了如图 4(a)所示的因果图,其中节点 U 、 I 、 C 、 S 、 R 、 M 、 Y 分别表示用户、新闻、用户的从众性特质、新闻流行度、融合从众性特质与流行度分数、用户偏好与产品的匹配分数、最终的点击概率分数,路径 $(U, I) \rightarrow M \rightarrow Y$ 表示用户真实偏好与新闻特征之间的匹配度,是本文希望模型从数据中学习到的内容,而路径 $U \rightarrow C$ 与 $I \rightarrow S$ 分别表示针对用户的从众性特质和新闻流行度属性的显式建模;路径 $(C, S) \rightarrow$

$R \rightarrow Y$ 表示用户从众性和新闻流行度的共同作用对最终结果的影响,是希望从有偏推荐模型中去除的. 通过该因果图,用户点击行为背后的复杂交互关系被准确描述出来,从而有助于用户偏好的无偏表征以及去偏新闻推荐效果的提升. 基于以上所构建的因果图,本文提出了从众性感知的因果去偏新闻推荐方法 CADNN,该方法的总体框架如图 5 所示,图中左边利用已有的新闻推荐模型计算用户偏好与新闻的匹配度分数 m_{ud} ,右边新闻流行度模块 NewsPop 计算流行度分数 s_d ,用户从众性模块 TAUC 计算用户的从众性特质分数 c^u ,三者融合预测最终的用户点击分数 \hat{y}_{ud} ,右下方表示用户的历史点击日志,其中 U_1, U_2, \dots 为用户, N_1, N_2, \dots 表示新闻,方法中所涉及的符号见表 1. 接下来,本文将详细介绍技术细节.

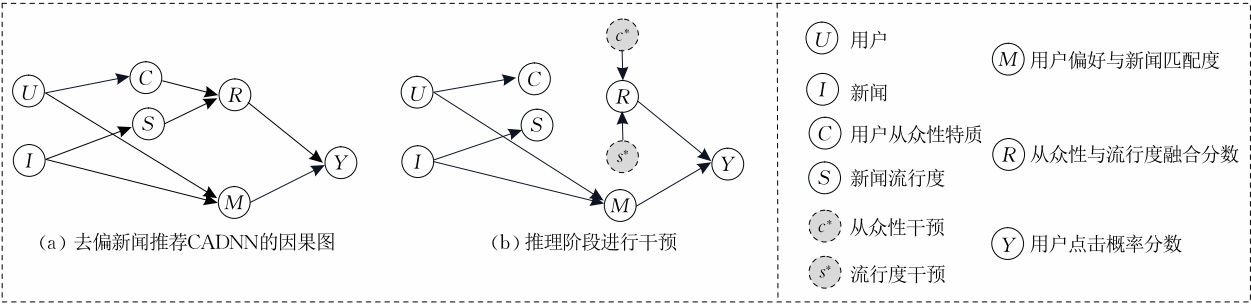


图 4 CADNN 方法的因果图

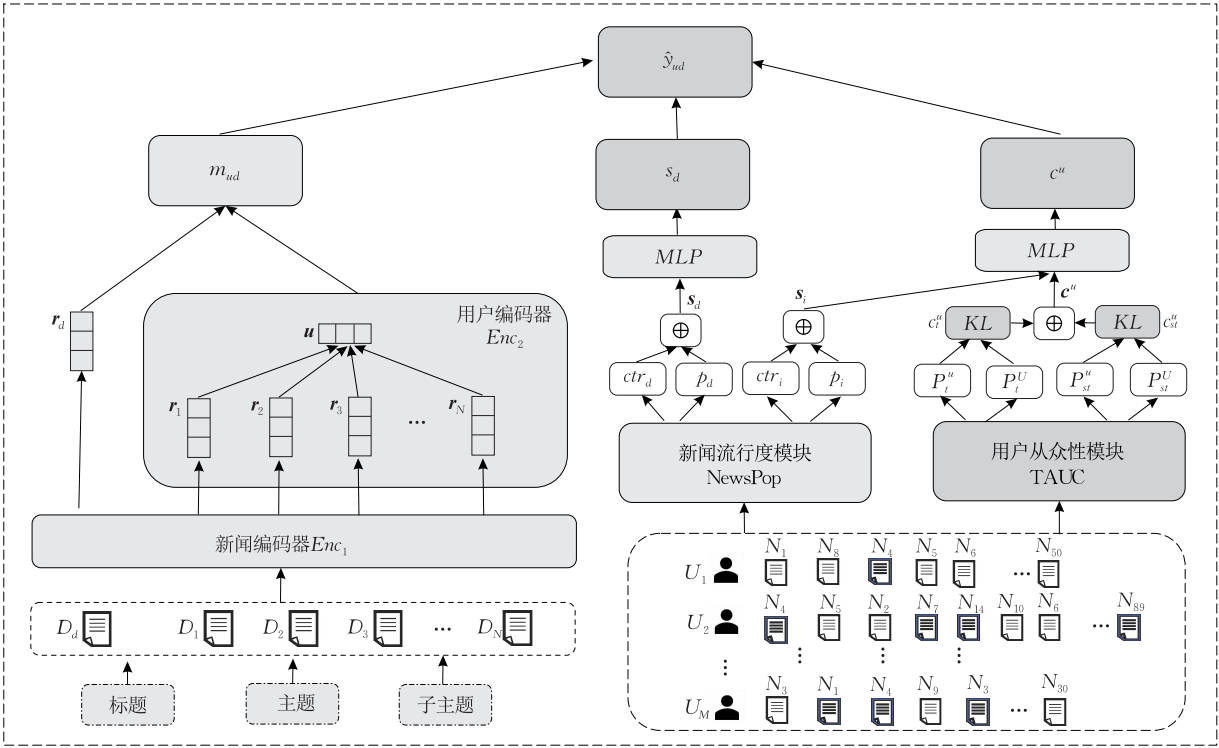


图 5 CADNN 框架图

表 1 符号注释

符号	描述
$ctr(D_i)$	新闻 D_i 的点击率
$p(D_i)$	新闻 D_i 的推荐率
s_i	新闻 D_i 的流行度表征
s_d	候选新闻 D_d 的流行度分数
N_{all}, N_u	新闻总数和用户 u 历史点击新闻数
p_t^U, p_{st}^U	整个历史新闻的主题和子主题分布
p_t^u, p_{st}^u	用户 u 历史点击新闻的主题和子主题分布
c_t^u, c_{st}^u	基于主题和子主题的用户 u 的从众性特质
c_h^u	用户 u 的从众性特质表征
c^u	用户 u 的从众性特质分数
u	用户 u 的表征
r_i	新闻 D_i 的表征
m_{ud}	用户 u 的偏好与候选新闻 D_d 的匹配度分数

3.3 从众性感知的因果去偏新闻推荐方法 CADNN

在本节中,本文首先详细介绍了图 4(a)中每条路径的因果效应计算方法,具体包括:(1)新闻流行度建模;(2)用户从众性特质建模;(3)用户偏好和新闻匹配程度建模;然后本文详细介绍了提出的 CADNN 方法的训练和推理过程.

3.3.1 新闻流行度建模

在实际场景中,新闻流行度并不是新闻的固有属性(例如标题、主题、内容等),而是在与用户的不断交互过程中通过用户点击所展现出来的.流行度越高的新闻普遍会有更高的点击率.基于该观测结果,本文同时利用用户历史点击记录中的新闻点击率和推荐率,设计了一个全新的新闻流行度衡量模块 NewsPop,用于计算新闻的流行程度,即计算图 4(a)中路径 $I \rightarrow S$ 的效应.具体而言,该模块可以形式化为如下方式:

$$ctr(D_i) = \frac{n_{click(D_i)}}{n_{rec(D_i)}} \tag{3}$$

$$p(D_i) = \frac{n_{rec(D_i)}}{\sum_{i=1}^{N_{all}} n_{rec(D_i)}} \tag{4}$$

$$s_i = ctr(D_i) \oplus p(D_i) \tag{5}$$

其中 $n_{click(D_i)}$ 表示新闻 D_i 在历史交互中被点击的次数, $n_{rec(D_i)}$ 表示新闻 D_i 在历史交互中被推荐的次数, $\sum_{i=1}^{N_{all}} n_{rec(D_i)}$ 表示所有新闻在历史交互中的推荐总数, \oplus 表示拼接操作.通过该方式,可以利用新闻的点击率和推荐率的综合信息来估计对应新闻的流行程度.

3.3.2 用户从众性建模

从众性或乐队花车效应(Bandwagon effect)是指人们受到多数人的一致思想或行动影响,而跟从大众的思想或行为^[56].受从众性影响,用户所展现

的行为在一定程度上无法反映出用户的真实偏好,从而导致模型无法准确建模用户偏好,甚至被有偏信息误导.因此,准确的用户从众性建模对无偏新闻推荐质量的提升至关重要.然而,在用户的历史点击记录中,并不存在对其从众性描述的相关信息,这对用户偏好的准确建模提出了巨大的挑战.为了解决该问题,本文提出了一种全新的主题感知的用户从众性建模模块(Topic-Aware User Conformity Modeling, TAUC).正如图 2 观测到的现象,用户的从众性可以通过对用户历史点击主题分布与整体的新闻主题分布进行分析得到,当用户的历史点击主题分布与整体的新闻主题分布有比较高的重合度时,用户更倾向于点击所推荐的热点流行新闻,其从众性特质更强.基于该发现,本文所提出的 TAUC 模块可以通过如下方式实现:

$$c_t^u = KL(p_t^u | p_t^U) \tag{6}$$

$$p_t^U = [p_{t_1}^U, p_{t_2}^U, \dots, p_{t_K}^U] \tag{7}$$

$$p_t^u = [p_{t_1}^u, p_{t_2}^u, \dots, p_{t_K}^u] \tag{8}$$

其中, KL 表示 KL 散度. $p_{t_i}^U$ 表示主题 t_i 在历史新闻数据的主题分布中的占比,即主题 t_i 在整个历史点击新闻中出现的频率, $p_{t_i}^u$ 表示主题 t_i 在用户 u 历史点击新闻的主题分布中的占比,即在用户 u 的历史点击新闻中主题 t_i 的点击率, K 表示新闻历史数据的主题数.当 c_t^u 越小时,表示用户点击历史的主题分布与整个新闻历史点击的主题分布越相似,说明用户有着越高的从众性特质,反之则说明用户的从众性特质越低.

更进一步,考虑到在实际场景中,新闻不仅拥有大类的主题,同时每个主题还有细分的子主题信息,例如主题 *news* 中包含子主题 $\{newsworld, newspolitics, newsphotos\}$ 等.细分的子主题能够以一种细粒度的方式对用户的历史点击主题分布与新闻的主题分布进行建模,从而更好地反映用户的从众性特质.图 6 中给出了图 2 中的用户在子主题上的历史点击分布与新闻的主题分布之间的关系.需要说明的是,由于子主题数量过多(超过 100 种),图 6 仅选取了在整体历史点击新闻中点击率前 10 和点击率后 10 的子主题进行展示.可以从图 6 中观测到与图 2 类似的现象:用户 U4985 点击历史新闻子主题分布与整体的历史新闻子主题分布相似,其点击的候选新闻中也更多包含子主题点击率高的新闻.因此,本文在式(6)~(8)的基础上进行改进,通过引入对子主题的建模,实现更准确的用户从众性特质建模.利用子主题建模的相关计算过程可表

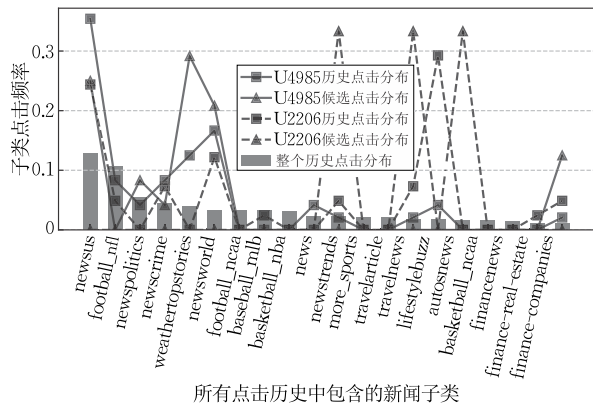


图6 MIND数据集上整体点击和用户点击新闻子类频率

示为如下形式：

$$c_{st}^u = KL(p_{st}^u | p_{st}^U) \quad (9)$$

$$p_{st}^U = [p_{st_1}^U, p_{st_2}^U, \dots, p_{st_Q}^U] \quad (10)$$

$$p_{st}^u = [p_{st_1}^u, p_{st_2}^u, \dots, p_{st_Q}^u] \quad (11)$$

其中, $p_{st_i}^U$ 表示子主题 st_i 在新闻历史数据的主题分布中的占比, $p_{st_i}^u$ 表示子主题 st_i 在用户 u 历史点击新闻的主题分布中的占比, Q 表示新闻历史数据的子主题数。

在分别利用主题和子主题信息进行计算后, 用户的从众性特质可通过以下加权融合的方式得到：

$$c_h^u = c_t^u \oplus c_{st}^u \quad (12)$$

$$w_u = \sigma(MLP(c_h^u)) \quad (13)$$

$$w_i = \sigma(MLP(s_i)) \quad (14)$$

$$c^u = \frac{\sum_{i=1}^{N_u} \varphi(w_i s_i)}{1 - w_u} \quad (15)$$

其中 $MLP(\cdot)$ 表示一个多层感知机. s_i 为用户历史点击的第 i 则新闻的流行度. $\sigma(\cdot)$ 表示 Sigmoid 激活函数. $\varphi(\cdot)$ 表示 Softplus 激活函数^[24], 确保值的正向性. 通过利用本文提出的 TAUC 模块, 可从用户的历史点击记录中准确分析用户的从众性特质。

3.3.3 用户偏好与新闻匹配度建模

在新闻推荐中, 用户偏好与新闻内容的匹配度建模是一个被广泛研究的内容, 有非常多的代表性工作被提出, 例如基于特征工程的推荐算法^[57-59], 但这些方法由于未考虑上下文和序列信息而导致无法准确建模新闻和用户表征, 后续神经网络技术的引入解决了该问题, 大大提升了用户偏好与新闻内容建模的准确性^[1-6]. 为此, 本文选择利用已有的基于神经网络的新闻推荐模型 (例如 NRML^[3] 和 NRMS^[4]) 实现对用户偏好和新闻匹配程度的建模, 如图 5 所示. 模型的输入为新闻序列, 包括用户的历

史点击新闻序列和候选新闻, 以用户 u 为例, 历史点击序列为 $D_H = [D_1, D_2, \dots, D_{N_u}]$, 其中 N_u 表示历史点击新闻数, $D_d \in D_D$ 表示候选新闻, 每则新闻 $D_i \in \{D_H, D_d\}$ 包含新闻标题 $W = [W_1, W_2, \dots, W_L]$, 其中 L 表示单词数, 主题的 ID V_t 和子主题 ID V_{st} 三种信息. 将 D_H 和 D_d 输入模型后, 通过新闻编码器 Enc_1 编码后得到新闻 D_i 的表征：

$$r_i = Enc_1(D_i) \quad (16)$$

用户的表征则是由用户的历史点击行为表示, 将得到的历史点击新闻序列 D_H 表征 $r_H = [r_1, r_2, \dots, r_{N_u}]$ 输入到用户编码器 Enc_2 得到用户 u 的表征为

$$u = Enc_2(r_H) \quad (17)$$

最后利用用户表征 u 和候选新闻表征 r_d 通过内积计算得到用户偏好和新闻的匹配分数：

$$m_{ud} = u^T r_d \quad (18)$$

3.3.4 用户点击行为预测

新闻推荐任务的目标是为用户推荐其感兴趣的新闻, 为了能够推荐符合用户偏好的新闻, 实现高质量的无偏新闻推荐, 本文基于构建的因果图在有偏的新闻数据上进行有偏学习, 分别学习用户偏好和新闻匹配度、新闻流行度以及用户的从众性特征三个影响最终点击行为的因素, 该过程可以表示为如下形式：

$$\hat{y}_{ud} = (s_d + c^u) * m_{ud} \quad (19)$$

$$s_d = \sigma(MLP(s_d)) \quad (20)$$

其中 s_d 表示新闻流行度产生的效应 ($I \rightarrow S$), s_d 表示候选新闻 D_d 的流行度, c^u 表示用户的从众性特质产生的效应 ($U \rightarrow C$). 而在推理阶段, 本文的目标是使得推荐的新闻更符合用户的偏好, 不受到新闻流行度以及用户的从众性特质的影响. 因此, 在推理阶段, 如图 4(b) 所示, 通过对 s_d 和 c^u 进行干预, 实现高质量的无偏新闻推荐. 该预测过程可以表示为如下形式：

$$\hat{y}_{ud}^* = (s^* + c^*) * m_{ud} \quad (21)$$

其中 \hat{y}_{ud}^* 表示用户 u 对新闻 d 的点击率, s^* 表示 s_d 设定的值, c^* 表示 c^u 设定的值. 为了简单起见, 在实验中将 $s^* + c^*$ 的值设置为 1, 即 $\hat{y}_{ud}^* = m_{ud}$.

3.4 模型训练

本文使用负采样技术进行模型训练. 对于用户浏览的历史新闻可以被视为一个正样本, 在没有浏览的新闻中随机抽取 K 则新闻作为负样本, 这些新闻与点击的新闻在同一会话中呈现, 但没有被该用户点击. 共同预测正面新闻 \hat{y}^+ 和 K 则负面新闻的点击概率得分为 $[\hat{y}_1^-, \hat{y}_2^-, \dots, \hat{y}_K^-]$, 将新闻点击预测

问题表述为一个 $K+1$ 类分类任务,使用 Softmax 对这些点击概率分数进行归一化,以计算一个正样本的后验点击概率:

$$\hat{p}_i = \frac{\exp(\hat{y}_i^+)}{\exp(\hat{y}_i^+ + \sum_{j=1}^K \hat{y}_{i,j}^-)} \quad (22)$$

其中, \hat{y}_i^+ 表示第 i 则点击新闻的点击概率分数, $\hat{y}_{i,j}^-$ 表示和第 i 则点击新闻在同一会话中的第 j 则未点击新闻的点击概率分数. 优化目标可形式化为

$$\argmin_{\theta} \mathcal{L} = - \sum_{i \in T_{rn}} \log(\hat{p}_i) \quad (23)$$

其中 T_{rn} 表示训练集中所有正样本.

4 实验结果与分析

在本节中,本文首先介绍了实验设置,包括基准数据集 MIND、对比方法以及模型参数设定与评估指标. 为了更好地对模型效果进行评估,本文详细介绍了基于 MIND 数据集的无偏测试集构建方法. 在此基础上,本文详细介绍并分析了相关实验结果,同时给出了相关的案例分析.

4.1 实验设置

4.1.1 实验基准数据集

本文选择 MIND 数据集作为验证数据集, MIND 是微软新闻网站的匿名行为日志中收集的一个用于新闻推荐研究的大规模数据集^[60], 该数据集提供丰富的新闻信息, 包括新闻 ID、主题、子主题、标题、摘要等. 针对用户点击行为也有丰富的记录, 包括用户 ID、时间、历史点击记录、新闻曝光与点击记录等. 本文所选取的 MIND_Small 包含 50 000 的用户历史记录. 同时为了提升结果的可靠性, 本文随机从 MIND-Large 数据集中随机抽取 150 000 的用户数据构成了新的数据集 MIND_150K. 表 2 展示了数据集的相关统计信息.

表 2 实验中使用数据集的统计信息

Datasets	#User	#News	#Clicks	#Impressions
MIND_Small	训练集	50 000	51 282	5 107 639
	验证集	50 000	42 416	2 362 514
	测试集	50 000	42 416	2 362 514
	挑战集	50 000	42 416	2 362 514
MIND_150K	训练集	150 000	75 986	14 551 181
	验证集	30 138	375 986	1 219 412
	测试集	30 328	75 986	1 229 564
	挑战集	40 190	75 986	1 620 998

4.1.2 参数设定与评价指标

由于本文所提出的 CADNN 方法是模型无偏

的,为了充分验证所提出的方法的有效性,本文选择新闻推荐中的代表性工作 NAML^[3] 和 NRMS^[4] 作为新闻编码的骨干网络进行模型效果验证. 需要说明的是, CADNN 方法也可灵活选择其他新闻编码骨干网络. 除此之外,实验使用 Glove (Global vectors for word Representation) 对单词表征进行初始化, 单词表征的维度设置为 300, 注意力向量的维度设置为 200, 负采样的比率 K 设置为 4, 模型优化器选用 Adam, 学习率初始化为 0.0001, 采用 0.2 的 dropout 防止过拟合, 批处理大小设置为 64. 除了这些统一的参数, 针对不同的骨干网络, 模型的参数设置如下: NRMS 中多头注意力的数目设置为 20, 输出的每个头的维度设置为 400. NAML 中 CNN 模块使用的过滤器数目设置为 300, 窗口大小设置为 3.

本文选择新闻推荐中常用的三个评价指标来测试 CADNN 的性能, 即受试者工作特征曲线下的面积 AUC (Area Under Curve)、平均倒数排名 MRR (Mean Reciprocal Rank) 和归一化折损累计增益 $NDCG$ (Normalized Discounted Cumulative Gain), 其中 AUC 是与训练目标直接相关的指标, AUC 的值越大说明预测的效果越好; MRR 和 $NDCG$ 是用于推荐任务中的排序指标, MRR 关注第一个相关产品的排名, $NDCG$ 评估的是排名质量, 这两个值越高, 说明推荐性能越好.

4.1.3 对比方法

为了说明本文方法的有效性, 选择了典型的去偏方法作为对比实验, 具体有:

(1) MACR^[18]. 利用因果关系建模产品对排名分数的直接影响, 使用反事实推理消除产品流行度属性对排名分数的影响.

(2) PDA^[22]. 使用因果干预切断因果图中流行度到产品之间的路径, 以此来消除产品流行度和产品之间的虚假关联.


(3) DICE^[23]. 不同于之前简单估计流行度值的方法, 该方法对用户的点击进行解耦, 基于因果推断中的碰撞效应以特定原因学习用户兴趣和从众性表征, 能够在 OOD 环境中表现更加稳健.

(4) TIDE^[24]. 基于时间从产品流行度解耦出良性偏差和有害偏差, 在训练阶段估计从众性对预测的因果效应, 并在推理阶段进行干预消除有害偏差, 同时保留良性偏差.

同时为更好地展现所提出的去偏方法的性能, 本文骨干模型 NRMS^[4] 和 NAML^[3] 也作为基准模型进行模型性能的对比.

4.2 无偏新闻推荐测试集构建

正如第 1 节中描述的,本文要解决的问题是如何从有偏观测数据中学习用户的真实偏好,从而实现无偏新闻推荐.然而,原始的 MIND 数据集并不支持该问题的评估和验证.为此,本文在原始 MIND 测试集的基础上,通过借鉴之前的工作^[22]构建了一个全新的无偏挑战测试集^①.具体而言,本文从测试集的每一个用户推荐日志中对每类主题的新闻进行随机抽取,保证每类主题新闻出现频率尽可能相等,



然后将抽取出的用户行为数据构成一个新的去偏测试集(即挑战集).相对于原始测试集,本文所构建的去偏测试集在新闻主题分布上更趋近于均匀分布,在一定程度上能够缓解新闻流行度对用户决策的影响.相关对比结果如图 7 所示.同时,从该图中还可以观察到,该测试集在每个新闻主题上的采样数量并不是完全均等,对于极小概率出现的新闻主题,仍保持一定的客观性.两个数据集所对应的无偏挑战测试集的统计信息如表 2 所示.




图 7 一般数据集和无偏挑战集的新闻主题分布

4.3 模型对比结果分析

表 3 和表 4 展示了分别以 NRMS 和 NAML 为骨干模型的各个去偏方法在不同的测试集和挑战集上的表现(黑体表示最优值,下划线表示次优值),通过对实验结果的深入分析,可以总结出以下发现:

本文的方法在不同的测试集和不同的评价标准上均取得了最优的效果.以 NAML 为骨干网络的方法为例,本文的方法在两个测试集上的每个指标都有不同程度的提升,例如在 MIND_Small 数据集上各指标提升分别为 $AUC(+0.48\%)$ 、 $MRR(+2.26\%)$ 、

$NDCG@5(+2.18\%)$ 、 $NDCG@10(+1.67\%)$,同时在两个无偏挑战测试集上也取得了最优的表现,其中在 MIND_150K 数据集上提升分别为 $AUC(+3.64\%)$ 、 $MRR(+5.97\%)$ 、 $NDCG@5(+7.02\%)$ 、 $NDCG@10(+4.86\%)$.以 NRMS 为骨干模型时,本文所提出的方法也有相似的表现.这些结果充分证明了本文所提出的方法在无偏新闻推荐上的有效性.通过深入建模影响用户点击行为的新闻流行度、用户从众性特质以及用户偏好与新闻的匹配程度,CADNN 方法实现了对用户偏好的无偏建模分析,进而提升了无偏推荐的质量.

表 3 在 MIND_Small 数据集上各模型性能对比

数据集		测试集				挑战集			
骨干	方法	AUC	MRR	NDCG@5	NDCG@10	AUC	MRR	NDCG@5	NDCG@10
NRMS	DICE	44.09	18.97	18.53	24.75	37.96	13.10	10.72	19.18
	TIDE	49.65	21.60	21.86	28.44	49.65	18.31	18.05	26.65
	PDA	64.62	30.65	33.47	39.62	66.08	29.44	33.84	41.61
	MACR	64.51	30.21	33.14	39.42	66.36	29.01	33.40	41.63
	NRMS	<u>65.62</u>	<u>31.15</u>	<u>34.01</u>	<u>40.63</u>	<u>68.21</u>	<u>30.85</u>	<u>35.92</u>	<u>43.84</u>
	CADNN	66.08	31.28	34.35	40.88	68.79	31.11	36.31	44.19
NAML	DICE	50.32	21.70	21.85	28.51	49.47	18.82	18.88	27.30
	TIDE	52.18	22.55	23.43	29.96	50.86	20.97	22.15	29.88
	PDA	55.39	23.42	24.84	31.34	57.26	22.27	24.72	32.90
	MACR	59.52	26.90	28.88	35.30	62.37	25.68	28.89	37.30
	NAML	<u>67.15</u>	<u>32.31</u>	<u>35.70</u>	<u>41.82</u>	<u>69.69</u>	<u>32.35</u>	<u>37.75</u>	<u>45.32</u>
	CADNN	67.47	33.04	36.48	42.52	70.41	32.74	38.47	45.97

① <https://github.com/NLPfreshman0/CADNN>

表 4 在 MIND_150K 数据集上各模型性能对比

数据集		测试集				挑战集			
骨干	方法	AUC	MRR	NDCG@5	NDCG@10	AUC	MRR	NDCG@5	NDCG@10
NRMS	DICE	45.27	20.40	20.03	26.36	41.46	19.29	19.10	29.07
	TIDE	55.33	27.43	29.61	35.36	54.40	28.81	32.50	40.96
	PDA	65.22	30.63	33.59	39.85	67.11	34.30	40.67	49.08
	MACR	64.97	<u>31.24</u>	34.04	40.57	<u>68.95</u>	<u>35.89</u>	<u>43.01</u>	<u>51.24</u>
	NRMS	<u>66.15</u>	31.14	<u>34.30</u>	<u>40.90</u>	67.42	34.36	41.27	46.69
	CADNN	66.46	31.75	35.08	41.38	69.99	36.41	43.97	52.04
NAML	DICE	44.40	19.70	19.14	25.41	40.02	18.70	18.07	28.07
	TIDE	54.20	27.85	29.85	35.50	54.30	29.70	33.56	41.72
	PDA	64.15	30.95	33.79	39.78	64.25	32.90	38.47	46.89
	MACR	64.79	29.74	33.20	39.29	68.10	35.27	42.05	50.25
	NAML	<u>68.20</u>	<u>33.07</u>	<u>36.54</u>	<u>42.86</u>	<u>70.14</u>	<u>36.84</u>	<u>44.17</u>	<u>52.25</u>
	CADNN	68.41	33.44	37.10	43.28	72.70	39.04	47.27	54.79

基线对比模型在保证去偏效果的同时,都出现了不定程度的推荐性能下降(即对应骨干网络的推荐性能降低).例如基线模型 MACR 在推荐性能的各评价指标上相对于骨干网络 NAML 均有超过 1%的性能下降.当骨干模型为 NRMS 时,虽然 MACR 在 MIND_150K 挑战测试集上的性能相较于骨干模型有所提升,但在一般测试集和 MIND_Small 挑战测试集上的推荐效果是下降的,说明其在不同情况下去偏效果不够稳定,这种现象说明了这些方法虽然取得了一定的去偏效果,但对用户点击新闻的行为背后的复杂认知因素未进行深入的分析,从而造成去偏学习的效果不够鲁棒,这也是本文所提出的 CADNN 方法能够取得最好效果的原因之一.

4.4 消融实验分析

第 4.3 节的整体实验结果已经证明了本文所提出的方法的有效性,然而哪个模块对模型的推荐效果的提升有更重要的作用仍然是未知的.为了进一步分析本文所提出的三方面因素对最终效果的影响程度,本文还进行了额外的消融实验,具体的实验设置如下:

(1) w/o c'' :不考虑用户从众性特质对用户点击行为的影响,即不考虑路径 $U \rightarrow C$ 的因果效应.

(2) w/o s_d :不考虑新闻流行度对用户点击行为的影响,即不考虑路径 $I \rightarrow S$ 的因果效应.

新闻流行度模块 NewsPop 和用户从众性模块 TAUC 在不同数据集上的消融实验(用户偏好与新闻的匹配度模块是新闻推荐的基础模块,不参与消融)结果如表 5 和表 6 所示.根据实验结果,可以总结出以下结论:在不考虑用户的从众性特质(w/o c'')或者新闻的流行度(w/o s_d)的情况下,模型在本文所提出的挑战集上的效果在大部分情况下会有不同程度的降低,说明了这两种因素在无偏新闻推荐中的重要性.其中在多数情况下新闻流行度对模型

的性能影响较大,说明新闻流行度是影响用户决策的更重要的因素,尽管构建的挑战集在一定程度上能够缓解不同类别的新闻流行度对用户决策的影响,但由于新闻的时效性很强,在特定的时间内用户可能更偏向于点击热点新闻.这也与相关心理学研究成果一致,一部分用户可能会更倾向于做出与群体行为一致的决策^[61].对新闻流行度偏差去偏后,用户点击行为更倾向于真实偏好,推荐性能提升.而当去偏效果足够好时,再考虑用户的从众性特质建模,可能会对模型的推荐性能起到限制作用,如 MIND_150K 数据集上以 NRMS 为骨干时考虑新闻流行度时模型的性能要比 CADNN 方法好.

表 5 在 MIND_Small 上不同因素对用户点击行为的影响

骨干	方法	AUC	MRR	NDCG@5	NDCG@10
NRMS	CADNN	68.79	31.11	36.31	44.19
	w/o c''	<u>67.55</u>	<u>30.49</u>	<u>35.46</u>	<u>43.29</u>
	w/o s_d	67.14	29.97	34.75	42.71
NAML	CADNN	70.14	32.74	38.47	45.97
	w/o c''	<u>69.94</u>	<u>32.43</u>	<u>37.86</u>	<u>45.43</u>
	w/o s_d	69.81	32.39	37.75	45.34

表 6 在 MIND_150K 上不同因素对用户点击行为的影响

骨干	方法	AUC	MRR	NDCG@5	NDCG@10
NRMS	CADNN	69.99	<u>36.41</u>	<u>43.97</u>	<u>52.04</u>
	w/o c''	<u>69.59</u>	36.83	44.24	52.24
	w/o s_d	69.30	36.22	43.44	51.59
NAML	CADNN	72.70	39.04	47.27	54.79
	w/o c''	71.98	38.59	<u>46.69</u>	54.23
	w/o s_d	<u>72.30</u>	<u>38.61</u>	46.61	<u>54.28</u>

与此同时,当以 NAML 为骨干模型时,从表 6 中可以发现在 MIND_150K 数据集上用户的从众性特质模块对性能的影响超过了新闻流行度,说明对用户从众性特质建模的必要性.本文提出的 CADNN 方法同时考虑了新闻流行度和用户的从众性特质,从而对用户所展现的点击行为进行了更全面准确的分析,进而能够实现更好的无偏新闻推荐.除此之外,本文

还发现了 CADNN 方法在 MIND_150K 数据集上展现出的不同实验结果,在该数据集上 CADNN 方法在 AUC 指标上表现最优,但在其他两个指标上,即 MRR 和 NDCG 上,未考虑用户从众性特质时的模型性能优于 CADNN. 本文分析除了上述原因外,还可能的原因是 NRMS 模型和数据集在实际推荐任

务中的综合作用,可能导致用户从众性特质模块的引入产生一定的负面影响,在一定程度上减弱了 CADNN 方法在推荐准确性方面的优势.

为了更深入分析本文所提出的 TAUC 模块在建模用户从众性方面的优势,本文对 TAUC 的不同组成部分进行了深入分析,相关实验结果如图 8 和图 9

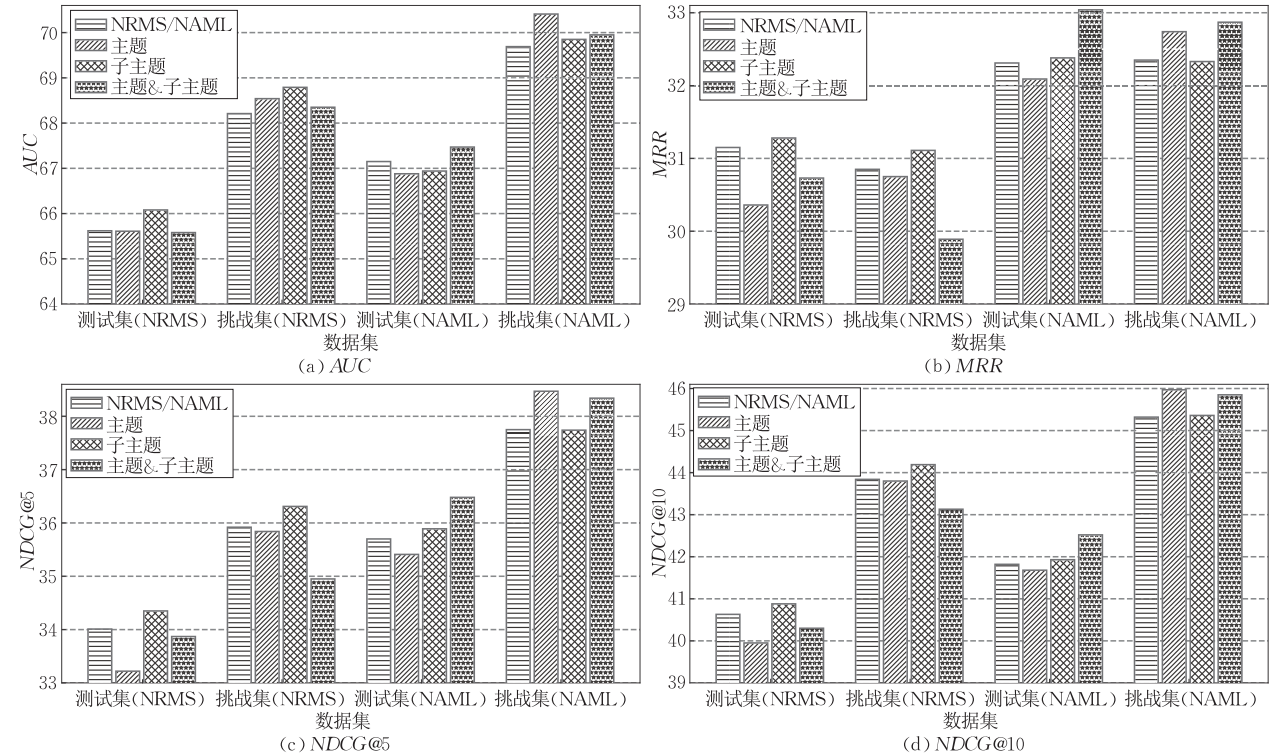


图 8 基于 MIND_Small 数据集在各评价指标上不同的组成部分对用户从众性特质建模的影响




图 9 基于 MIND_150K 数据集在各评价指标上不同的组成部分对用户从众性特质建模的影响

所示,图中横坐标表示按照不同的测试集和不同骨干网络分为四组,分别是基于原始测试集和 NRMS 骨干,基于挑战集和 NRMS,基于原始测试集和 NAML,基于挑战集和 NAML,每组均测试四种组成成分:没有建模用户的从众性特质、利用类别信息建模用户的从众性特质、利用子类别信息建模用户的从众性特质和利用类别和子类别信息共同建模用户的从众性特质,纵坐标表示不同的评价指标值,(a)、(b)、(c)、(d)分别表示评价指标 AUC 、 MRR 、 $NDCG@5$ 和 $NDCG@10$. 从这些实验结果中,可以总结出如下结论:



在原始测试集上,使用主题信息和子主题信息来共同建模用户的从众性特质在以 NAML 为骨干网络时取得了最优的效果,在以 NRMS 为骨干网络时取得了次优的效果,本文分析可能的原因是 NAML 在建模新闻表征时通过使用多视角的注意力机制从不同方面建模用户和新闻,与 TAUC 使用不同粒度的类别信息能够进行有效结合,从而实现更准确的用户从众性建模. 而 NRMS 方法并未使用多方面的信息,仅使用了新闻标题信息,因此,单独的子主题信息就已经能够提供充足的信息,增加额

外的主题信息反而会导致模型的参数量变大,从而降低了模型的效果. 与此同时,在仅使用主题信息或者仅使用子主题信息时,子主题信息能够帮助模型取得更好的效果,表明子主题信息能够帮助模型以一个更细粒度的方式建模用户的从众性.

在挑战测试集上,主题和子主题的分布更均匀,与原始测试集有较大的不同. 从实验结果中可以看出在大多数情况下使用主题信息进行建模已经可以取得最优的效果,增加子主题信息反而会因为增加模型参数或者因为子主题类别过多而带来一定的噪声信息,最终造成模型性能的下降. 与之相对的,不论是仅使用某一类主题信息,还是同时使用两种不同粒度的主题信息,本文提出的方法 CADNN 始终要优于骨干网络,也进一步说明了该方法的有效性.

4.5 案例分析

为了更形象具体展示本文所提出的 CADNN 方法的有效性,本节以用户 U35253 为例,提供了相应的案例分析. 本文分别提供了 NRMS 方法和本文所提出的 CADNN 方法为该用户推荐的 Top-10 新闻列表,并将其展示在图 10 中下面两个表格中,其



Top 10 News Recommended by CADNN				
1	N121267	lifestyle	lifestyleroyals	Meghan Markle's lawyers Debunk Multiple False Tabloid Stories in New Court Documents
2	N56602	tv	tv-celebrity	The Kardashians Face Backlash Over 'Insensitive' Family Food Fight in KUWTK Clip
3	N54558	travel	travelnews	Survey: South Carolina has the worst roads in the country
4	N107373	news	newsworld	Today in History: November 2
5	N120066	video	lifestyle	7-Year-Old Activist Calling on Crayola to Be More Eco-Friendly
6	N27669	travel	ustravel	The Coolest Way to See NYC Is in a Vintage Car From the Roaring' 20s on This Midtown Tour
7	N56505	autos	autosmotorcycles	Top 5 Craziest Motorcycles From EICMA 2019
8	N125119	sports	more_sports	Police trying to identify man seen throwing rabbit in crate into Gaston Co. lake
9	N3475	sport	football_nfl	Police not pursuing charges against Browns' Myles Garrett
10	N116161	news	newsus	Escape from Charlotte to San Antonio on a budget

Top 10 News Recommended by NRMS				
1	N14612	news	newsus	DHS Sued for Answers About Its Use of DNA Testing at the Border
2	N121267	lifestyle	lifestyleroyals	Meghan Markle's Lawyers Debunk Multiple False Tabloid Stories in New Court Documents
3	N125119	sports	more_sports	Police trying to identify, man seen throwing rabbit in crate into Gaston Co. lake
4	N3475	sports	football_nfl	Police not pursuing charges against Browns' Myles Garrett
5	N116161	news	newsus	Escape from Charlotte to San Antonio on a budget
6	N87928	movies	movies-gallery	50 Best Movie Sequels of All Time
7	N54558	travel	travelnews	Survey: South Carolina has the worst roads in the country
8	N107373	news	newsworld	Today in History: November 2
9	N54907	sports	icehockey_nhl	Greenway scores in 3rd to lift Wild over Coyotes 3-2
10	N2756	news	newsworld	AP interview: Evo Morales wants UN mediation in Bolivia

图 10 案例分析

中斜体标注的是出现在用户历史点击主题的新闻, 包含不同的主题. 图 10(a) 展示了用户 U_{35253} 的历史点击分布和推荐日志中为该用户推荐的新闻分布. 从结果中可以观察到该用户偏向于点击流行度较高的新闻主题, 所以为其推荐的候选新闻主题分布与整体的历史点击新闻主题分布趋于类似, 可以得出该用户的从众性特质较高, 容易受到新闻流行度的影响. 本文所提出的 CADNN 方法会充分考虑这两者对于用户点击行为产生的影响, 在进行推荐时会更多推荐符合该用户偏好的新闻, 例如主题 *tv* 对应的新闻 N_{56602} , 而 NRMS 方法中并未对该类主题新闻进行推荐. 同时 CADNN 方法并没有直接忽略流行度较高的新闻, 而是根据用户的真实偏好, 对历史点击中出现的同主题的流行度高的新闻也进行了推荐, 例如主题 *news* 对应的新闻 N_{107373} 、 N_{116161} 和主题 *sports* 对应的新闻 N_{125119} 、 N_{3475} , 但推荐率要远低于 NRMS 方法, 图 10(b) 展示的是为用户推荐的 Top-10 新闻列表中每类主题推荐的次数, 可以得到 NRMS 方法对于这两类新闻的推荐率为 70%, 而 CADNN 方法的推荐率仅有 40%. 与此同时, CADNN 方法会推荐更多类在用户历史点击中未出现的新闻主题, 说明该方法对用户点击行为背后的复杂因素进行了准确分析, 从而在历史点击中未涉及的新闻主题上做出了更精准的预测. 因此, 本文提出的 CADNN 方法不仅能够从用户历史行为中准确预测用户偏好, 还可以识别出潜在的用户兴趣, 为用户呈现多元化的新闻内容, 提升了推荐的效果和用户体验.

4.6 模型复杂度分析

假设新闻和用户表征都是 e 维, 候选新闻数为 N_d , 用户 u 点击的历史点击新闻数 N_u , 骨干模型 NAML 和 NRMS 的时间复杂度分别为 $\mathcal{O}(N_u e^2 + N_d e)$ 和 $\mathcal{O}(3N_u e^2 + N_u^2 e + N_d e)$, 而本文提出的方法 CADNN 在骨干模型的基础上增加了新闻流行度建模和用户从众性特质建模, 其中只有用户从众性模块 TAUC 涉及两次 KL 散度计算和一次加权求和操作, 时间复杂度增加 $\mathcal{O}(K + Q + N_u)$. 真实世界的新闻推荐系统中, 新闻的主题数 K 最大为 16, 子主题数 Q 不超过 200, 历史点击新闻数 N_u 不超过 600, 因此在实际设置中, CADNN 可以实现与骨干模型相当的时间复杂度; 同样地, 本文提出的模型参数在骨干模型上实现的是常数量级的增长, 只有 MLP 的引入导致了模型参数量的增加. 所有模型实验均在单张 NVIDIA RTX A3090 GPU 上运行.

5 结论和未来工作

针对去偏新闻推荐问题, 本文深入探究了用户点击行为背后的复杂认知因素, 提出了一种全新的从众性感知的因果去偏新闻推荐方法 CADNN. 具体而言, 本文首先通过对数据的深入分析, 提出用户的点击行为由三种不同的因素决定: 用户偏好与新闻的匹配度、新闻流行度以及用户的从众性特质的观点. 然后基于该观测结果构建对应的因果图, 用于准确描述不同变量之间的关系; 在此基础上, 本文分别提出了新闻流行度衡量模块 NewsPop, 主题感知的用户从众性建模模块 TAUC, 用于新闻流行度以及用户的从众性特质进行准确建模, 同时利用已有的方法实现用户偏好与新闻匹配度的准确建模. 接下来, 通过对不同模块的结果进行融合, 并利用因果推荐中的干预技术实现在有偏数据上的用户偏好无偏表征及新闻去偏推荐. 最后, 本文在公开的新闻推荐数据集 MIND 上进行了大量的实验, 证明了所提出方法的有效性. 同时本文构建并公开了一个更具挑战性的无偏新闻推荐测试集用于支持相关方向的研究. 在未来的工作计划中, 本文拟在用户的从众性建模以及如何将更多用户认知行为先验知识引入到无偏新闻推荐中, 实现更高质量的无偏新闻推荐方面展开相关研究.

参 考 文 献

- [1] Okura S, Tagami Y, Ono S, et al. Embedding-based news recommendation for millions of users//Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. Halifax, Canada, 2017: 1933-1942
- [2] Wang H W, Zhang F Z, Xie X, et al. DKN: Deep knowledge-aware network for news recommendation//Proceedings of the 2018 World Wide Web Conference. Lyon, France, 2018: 1835-1844
- [3] Wu C H, Wu F Z, An M X, et al. Neural news recommendation with attentive multi-view learning. arXiv preprint arXiv: 1907.05576, 2019
- [4] Wu C H, Wu F Z, Ge S Y, et al. Neural news recommendation with multi-head self-attention//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing. Hong Kong, China, 2019: 6389-6394