

# 用户生成内容场景下角色导向图神经推荐方法

娄铮铮 朱军娇 张万闯 吴 宾

(郑州大学计算机与人工智能学院 郑州 450001)

**摘要** 近年来互联网的飞速发展不断改变着信息的生产和传递方式,随之出现了用户使用互联网的新方式——用户生成内容(User-Generated Content, UGC). 该场景中内容以传播速度快、获取成本低等优势迅速占据互联网信息传播的重要地位. 不同于传统推荐场景, UGC 场景下用户同时扮演生产者和消费者双重角色, 这使得在构建推荐模型时既需要考虑消费者与内容之间的交互信息, 也需关注内容生产者对于消费者决策的影响. 因此, UGC 场景下个性化推荐算法研究的关键在于如何充分挖掘消费者-内容和消费者-生产者之间的关联关系. 在面向 UGC 场景的推荐研究中, 比较有代表性的模型为 CPRec, 该模型虽取得一定进展, 但仍存在两点不足之处. 其一, 在模型构建层面, 未能显式建模消费者-内容与消费者-生产者之间的高阶连通关系, 难以学习出高质量的节点表征. 其二, 在模型优化层面, 无法区分每个观测数据在不同训练阶段的贡献度, 将影响推荐结果的质量. 为此, 本文提出一种新颖的角色导向图神经推荐方法 RGNRec(Role-Guided Graph Neural Recommendation)用于 UGC 场景的个性化排序任务. 特别地, 基于用户的历史行为数据与内容的创作者信息分别构建了消费者-内容交互图和消费者-生产者交互图. 进一步, 为了显式捕获两种交互图中的高阶连通信息, 构建一种双通道线性传播模块, 同时刻画了消费者兴趣与内容生产者影响的扩散过程. 最终, 提出设计一种自适应的正样本权重生成策略, 将其融入非采样损失函数, 并建立双层优化机制来学习模型的参数. 本文的核心贡献包括:(1)引入双通道线性传播模块, 以显式解耦出自身兴趣与内容生产者效应对于用户偏好建模的不同贡献度;(2)提出权重自适应的非采样损失函数, 以解决不同观测样例在模型不同训练阶段贡献不同的问题. 本文分别采用经典的和最先进的图神经网络方法作为基准, 在 3 个 UGC 场景 Pinterest、Recipes 和 Reddit 下进行了实验对比. 在整体推荐性能方面, 无论模型精度亦或训练效率上均优于各基准方法, 尤其在 Precision@10 指标上获得了 4.31%~17.83% 的提升; 然后通过消融实验证明了双通道线性传播模块和权重自适应优化机制的合理性与必要性; 最后通过实验证明了本文方法在缓解数据稀疏和用户冷启动方面的优越性.

**关键词** 推荐系统; 图神经网络; 用户生成内容; 双重角色; 非采样学习

**中图法分类号** TP18      **DOI 号** 10.11897/SP.J.1016.2024.01288

## Role-Guided Graph Neural Recommendation in User-Generated Content Scenarios

LOU Zheng-Zheng ZHU Jun-Jiao ZHANG Wan-Chuang WU Bin

(School of Computer and Artificial Intelligence, Zhengzhou University, Zhengzhou 450001)

**Abstract** Personalized recommendation is a vital and indispensable tool at overcoming the information overload problem. It can help users to find their desired information and assist content providers to obtain fruitful profits. It has been widely deployed in various fields, such as news, e-commerce applications, location-based services, etc. In these classical scenarios, a user generally plays a single role (i. e., customer). With the rapid development of the Internet, we have witnessed a revolution in information production and transmission manner. In this case, there is a

收稿日期: 2023-04-18; 在线发布日期: 2024-01-30. 本课题得到国家自然科学青年基金项目(62102369)、中国博士后科学基金项目(2023M743188)和河南省重点研发与推广专项(科技攻关)(232102211045)资助. 娄铮铮, 博士, 副教授, 中国计算机学会(CCF)专业会员, 主要研究方向为机器学习、模式识别及推荐系统. E-mail: zzlou@zzu.edu.cn. 朱军娇, 硕士研究生, 主要研究方向为图神经网络、推荐系统. 张万闯, 硕士研究生, 主要研究领域为目标检测、推荐系统. 吴宾(通信作者), 博士, 副研究员, 中国计算机学会(CCF)专业会员, 主要研究领域为机器学习、推荐系统、社交网络分析及多媒体. E-mail: wubin7019088@gmail.com.

new way to access the Internet, i. e. , user-generated content (UGC). Owing to the advantages of rapid spread and easy access, it has been an important fashion of information propagation. In contrast with traditional recommendation scenarios, a user in UGC plays dual roles: consumer and producer. When building a personalized recommendation, we consider not only the consumer-item interactions, but also the impact of a producer for user decision making. Thereby, how to sufficiently capture the relationships of consumer-item and consumer-producer is the key to an effective recommendation. In the UGC-based recommendation studies, CPRec is the most representative model. Despite its effectiveness, we argue that it still has two defects. On the one hand, in perspective of model construction, it fails to explicitly exploit high-order connectivity behind consumer-item interactions and consumer-producer relationships. As a result, it is non-trivial to learn high-quality embeddings for all users and producers. On the other hand, in perspective of model optimization, it fails to differentiate the importance of each observed instance during training, which results in the suboptimal recommendation results. In light of these two defects, we propose a Role-Guided Graph Neural Recommendation (RGNRec) for the personalized ranking task in UGC scenarios. Specifically, we first construct a consumer-item interaction graph and a consumer-producer interaction graph based on the users' historical behaviors and the item's producer information. Furthermore, in order to explicitly capture the high-order connectivity, we design a dual-channel linear propagation module upon both graphs. In this way, our solution simulates the diffusion process of user interest and producer influence. Lastly, we contribute an adaptive weight strategy for the non-sampling loss function, and view the overall training procedure as a bi-level optimization problem. The key contributions of this paper are as follows: (1) introduce the dual-channel linear propagation module, which explicitly disentangles the users' motives behind individual taste and the influence of a producer; (2) propose an adaptive weighted non-sampling loss function, which could adjust the weight coefficient of each observed instance at different training periods. We choose the classical recommenders and several recent state-of-the-art graph neural networks as baselines and perform extensive experiments under three UGC scenarios: Pinterest, Recipes, Reddit. In terms of overall performance comparison, RGNRec consistently and significantly surpasses all baselines in model effectiveness and training efficiency, especially improving *Precision@10* by 4.31%–17.83%. Then, ablation studies validate the rationality and necessity of the dual-channel linear propagation module and the optimization mechanism with an adaptive weight strategy. Finally, the related experiments demonstrate the strengths of our proposed method in alleviating data sparsity and user cold-start issues.

**Keywords** recommender systems; graph neural networks; user-generated content; dual roles; non-sampling learning

## 1 引言

在当今大数据时代,推荐系统已成为缓解信息过载问题的有效技术,是各大应用领域的核心组件,如电子商务、短视频和兴趣点推荐等<sup>[1-3]</sup>。个性化推荐的深入研究不仅能够改善用户的体验,而且可以帮助商家获取丰厚的利润。在众多推荐方法中,协同过滤(Collaborative Filtering, CF)因不依赖于物品的内

容信息而广受欢迎,其变革过程为从初期基于邻域的方法<sup>[4]</sup>、早期矩阵分解模型(Matrix Factorization, MF)<sup>[5-8]</sup>、中期神经协同过滤方法<sup>[9-10]</sup>到近期图神经网络(Graph Neural Networks, GNN)<sup>[11-14]</sup>。尽管CF方法已取得显著进展,但因其仅依靠用户与物品的交互数据而面临着数据稀疏和冷启动问题<sup>[15]</sup>。

近些年,社交媒体的发展不断改变着信息生产与传递的方式,普通用户便可作为内容生产者来创作内容并上传平台。这种用户与系统产生交互的新形式

亦被称为用户生成内容(User-Generated Content, UGC)<sup>[16]</sup>场景,以传播速度快、获取成本低等优势迅速占据信息传播的重要地位。不同于电子商务应用, UGC 场景下用户同时担任两种角色:消费者和生产者;该场景中用户与内容之间的交互行为不仅源于自身的喜好,而且会明显受到内容生产者的影响<sup>[17]</sup>。因此,合理建模消费者与内容生产者之间的交互关系有助于更加准确地预测用户喜好,为缓解 CF 面临的两大问题带来些许曙光。

当前部分工作已尝试将用户的双重角色信息引入到传统 CF 方法。Wang 等人<sup>[18]</sup>对评分与评论两种行为进行建模,引入评论者和打分者双重角色来提升推荐系统的评分预测精度。与本文最相关的工作,Kang 等人<sup>[19]</sup>研究了用户担任消费者和生产者双重角色对于用户隐式反馈行为的影响,并将其融入传统矩阵分解模型。这些工作虽验证了 UGC 场景下显式建模用户双重角色的必要性,但从模型构建层面仍存在两点不足:其一,它们均未显式探讨消费者与内容之间的高阶连通关系,难以认为不流行内容学习出高质量的表征。从图 1 可观测出,存在高阶连通路径  $u_1 \rightarrow i_2 \rightarrow u_4 \rightarrow i_5$ 。倘若显式建模该路径,那么即便消费者  $u_1$  未曾访问过内容  $i_5$ ,其相应的信息仍有助于  $i_5$  的表征学习。其二,上述两种方法未能显式建模消费者与生产者的高阶连通关系,导致难以不活跃生产者刻画出高质量表征。直观上,我们可以将消费者-内容-生产者构成一个三部图并直接运用 GNN 学习节点的表征。然而,同一用户作为消费者与作为生产者时却存在信息富密度的差异,即消费行为通常远多于创作行为。这可能导致模型训练过多拟合消费行为数据,而无法充分挖掘用户作为创作者的信息。在模型优化方面,主要包括两种学习策略:基于负采样<sup>[8,12]</sup>和基于非采样<sup>[5,20]</sup>。前者基于特定的数据分布(如均匀分布)来选取负样本,并与观测样本来构建训练样例,但负样本的选取质量对于模型精度有着较大影响。为了避免负采样过程,后者将所有观测数据归为正样本,将所有未观测数据视为负样本,并将个性化排序任务转化为机器学习的回归优化问题。早期的非采样策略<sup>[5]</sup>依赖交替最小二乘法优化推荐模型参数,但矩阵求逆运算的存在使得时间复杂度与表征维度的三次方成正比。后续,文献<sup>[20-22]</sup>研究了基于梯度下降的非采样学习策略,并分别用于 MF 和 GNN 的优化。尽管已取得不错效果,但这些工作在模型的不同训练阶段为每个正样本均赋予相同的权重,导致推荐精度趋向次优。

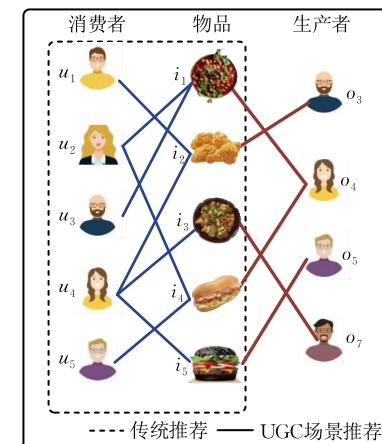


图 1 UGC 场景下食谱推荐示意图

为了解决上述问题,本文提出一种角色导向图神经推荐方法(Role-Guided Graph Neural Recommendation, RGNRec)用于 UGC 场景的个性化排序任务。具体而言,首先引入两个权重矩阵将每个用户的初始表征映射为双重角色表征,避免了因分别初始化角色表征而带来大量模型参数。随后,引入一种双通道线性传播模块,不仅解耦了内容的生产者对于消费者喜好的影响,而且捕获了消费者-内容交互图与消费者-生产者交互图中的高阶连通信息。进一步,为了满足于工业场景的需求,引入一种权重自适应的非采样学习机制来优化 RGNRec 的模型参数。该训练方式不仅能够充分发挥 GPU 的矩阵运算能力,而且保留了从全部数据样本中学习模型参数的优势。

本文的主要贡献可概括为:

- (1) 强调了用户生成内容场景下显式建模用户双重角色信息的重要性,并提出一种角色导向图神经推荐方法。
- (2) 设计双通道线性传播模块,不仅解耦出内容的创作者对于消费者决策的影响,而且捕获了两个交互图中节点之间的高阶连通信息。
- (3) 引入一种权重自适应的非采样损失函数,并运用双层优化机制来学习模型参数。
- (4) 在 3 个 UGC 场景下的实验结果表明,RGNRec 不论推荐精度亦或训练效率均显著优于最先进的推荐方法。

## 2 相关工作

与本文紧密相关的工作主要涉及传统推荐方法、UGC 推荐方法和推荐系统的模型优化 3 部分。

## 2.1 传统推荐方法

传统推荐方法侧重于如何基于用户与物品的交互信息刻画用户的喜好,期望向用户提供精准的个性化服务,这种技术亦称为 CF。在 CF 的初期时代,主要探索基于邻域的方法<sup>[4]</sup>,即依靠近邻用户(物品)与目标物品(用户)之间的相关性来预测目标用户对于特定物品的喜爱程度。受 Netflix 大赛的影响,基于 MF 的推荐模型广受业界关注<sup>[5-8]</sup>,其基本原理为:为每个用户与物品学习一个向量化表征,并采用内积函数建模该用户对于此物品的喜爱程度。受多层感知机理论上可以拟合任意函数的启发,He 等人<sup>[9]</sup>提出神经协同过滤(Neural Collaborative Filtering, NCF),并采用多层感知机增强 MF 中内积函数的建模能力。随后,He 等人<sup>[10]</sup>进一步提出卷积协同过滤方法(Convolutional Collaborative Filtering, ConvCF),采用向量外积取代内积,并运用卷积神经网络来捕获用户与物品之间的复杂交互关系。然而,这些方法将每个交互行为视为一个独立的训练实例,未能显式捕获用户与物品之间的协作信号,从而无法有效缓解数据稀疏问题。

随着 GNN 的快速发展,许多学者倾向于将其应用于推荐系统<sup>[23-25]</sup>,旨在使用图中拓扑结构信息来学习高质量的用户与物品表征。例如,受经典图卷积网络的启发,Wang 等人<sup>[12]</sup>提出一种神经图协同过滤方法(Neural Graph Collaborative Filtering, NGCF),通过嵌入多个消息传播层来显式捕获用户-物品交互图的高阶连通信息。后续,He 等人<sup>[13]</sup>通过消融实验发现 NGCF 的特征变换和非线性激活操作对模型训练未能起到积极作用,并提出轻量化图卷积网络(Light Graph Convolutional Network, LightGCN)。鉴于负样本的选择质量直接决定着模型精度,Huang 等人<sup>[14]</sup>首先通过插值方法向普通负样本中添加正样本信息以合成难负样本,然后基于池化操作将多个难负样本进行结合,最终生成高质量的虚拟负样本来训练 LightGCN 方法。为了缓解物品的长尾分布问题,Wu 等人<sup>[26]</sup>提出自监督图学习方法(Self-supervised Graph Learning, SGL),使得学习的用户与物品表征具有较高鲁棒性。为了缓解用户-物品二部图中的噪声问题,Fan 等人<sup>[27]</sup>提出图趋势过滤网络(Graph Trend Filtering Networks, GTN),以生成高质量的用户与物品表征。

## 2.2 UGC 推荐方法

伴随社交媒体平台的飞速发展,涌现出用户使

用互联网的一种新方式,即通过互联网平台既可获取他人的创作内容,同时可以对自己生产的内容进行传播。如在 Pinterest 网站中,每位用户既可以上传自己创作的图片,也可以浏览、点赞以及评论其他用户所上传的作品。Krumm 等人<sup>[16]</sup>将这种用户使用互联网的新方式统称为 UGC 场景。

不同于电子商务领域,UGC 场景下用户同时承担内容的生产者和消费者两种角色,这使得传统推荐方法无法在该场景中获得满意的个性化服务。针对这一挑战,Wang 等人<sup>[18]</sup>开创性探索了用户分别作为评论者和打分者对于评分预测任务的影响,并提出了一种融合双重角色信息的推荐模型用于评分预测任务。Kang 等人<sup>[19]</sup>讨论了用户作为消费者和生产者两种角色对于用户隐式反馈行为的影响,并提出一种角色信息增强的矩阵分解模型用于个性化排序任务。最近,Huang 等人<sup>[28]</sup>提出一种深度交互属性生成模型(Deep Interaction-Attribute-Generation, DIAG),同时将用户与物品的交互关系、用户与物品的生成关系以及物品的属性信息整合到一个统一的框架。上述 3 种推荐方法一定程度上取得了一些进展,验证了在 UGC 场景下考虑角色信息的必要性。然而,这些工作仅使用了消费者-内容及消费者-生产者之间的直接交互关系,而未能显式捕获节点之间的高阶连通信息。

## 2.3 推荐系统的模型优化

在真实推荐场景中,用户、物品及交互记录的数量通常达到百万甚至亿级规模,因此如何学习模型参数将直接影响着算法的效率和精度。从模型优化角度,一个推荐模型在学习策略上主要包括:负采样<sup>[29]</sup>和非采样<sup>[5]</sup>。前者基于特定数据分布选取合适的负样本,并协同正样本学习模型的参数<sup>[30-31]</sup>。其中,最具代表性的工作是贝叶斯个性化排序(Bayesian Personalized Ranking, BPR)<sup>[8]</sup>,其假定用户对已交互物品的喜爱要强于未观测数据,并通过均匀分布选取负样本。然而,物品的长尾分布问题使得负样本选取的质量和数量直接影响着模型精度与收敛性。更甚者,由于负采样过程的存在,使得模型训练面临 CPU 与 GPU 之间频繁切换的问题,导致无法充分发挥 GPU 的利用率。

基于非采样的学习策略通常将所有观测数据归为正样本,将所有未观测数据视为负样本,并将物品排序任务转化为机器学习的回归优化问题。典型的工作是 Hu 等人<sup>[5]</sup>提出的权重矩阵分解模型,其采

用交替最小二乘法(Alternating Least Squares, ALS)优化模型参数. 然而, 这种优化方式由于矩阵求逆运算的存在, 使得算法的时间复杂度与表征维度的立方成正比, 导致难以实现大规模工业部署. 为了解决 ALS 的效率问题, He 等人<sup>[32]</sup>提出一种元素级 ALS 用于学习 MF 的模型参数. Chen 等人提出基于小批量梯度下降法的非采样优化器, 分别用于矩阵分解<sup>[20]</sup>和因子分解机模型<sup>[33]</sup>的参数学习. 近期, Wu 等人提出快速非采样学习策略, 分别用于社会化推荐<sup>[21]</sup>和长尾物品推荐<sup>[22]</sup>任务, 最大程度发挥了 GPU 的矩阵运算能力. 尽管这些

工作缓解了非采样学习策略的效率问题, 却无法在模型训练过程中为每个正样本分配自适应的权重.

### 3 角色导向的图神经推荐模型

本节首先引入与本文密切相关的一些形式化定义; 其次详细阐述了角色导向的图神经推荐模型, 包含 3 个组件: 表征初始化、双通道线性传播以及模型预测, 其可视化如图 2 所示. 最后详细介绍模型优化过程.

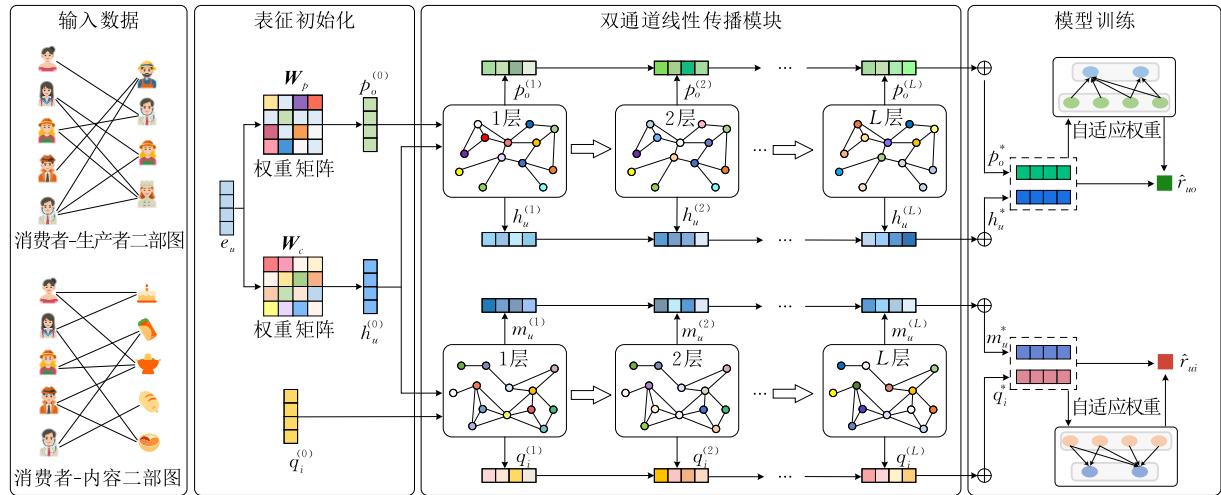


图 2 RGNRec 框架图

#### 3.1 相关定义

**定义 1.** 消费者-内容交互图.

消费者-内容交互图定义为  $G_c = (\mathcal{C} \cup \mathcal{I}, \mathcal{E})$ , 其中  $\mathcal{C} = \{c_1, c_2, \dots, c_{|\mathcal{C}|}\}$  表示消费者集;  $\mathcal{I} = \{i_1, i_2, \dots, i_{|\mathcal{I}|}\}$  表示内容集合;  $\mathcal{E}$  表示消费者与内容存在交互行为的边集. 交互矩阵  $\mathbf{R}_c$  为  $|\mathcal{C}| \times |\mathcal{I}|$  的矩阵, 且  $r_{ci} = 1$  表示消费者  $c$  访问过内容  $i$ .

**定义 2.** 消费者-生产者交互图.

消费者-生产者交互图定义为  $G_p = (\mathcal{C} \cup \mathcal{P}, \mathcal{E}')$ , 其中  $\mathcal{C}$  同定义 1,  $\mathcal{P} = \{p_1, p_2, \dots, p_{|\mathcal{P}|}\}$  表示生产者集合.  $\mathcal{E}'$  表示消费者与生产者之间的边集. 交互矩阵  $\mathbf{R}_p$  为  $|\mathcal{C}| \times |\mathcal{P}|$  的矩阵, 且  $r_{co} = 1$  表示消费者  $c$  访问过生产者  $p$  所创作的内容.

**定义 3.** 高阶连通性.

针对交互图中的任意两个节点, 如果经过  $L \geq 3$  次传递可达, 则视为这两个节点具有高阶连通性. 以交互图  $G_c$  为例, 三阶连通  $c_1 \rightarrow i_1 \rightarrow c_2 \rightarrow i_2$  表示消费者  $c_1$  尽管未访问过内容  $i_2$  但可能对其感兴趣, 由于兴趣相投的消费者  $c_2$  曾访问过内容  $i_2$ .

**定义 4.** 个性化排序任务描述.

给定消费者  $c \in \mathcal{C}$ , 内容集合  $\mathcal{I}$ , 消费者-内容交互图  $G_c$  及消费者-生产者交互图  $G_p$ . 本文的推荐目标是为消费者  $c$  提供一个排序好的个性化内容列表, 这些内容从未浏览过但却存在感兴趣的潜在可能性.

#### 3.2 表征初始化

本文采用列向量  $e_u \in \mathbb{R}^D$  和  $q_i \in \mathbb{R}^D$  来分别初始化用户  $u$  和内容  $i$  的表征, 其中  $D$  为表征向量的维度; 相应地, 所有用户和内容的表征向量可构成表征矩阵  $\mathbf{E} \in \mathbb{R}^{|\mathcal{C}| \times D}$  和  $\mathbf{Q} \in \mathbb{R}^{|\mathcal{I}| \times D}$ :

$$\mathbf{E} = [e_1^\top, e_2^\top, \dots, e_{|\mathcal{C}|}^\top], \mathbf{Q} = [q_1^\top, q_2^\top, \dots, q_{|\mathcal{I}|}^\top] \quad (1)$$

在 UGC 场景下, 每个用户承担两种角色, 倘若共用一个向量, 将导致难以刻画图  $G_p$  中消费者与生产者之间关系的有向性. 直观上, 可为每种角色单独初始化一个向量, 但该方式额外引入了大量的模型参数. 同一用户在两个交互图中节点度的富有程度显著不同, 上述方式可能导致无法为每种角色学习出高质量的表征. 为此, 本文对每个用户的两种角色共享一个初始向量, 并通过两个转换矩阵映射到不同的角色空间:

$$\mathbf{h}_u = \mathbf{W}_c e_u, \mathbf{p}_o = \mathbf{W}_p e_u \quad (2)$$

其中  $\mathbf{W}_c, \mathbf{W}_p \in \mathbb{R}^{D \times D}$ , 采用上述方式仅引入少量的参数便实现了每个用户的角色自适应.

### 3.3 双通道线性传播模块

由第 3.1 节可知, UGC 场景中包括消费者-内容交互图和消费者-生产者交互图, 如何建模二者是精确建模用户喜好的关键所在. 直观上, 我们可将其合为一个复杂异构图, 然后采用异构图神经网络学习每个节点的表征. 然而, 这种方式无法显式解离出不同因素对于用户喜好的影响. 在 UGC 场景下, 用户的决策通常受两部分影响. 其一, 消费者自身兴趣, 用于回答“消费者喜欢什么类型内容”的问题, 可通过建模消费者-内容交互图进行学习. 其二, 内容生产者效应, 用于回答“消费者青睐于何种生产者风格”的问题, 可通过建模消费者-生产者交互图进行捕获. 鉴于此, 本节设计一种双通道线性传播模块, 用于分别建模消费者-内容交互图和消费者-生产者交互图. 两种通道输入不同但结构相似, 均由两个核心组件构成: 邻居聚合和表征读出, 可显式解耦出自身兴趣与内容生产者对于用户偏好的不同贡献度.

#### 3.3.1 邻居聚合

为了显式捕获图中节点之间的高阶连通信息, GNN 成为一种流行技术, 并在节点分类、链路预测以及计算机视觉任务领域得到广泛运用<sup>[11]</sup>. GNN 的核心思想是通过执行多个图传播层为每个节点生成高质量的表征<sup>[34]</sup>. 换言之, 大多数 GNN 方法通过聚合近邻节点特征来生成目标节点的局部表达, 这种操作亦称为邻居聚合. 以消费者-生产者交互图为例, 给定消费者  $u$  在第  $l$  层表征向量  $\mathbf{h}_u^{(l)}$ , 这种邻居聚合的过程可抽象为下式:

$$\mathbf{h}_u^{(l+1)} = f(\mathbf{h}_u^{(l)}, \{\mathbf{p}_o^{(l)} | o \in \mathcal{S}_u\}) \quad (3)$$

其中  $\mathcal{S}_u$  表示与消费者  $u$  存在交互行为的生产者集合, 这里  $\mathbf{h}_u^{(0)}$  表示用户  $u$  的初始化表征经过式(2)转换得到的消费者表征向量  $\mathbf{h}_u$ ;  $\mathbf{p}_o^{(0)}$  是由式(2)得到的生产者表征向量  $\mathbf{p}_o$ ;  $f(\cdot)$  用于聚合邻居节点特征的消息聚合函数, 有多种方式实现如 GCN 的权重平均<sup>[35]</sup> 和 NGCF 的双交互聚合器<sup>[12]</sup>.

近期, He 等人<sup>[13]</sup>通过消融实验发现 GNN 中的两个常规操作——特征转换和非线性激活不仅增加了模型的复杂度而且极大降低了模型精度. 鉴于此, 本文沿用 LightGCN 所设计的线性聚合器作为传播规则:

$$\begin{aligned} \mathbf{h}_u^{(l+1)} &= \sum_{o \in \mathcal{S}_u} \frac{1}{\sqrt{|\mathcal{S}_u| |\mathcal{S}_o|}} \mathbf{p}_o^{(l)}, \\ \mathbf{p}_o^{(l+1)} &= \sum_{u \in \mathcal{S}_o} \frac{1}{\sqrt{|\mathcal{S}_o| |\mathcal{S}_u|}} \mathbf{h}_u^{(l)} \end{aligned} \quad (4)$$

其中  $\mathcal{S}_o$  表示消费过生产者  $o$  所生产内容的用户集合.

$1/\sqrt{|\mathcal{S}_u| |\mathcal{S}_o|}$  为归一化项, 用于避免多次聚合操作而导致表征值过大.

类似地, 基于消费者-内容交互图可得出以下传播规则:

$$\begin{aligned} \mathbf{m}_u^{(l+1)} &= \sum_{i \in \mathcal{N}_u} \frac{1}{\sqrt{|\mathcal{N}_u| |\mathcal{N}_i|}} \mathbf{q}_i^{(l)}, \\ \mathbf{q}_i^{(l+1)} &= \sum_{u \in \mathcal{N}_i} \frac{1}{\sqrt{|\mathcal{N}_i| |\mathcal{N}_u|}} \mathbf{m}_u^{(l)} \end{aligned} \quad (5)$$

这里  $\mathbf{m}_u^{(0)} = \mathbf{h}_u$ ,  $\mathbf{q}_i^{(0)} = \mathbf{q}_i$ ,  $\mathcal{N}_u$  表示消费者  $u$  浏览过的集合,  $\mathcal{N}_i$  表示浏览过内容  $i$  的用户集合.

#### 3.3.2 表征读出

在经过  $L$  次邻居聚合操作后, 可从消费者-生产者交互图中为每个消费者  $u$  和生产者  $o$  获取多个表征向量, 即  $\{\mathbf{h}_u^{(0)}, \dots, \mathbf{h}_u^{(L)}\}$  和  $\{\mathbf{p}_o^{(0)}, \dots, \mathbf{p}_o^{(L)}\}$ . 类似地, 可从消费者-内容交互图中获取消费者  $u$  和内容  $i$  的每层表征向量, 即  $\{\mathbf{m}_u^{(0)}, \dots, \mathbf{m}_u^{(L)}\}$  和  $\{\mathbf{q}_i^{(0)}, \dots, \mathbf{q}_i^{(L)}\}$ . 为了捕获多跳邻居信息并缓解过平滑问题, GNN 通常整合由不同传播层所生成的表征来获取节点的最终表征. 实验中, 本文尝试了注意力机制、LSTM 等多种整合方式, 但其性能均弱于最简单的平均池化操作. 因此, 为了保持模型的简单性, 本节使用平均池化生成节点的最终表征:

$$\begin{aligned} \mathbf{h}_u^* &= \frac{1}{L+1} \sum_{l=0}^L \mathbf{h}_u^{(l)}, \quad \mathbf{p}_o^* = \frac{1}{L+1} \sum_{l=0}^L \mathbf{p}_o^{(l)}, \\ \mathbf{m}_u^* &= \frac{1}{L+1} \sum_{l=0}^L \mathbf{m}_u^{(l)}, \quad \mathbf{q}_i^* = \frac{1}{L+1} \sum_{l=0}^L \mathbf{q}_i^{(l)} \end{aligned} \quad (6)$$

这里  $\mathbf{h}_u^*$  用于捕获消费者  $u$  对于不同生产者的偏好,  $\mathbf{p}_o^*$  用于捕获生产者  $o$  对于不同题材内容创作的偏好,  $\mathbf{m}_u^*$  用于捕获消费者  $u$  对于不同题材内容的喜爱,  $\mathbf{q}_i^*$  用于捕获内容  $i$  隶属于不同题材内容的分布. 需说明的是, 对于同一用户而言,  $\mathbf{h}_u^*, \mathbf{p}_o^*, \mathbf{m}_u^*$  三者关联一个核心向量  $\mathbf{e}_u$ , 且  $\mathbf{h}_u^*, \mathbf{m}_u^*$  基于相同的初始向量  $\mathbf{h}_u$  分别在图  $G_p, G_c$  进行表征传播所得到.  $\mathbf{h}_u^*, \mathbf{p}_o^*$  用于建模消费者对于内容生产者的欣赏度, 而  $\mathbf{m}_u^*, \mathbf{q}_i^*$  用于刻画消费者对于内容的喜爱度.

本文基于双通道线性传播模块学习 4 个表征向量的意义在于, 不仅整合了用户的双重角色信息, 而且能够显式解离消费者自身兴趣与内容创作者对于用户最终决策的贡献度.

#### 3.3.3 矩阵计算形式

上述双通道线性传播模块均是向量之间的运算操作, 这将导致无法充分发挥 GPU 设备的矩阵加速计算优势. 为了提升模型效率, 有必要探讨该模块的矩阵计算形式. 给定消费者-内容交互图  $G_c$  和对应的矩阵  $\mathbf{R}_c$ , 可得出该图的邻接矩阵为

$$\mathbf{A}_c = \begin{pmatrix} \mathbf{0} & \mathbf{R}_c \\ \mathbf{R}_c^T & \mathbf{0} \end{pmatrix} \quad (7)$$

假定  $\mathbf{B}^{(0)} \in \mathbb{R}^{(|\mathcal{C}|+|\mathcal{I}|) \times D}$  表示图  $G_c$  中所有节点初始表征进行拼接得到的矩阵,那么信息在该图中进行传播的矩阵化形式如下:

$$\mathbf{B}^{(l+1)} = \tilde{\mathbf{A}}_c \mathbf{B}^{(l)}, \quad \tilde{\mathbf{A}}_c = \mathbf{D}_c^{-\frac{1}{2}} \mathbf{A}_c \mathbf{D}_c^{-\frac{1}{2}} \quad (8)$$

其中  $\tilde{\mathbf{A}}_c$  为对称归一化矩阵.  $\mathbf{D}_c$  为  $(|\mathcal{C}|+|\mathcal{I}|) \times (|\mathcal{C}|+|\mathcal{I}|)$  的对角矩阵, 每个元素  $D_{tt}$  表示邻接矩阵  $\mathbf{A}_c$  中第  $t$  行的非零项数目. 迭代式(8)  $L$  次, 可得出:

$$\begin{aligned} \mathbf{F}^* &= \frac{1}{L+1} (\mathbf{B}^{(0)} + \mathbf{B}^{(1)} + \dots + \mathbf{B}^{(L)}) \\ &= \frac{1}{L+1} (\mathbf{I} + \tilde{\mathbf{A}}_c + \tilde{\mathbf{A}}_c^2 + \dots + \tilde{\mathbf{A}}_c^L) \mathbf{B}^{(0)} \\ &= \frac{1}{L+1} \sum_{l=0}^L \tilde{\mathbf{A}}_c^l \mathbf{B}^{(0)} \end{aligned} \quad (9)$$

同样地, 消费者-生产者交互图  $G_p$  上的信息传播过程亦被写为矩阵计算形式:

$$\begin{aligned} \mathbf{F}^{(l+1)} &= \tilde{\mathbf{A}}_p \mathbf{F}^{(l)}, \quad \tilde{\mathbf{A}}_p = \mathbf{D}_p^{-\frac{1}{2}} \mathbf{A}_p \mathbf{D}_p^{-\frac{1}{2}}, \\ \mathbf{F}^* &= \frac{1}{L+1} \sum_{l=0}^L \tilde{\mathbf{A}}_p^l \mathbf{F}^{(0)} \end{aligned} \quad (10)$$

其中  $\mathbf{A}_p \in \mathbb{R}^{(|\mathcal{C}|+|\mathcal{P}|) \times (|\mathcal{C}|+|\mathcal{P}|)}$  为图  $G_p$  的邻接矩阵,  $\mathbf{F}^{(0)} \in \mathbb{R}^{(|\mathcal{C}|+|\mathcal{P}|) \times D}$  为图  $G_p$  中消费者和生产者节点初始表征进行拼接得到的矩阵.

### 3.4 模型优化

#### 3.4.1 权重自适应的非采样损失函数

在模型优化阶段, 当前的图神经推荐方法大都依赖基于负采样的学习策略. 然而, 文献[14]的研究已经表明该策略所得到的模型精度高度敏感于负样本的选取质量, 且负采样过程的存在使得 CPU 与 GPU 之间频繁切换, 进而导致 GPU 的较低利用率. 为了避免这些问题, 本文选择使用非采样策略来优化 RGNRec 的模型参数. 遵循已有的非采样学习策略<sup>[21-22]</sup>, 本节采用平方损失函数作为优化目标, 分别学习两种交互图, 如式(11)所示:

$$\mathcal{L} = \sum_{u \in \mathcal{C}} \sum_{i \in \mathcal{I}} c_{ui} (r_{ui} - \hat{r}_{ui})^2 + \beta \sum_{u \in \mathcal{C}} \sum_{o \in \mathcal{P}} c_{uo} (r_{uo} - \hat{r}_{uo})^2 \quad (11)$$

其中  $\hat{r}_{ui} = \mathbf{m}_u^{*\top} \mathbf{q}_i^*$ ,  $\hat{r}_{uo} = \mathbf{h}_u^{*\top} \mathbf{p}_o^*$  分别表示用户  $u$  对内容  $i$  的喜好度及对生产者  $o$  的欣赏度.  $c_{ui}, c_{uo}$  用于控制不同的训练样本对于模型训练的贡献.

直接计算上述目标函数的时间复杂度为  $O(|\mathcal{C}| (|\mathcal{I}| + |\mathcal{P}|) D)$ , 这显然不切实际. 展开式(11)可得出:

$$\begin{aligned} \mathcal{L} &= \sum_{u \in \mathcal{C}} \sum_{i \in \mathcal{I}} c_{ui} \hat{r}_{ui}^2 - 2c_{ui} \hat{r}_{ui} r_{ui} + c_{ui} r_{ui}^2 + \\ &\quad \beta \sum_{u \in \mathcal{C}} \sum_{o \in \mathcal{P}} c_{uo} \hat{r}_{uo}^2 - 2c_{uo} \hat{r}_{uo} r_{uo} + c_{uo} r_{uo}^2 \end{aligned} \quad (12)$$

这里  $r_{ui}, r_{uo} \in \{0, 1\}$ , 将其代入上式可得:

$$\begin{aligned} \mathcal{L} &= \sum_{u \in \mathcal{C}} \sum_{i \in \mathcal{N}_u} c_{ui}^+ \hat{r}_{ui}^2 - 2c_{ui}^+ \hat{r}_{ui} + c_{ui}^+ + \sum_{u \in \mathcal{C}} \sum_{i \in \mathcal{I} \setminus \mathcal{N}_u} c_{ui}^- \hat{r}_{ui}^2 + \\ &\quad \beta \sum_{u \in \mathcal{C}} \sum_{o \in \mathcal{S}_u} c_{uo}^+ \hat{r}_{uo}^2 - 2c_{uo}^+ \hat{r}_{uo} + c_{uo}^+ + \beta \sum_{u \in \mathcal{C}} \sum_{o \in \mathcal{P} \setminus \mathcal{S}_u} c_{uo}^- \hat{r}_{uo}^2 \end{aligned} \quad (13)$$

其中  $c_{ui}^+, c_{ui}^-$  分别用于控制正负样本对于模型训练的贡献度.

整理上式可得:

$$\begin{aligned} \mathcal{L} &= \sum_{u \in \mathcal{C}} \sum_{i \in \mathcal{N}_u} (c_{ui}^+ - c_{ui}^-) \hat{r}_{ui}^2 - 2c_{ui}^+ \hat{r}_{ui} + c_{ui}^+ + \\ &\quad \beta \sum_{u \in \mathcal{C}} \sum_{o \in \mathcal{S}_u} (c_{uo}^+ - c_{uo}^-) \hat{r}_{uo}^2 - 2c_{uo}^+ \hat{r}_{uo} + c_{uo}^+ + \\ &\quad \sum_{u \in \mathcal{C}} \sum_{i \in \mathcal{I}} c_{ui}^- \hat{r}_{ui}^2 + \beta \sum_{u \in \mathcal{C}} \sum_{o \in \mathcal{P}} c_{uo}^- \hat{r}_{uo}^2 \end{aligned} \quad (14)$$

在当前的非采样学习策略研究中, 通常将正样本的权重值设定为一个超参数<sup>[21-22]</sup>或基于物品的流行度设定负样本的权重值<sup>[32]</sup>. 对于前者而言, 主要缺陷在于无法区分不同的正样本对于模型训练的贡献度. 如图 3(a)所示, 正样本  $j$  在推荐列表的排名位置更接近于底部, 如果与正样本  $i$  赋予相同的权重, 这将导致模型收敛缓慢. 更甚者, 这两种设定方式均无法在模型训练过程中为每个正样本自适应赋予一个权重值. 对比图 3(a)和图 3(b)可知, 正样本  $i$  在前者应被赋予更大的权重值. 本文首先遵循文献[21-22]设定负样本权重值为 1 的做法, 然后基于两层神经网络设计一种权重自适应的方式用于控制每个正样本对于模型训练的贡献度, 其计算方式如下:

$$\begin{aligned} z_{ui} &= \tanh(\mathbf{W}_1 \cdot [\mathbf{m}_u^*, \mathbf{q}_i^*, \mathbf{m}_u^* \odot \mathbf{q}_i^*] + \mathbf{b}_1), \\ c_{ui}^+ &= \text{softplus}(\mathbf{W}_2 \cdot z_{ui} + \mathbf{b}_2) \end{aligned} \quad (15)$$

其中  $\{\mathbf{W}_1, \mathbf{b}_1, \mathbf{W}_2, \mathbf{b}_2\}$  为可学习的模型参数. 相似地,  $c_{uo}^+$  可由下式得出:

$$\begin{aligned} z_{uo} &= \tanh(\mathbf{W}_3 \cdot [\mathbf{h}_u^*, \mathbf{p}_o^*, \mathbf{h}_u^* \odot \mathbf{p}_o^*] + \mathbf{b}_3), \\ c_{uo}^+ &= \text{softplus}(\mathbf{W}_4 \cdot z_{uo} + \mathbf{b}_4) \end{aligned} \quad (16)$$

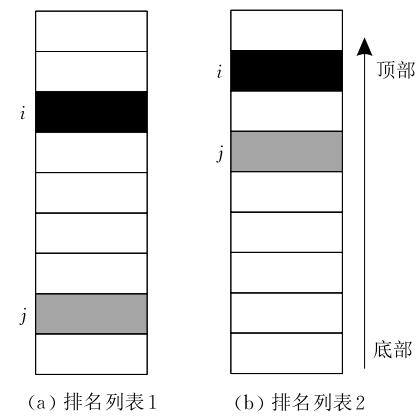


图 3 不同训练时刻下物品之间的相对排名

基于矩阵迹的性质  $\text{Tr}(\mathbf{XY}) = \text{Tr}(\mathbf{YX})$ , 并加上正则化项, 式(14)可被改写为本文提出的权重自适

应非采样损失函数:

$$\begin{aligned} \mathcal{L} = & \sum_{u \in \mathcal{C}} \sum_{i \in \mathcal{N}_u} (c_{ui}^+ - 1) \hat{r}_{ui}^2 - 2c_{ui}^+ \hat{r}_{ui} + c_{ui}^+ + \\ & \beta \sum_{u \in \mathcal{C}, o \in \mathcal{S}_u} (c_{uo}^+ - 1) \hat{r}_{uo}^2 - 2c_{uo}^+ \hat{r}_{uo} + c_{uo}^+ + \\ & \text{Tr}((\mathbf{H}_u^{*\top} \mathbf{H}_u^*) (\mathbf{P}_o^{*\top} \mathbf{P}_o^*)) + \lambda \|\boldsymbol{\Theta}\|^2 + \\ & \beta \text{Tr}((\mathbf{M}_u^{*\top} \mathbf{M}_u^*) (\mathbf{Q}_o^{*\top} \mathbf{Q}_o^*)) + \lambda' \|\boldsymbol{\Phi}\|^2 \quad (17) \end{aligned}$$

其中  $\boldsymbol{\Theta} = \{\mathbf{E}, \mathbf{Q}, \mathbf{W}_c, \mathbf{W}_p\}$ ,  $\boldsymbol{\Phi} = \{\mathbf{W}_1, \mathbf{W}_2, \mathbf{W}_3, \mathbf{W}_4, \mathbf{b}_1, \mathbf{b}_2, \mathbf{b}_3, \mathbf{b}_4\}$  为模型参数,  $\lambda$  和  $\lambda'$  为正则化系数.

### 3.4.2 双层优化机制

对于式(17),直观上可以对模型参数  $\boldsymbol{\Theta}, \boldsymbol{\Phi}$  进行联合优化. 由于权重相关项被嵌入在损失函数中,持续最小化权重值是最小化损失函数的最直接方式. 然而,这将导致权重值趋向非常小的值甚至为零. 因此,联合最小化上述损失函数将难以获取期望的自适应权重值. 受自动化机器学习的启发,本文将推荐模型与权重自适应生成的学习过程视为一个双层优化问题<sup>[36]</sup>:

$$\begin{aligned} \min_{\boldsymbol{\Phi}} \mathcal{J}_{\text{outer}}(\boldsymbol{\Theta}^*(\boldsymbol{\Phi})) &:= \mathcal{L}(\boldsymbol{\Theta}^*(\boldsymbol{\Phi})) \\ \text{s. t. } \boldsymbol{\Theta}^*(\boldsymbol{\Phi}) &= \arg \min_{\boldsymbol{\Theta}} \mathcal{J}_{\text{inner}}(\boldsymbol{\Theta}, \boldsymbol{\Phi}) := \mathcal{L}(\boldsymbol{\Theta}, \boldsymbol{\Phi}) \quad (18) \end{aligned}$$

其中  $\boldsymbol{\Theta}$  为模型结构相关的参数,  $\boldsymbol{\Phi}$  为权重自适应相关的参数,更详细的优化流程如算法 1 所示.

#### 算法 1. 模型优化的详细过程.

输入: 消费者-内容交互图  $G_c$ , 消费者-生产者交互图

$G_p$ , 学习率  $\eta$ , 正则化系数  $\lambda, \lambda'$ , 平衡系数  $\beta$

输出:  $\boldsymbol{\Theta}, \boldsymbol{\Phi}$

1. 初始化  $\boldsymbol{\Theta}, \boldsymbol{\Phi}$  中的所有参数
2. WHILE 连续 10 次迭代内模型精度有提升 DO
3. FOR  $u \in \mathcal{U}$  DO
4.  $\mathbf{h}_u = \mathbf{W}_c \mathbf{e}_u, \mathbf{p}_u = \mathbf{W}_p \mathbf{e}_u$
5. END FOR
6. //步骤 1: 学习  $\boldsymbol{\Theta}$
7. FOR  $l \in \{0, \dots, L-1\}$  DO
8. 根据式(8)和(10)计算  $\mathbf{B}^{(l+1)}$  和  $\mathbf{F}^{(l+1)}$ ;
9. END FOR
10. 根据式(9)和(10)生成  $\mathbf{B}^*$  和  $\mathbf{F}^*$ ;
11. 固定  $\boldsymbol{\Phi}$ , 通过优化  $\mathcal{J}_{\text{inner}}(\boldsymbol{\Theta}, \boldsymbol{\Phi})$  来更新  $\boldsymbol{\Theta}$
12. //步骤 2: 学习  $\boldsymbol{\Phi}$
13. 固定  $\boldsymbol{\Theta}$ , 通过优化  $\mathcal{J}_{\text{outer}}(\boldsymbol{\Theta}^*(\boldsymbol{\Phi}))$  来更新  $\boldsymbol{\Phi}$
14. END WHILE

### 3.4.3 模型讨论

(1) 模型参数量. 本文模型需学习的参数包括两部分:所有用户和内容的初始化表征向量  $\{\mathbf{E}, \mathbf{Q}\}$  以及权重参数  $\{\mathbf{W}_*, \mathbf{b}_*\}$ . 前者的参数量与用户和内容的数量呈线性相关,即  $(\mathcal{U} + \mathcal{I})D$ ,  $\mathcal{U} = \mathcal{C} \cup \mathcal{P}$ , 这与

最先进的推荐方法 SGL 和 LightGCN 一致. 后者对于所有用户和内容共享,即  $8D^2 + 4D$ . 考虑到  $D$  的取值通常远小于用户及内容的数量,因此这些额外的空间成本几乎可忽略不计.

(2) 时间复杂度. RGNRec 的计算量主要源于双通道线性传播模块、正样本权重的生成及损失函数的计算. 第 1 部分时间复杂度为  $O((|\epsilon| + |\epsilon'|)DL)$ , 第 2 部分为  $O((|\epsilon| + |\epsilon'|)D^2)$ , 第 3 部分为  $O((|\epsilon| + |\epsilon'|)D + (|\mathcal{U}| + |\mathcal{I}|)D^2)$ . 因此, RGNRec 的整体时间复杂度为  $O((|\epsilon| + |\epsilon'|)D(L + D + 1) + (|\mathcal{U}| + |\mathcal{I}|)D^2)$ .

### 3.4.4 模型预测

在模型训练完成后,可得出消费者  $u$  的表征  $\mathbf{h}_u^*$ ,  $\mathbf{m}_u^*$ , 内容  $i$  的表征  $\mathbf{q}_i^*$  以及生产者  $o$  的表征  $\mathbf{p}_o^*$ . 在 UGC 场景下,用户的决策通常由两部分决定: 用户自身兴趣和内容生产者影响. 为此,本文在模型推理阶段基于下式来估计目标用户  $u$  访问内容  $i$  的可能性:

$$\Pr(i|u, o) = \underbrace{(1-\alpha)\mathbf{h}_u^{*\top} \mathbf{p}_o^*}_{\text{用户自身兴趣}} + \underbrace{\alpha \mathbf{m}_u^{*\top} \mathbf{q}_i^*}_{\text{内容生产者效应}} \quad (19)$$

其中  $\alpha$  控制内容生产者效应对用户决策的贡献度.

## 4 实验结果及分析

### 4.1 数据集介绍

本文选取了 UGC 场景下 3 个不同规模的数据集进行实验: Pinterest、Recipes 以及 Reddit. 其中 Pinterest 数据集收集了 Pinterest 网站中用户上传、喜欢和收藏的图像; Reddit 数据集收集了 Reddit 网站 2017 年 3 月所有的内容信息及相应评论; Recipes 数据集收集了用户上传的食谱信息及对其他食谱的评论信息. 上述 3 个数据集中的每个内容仅关联一位生产者. 在对数据集进行预处理时,本文保留了数据集的 3 个主要特征: 用户编号、内容编号以及内容生产者编号.

表 1 从 6 个维度分析了 3 个数据集的统计特性. 由表中数值可知,消费者-内容之间的直接交互关系极度稀疏,即矩阵  $\mathbf{R}_c$  中绝大部分为缺失值; 相似地,可知矩阵  $\mathbf{R}_p$  中绝大部分也为缺失值. 因此,仅考虑两者之间的直接交互关系难以认为交互图中每个节点学习出高质量的表征. 进一步,图 4 以 Recipes 数据集为例,从 3 个角度展示了 Recipes 的数据分布情况,其中图 4(a)与图 4(b)为两个交互图相关的分布图. 通过分析结果可知,消费者-内容交互数

据的均值与方差为(3, 348), 消费者-生产者交互数据的均值与方差为(1.5, 10). 进一步, 从图 4(a) 和图 4(b) 可观测出大多数消费者仅有极少量的内容与生产者存在交互行为. 图 4(c) 则探讨了传播层数目  $L$  与式(10)中  $\tilde{A}_c^L$  和式(11)中  $\tilde{A}_p^L$  的关系. 不难看

出, 节点间的直接交互关系( $L=1$ )的密度极低, 但随着传播层数的增加, 其密度值显著变大. 其他两个数据集上虽未在图中展示, 但也具有同样趋势. 上述分析较好说明了显式捕获节点之间高阶连通信息的必要性.

表 1 数据集的统计特性

数据集	用户数量	内容数量	生产者数量	用户内容交互记录	消费者-内容交互稀疏度/%	消费者-生产者交互稀疏度/%
Pinterest	121 166	178 247	75 439	572 096	99.99	99.99
Recipes	71 675	89 477	4 064	218 889	99.99	99.96
Reddit	15 925	136 850	14 454	425 139	99.98	99.89

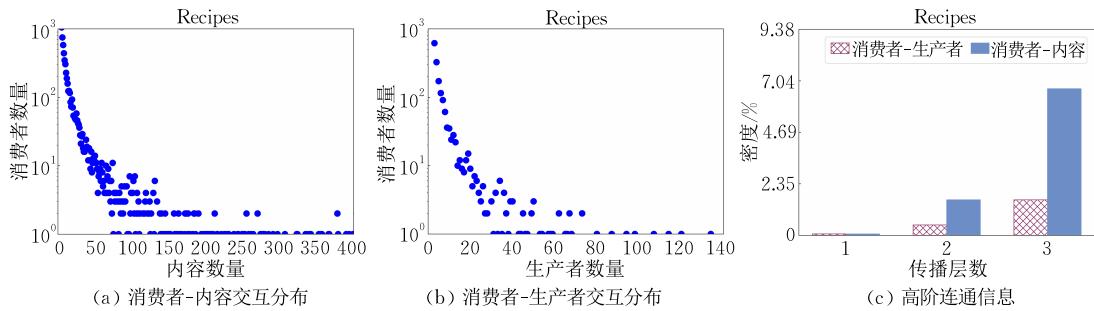


图 4 Recipes 数据集交互特性分析

## 4.2 评价指标

由于 3 个实验数据集均未提供用户访问内容时的时间戳, 因此随机选取每个用户 70% 的浏览记录作为训练数据, 10% 作为验证集, 剩余 20% 作为测试集. 在构建消费者-生产者交互图时, 本文仅考虑训练数据, 用于避免数据泄露的发生.

为了评估 RGNRec 在个性化推荐任务中的性能表现, 本文采用常见的准确率(Precision)、召回率(Recall)、平均准确率(MAP)和归一化折损累计增益(NDCG)四者作为评价指标<sup>[37-38]</sup>, 其计算方式如式(20). 式中  $l_{rec}^u$  表示系统向用户  $u$  提供的推荐列表,  $l_{tes}^u$  表示用户  $u$  在测试集中真实交互的内容列表;  $P_u(a)$  表示用户  $u$  的 Top-N 推荐列表中前  $a$  个位置的准确率;  $\delta_u(a)$  为一个指示函数, 即用户  $u$  与推荐列表第  $a$  个内容有交互为 1, 否则为 0.

$$\begin{aligned} Precision@N &= \frac{1}{|\mathcal{U}|} \sum_{u=1}^{|\mathcal{U}|} \frac{|l_{rec}^u \cap l_{tes}^u|}{N}, \\ Recall@N &= \frac{1}{|\mathcal{U}|} \sum_{u=1}^{|\mathcal{U}|} \frac{|l_{rec}^u \cap l_{tes}^u|}{|l_{tes}^u|}, \\ MAP@N &= \frac{1}{|\mathcal{U}|} \sum_{u=1}^{|\mathcal{U}|} \frac{\sum_{a=1}^N P_u(a) \delta_u(a)}{\min\{N, |l_{tes}^u|\}}, \\ NDCG@N &= \frac{1}{|\mathcal{U}|} \sum_{u=1}^{|\mathcal{U}|} \frac{\sum_{a=1}^{\min\{N, |l_{tes}^u|\}} \frac{2^{\delta_u(a)} - 1}{\log_2(a+1)}}{\sum_{a=1}^N 1/\log_2(a+1)} \quad (20) \end{aligned}$$

需注意, 文献[9-10]为了加快评测速度, 通常选取一部分负样本(如 99 个)与测试集中真实访问过的物品构成候选集, 并仅在该候选集上进行评测. 然而, 近期文献[39]研究表明评估阶段在采样环境下得出的结论存在与真实环境得出结论不一致的情况. 为了保证结论可靠性, 本文选择全样本评测, 即每个用户  $u$  在  $\mathcal{I} \setminus \mathcal{N}_u$  上进行测试.

## 4.3 基准方法及实验设置

为了验证 RGNRec 的性能, 本文选择了 6 个推荐方法来进行比较, 并在表 2 中提供了各推荐方法在 4 个属性方面的差异性.

(1) BPRMF<sup>[8]</sup>. 一种经典的成对排序推荐方法, 采用 BPR 损失函数来优化矩阵分解模型, 基于用户对内容的相对偏好生成一个排序列表.

(2) CPRec<sup>[19]</sup>. 首次讨论了角色信息对于个性化排序任务的影响, 使用矩阵分解分别建模用户-内容交互信息及捕获用户对生产者的欣赏, 初步验证了角色信息有助于提升个性化推荐的质量.

(3) ENMF<sup>[20]</sup>. 一种基于非采样学习策略的推荐方法, 采用批梯度下降法优化神经矩阵分解模型, 缓解了权重矩阵分解模型<sup>[5]</sup>因矩阵求逆操作而导致时间复杂度高的问题.

(4) LightGCN<sup>[13]</sup>. 一种基于 GNN 的协同过滤方法, 在 NGCF 基础上去除特征转换和非线性激活两种常规操作, 采用轻量化的线性图卷积模块作为

消息传播规则来捕获节点之间的高阶连通信息.

(5) GTN<sup>[27]</sup>. 为了缓解用户行为数据中的噪声问题, Fan 等人提出一种图趋势协同过滤方法,使得能够自适应捕获用户与物品之间的交互强度.

(6) MixGCF<sup>[14]</sup>. 一种负采样增强的图神经推荐方法,通过插值方法向普通负样本中添加正样本信息以合成难负样本,并基于池化操作将多个难负样本整合,进而合成虚拟的负样本来训练 LightGCN.

(7) SGL<sup>[26]</sup>. 一种为了缓解长尾问题而提出的自监督图学习框架,通过运用节点暂退、连边暂退和

随机游走 3 种方式为节点生成不同视图,以达到数据增广的目的. 需注意的是,本文仅将 SGL 用于消费者-内容交互图的建模.

为了公平起见,本文所有实验方法均基于开源推荐算法库 NeuRec 来实现. 实验中,设置表征维度  $D$  为 64, 学习速率的取值范围为 {0.001, 0.005, 0.01, 0.05}, 正则化系数的选取范围为 {1e-5, 1e-4, 1e-3, 1e-2, 0.1, 1}. ENMF 特有的超参数  $\alpha$  选取范围为 {0.005, 0.01, 0.05, 0.1, 0.2, 0.5, 1}. RGNRec 中各超参数的取值将在 4.4.6 节进行详细讨论.

表 2 基准方法属性对比

属性	BPRMF	CPRec	ENMF	LightGCN	GTN	MixGCF	SGL	RGNRec
考虑高阶信息	×	×	×	✓	✓	✓	✓	✓
引入角色信息	×	✓	×	×	×	×	×	✓
使用全样本	×	×	✓	×	×	×	×	✓
权重自适应	×	×	×	×	×	×	×	✓

## 4.4 实验结果与分析

### 4.4.1 与基准方法的推荐性能对比

表 3 展示了各推荐方法的模型参数量和 4 个评价指标上的结果. 此外, RGNRec 与最佳基准进行了成对(pair-wise)的 T 检验, 结果表明所有的性能提升具有统计稳定性, 而“\*\*”和“\*\*\*”分别表示  $p < 0.01$  和  $p < 0.001$ . 从表中可得出结论为:

(1) 在 3 个数据集上, ENMF 均优于 BPRMF, 这说明基于全样本数据的策略更易学习出较优的模型参数.

(2) 相比 BPRMF, 考虑角色信息的 CPRec 的性能均得到显著提升. 这验证了在 UGC 场景下, 显式区分用户的消费者与生产者两种角色的必要性.

(3) 在模型参数量相同的情形下, LightGCN 在 3 个数据集上的推荐性能均优于 BPRMF, 这说明显式捕获消费者-内容之间的高阶连通信息有助于消费者与内容的表征学习.

(4) GTN 取代了 LightGCN 的线性图卷积而采用图趋势过滤器来实现节点表征传播,一定程度缓解了交互数据的噪声问题,因此获得更高推荐精度. 此外, MixGCF 通过插值方法来合成难负样本以改善 LightGCN 的模型训练过程,这也验证了负样本的选择对于模型精度有较大的影响.

(5) 采用相同的信息传播规则, SGL 在 3 个数据集上的推荐精度均优于 LightGCN, 这是因为基于自监督学习的数据增广技术有助于提升模型的稳健性并缓解长尾分布问题.

(6) 有趣的是, CPRec 在 Reddit 数据集上的实

验结果在多个指标上明显优于 SGL. 由表 1 可知, Reddit 数据集中生产者与消费者重叠度高达百分之九十之多,而其他两个数据集上的重叠度相对较低,因此仅考虑消费者-生产者间的直接关系带来非常有限的性能增益.

(7) 相比最佳基准方法, RGNRec 仅额外引入了少量的参数,却在所有指标上均取得了最好的实验结果. 以 MAP@10 为例, 在 Pinterest、Recipes、Reddit 上分别取得 42.92%、6.24% 和 22.98% 的提升幅度. 这些显著的性能提升源于两方面: 其一,设计的双通道线性传播模块,不仅能够解耦出内容的生产者对于消费者喜好的影响,而且显示捕获了两个交互图中节点之间的高阶连通信息; 其二, 权重自适应的非采样优化机制更易学习出较优的模型参数.

### 4.4.2 不同推荐列表长度下的推荐性能对比

表 3 展示了各方法在推荐列表长度为 10 的实验结果,但无法确认在不同长度列表下的性能如何. 为此,图 5 讨论了  $N \in \{5, 10, 15, 20\}$  下各推荐方法的性能比较,并得出 3 个结论:

(1) RGNRec 与其他基准方法在 3 个数据集上呈现相同的变化趋势,即随着  $N$  的增加, Precision 值逐渐减小而 Recall 值逐渐变大.

(2) 相比于 BPRMF, CPRec 在不同推荐列表长度下均获得更好的实验结果,这再次验证了引入角色信息有助于更为准确地捕捉用户喜好.

(3) RGNRec 依然获得了最佳性能,这验证了消费者-内容交互图和消费者-生产者交互图两者之间的互补性,以及探索交互图中节点之间高阶连通信息的必要性.

表 3 在 3 个数据集上的实验结果(所有指标结果均乘以 100)

数据集	评价指标( $N=10$ )	BPRMF	ENMF	CPRec	LightGCN	GTN	MixGCF	SGL	RGNRec	相对提升/%
Pinterest	#Param(M)	18.2085	18.2086	18.4931	18.2085	18.2085	18.2085	18.2085	18.3063	—
	Precision	0.0831	0.1264	0.1308	0.2163	0.2466	0.2522	0.2635	<b>0.3105**</b>	17.83
	Recall	0.4464	0.6069	0.7697	1.2653	1.3533	1.4017	1.4741	<b>2.1068**</b>	42.92
	NDCG	0.2828	0.3572	0.4328	0.7434	0.8124	0.8203	0.8823	<b>1.2121***</b>	37.37
Recipes	MAP	0.1920	0.2177	0.2788	0.4922	0.5236	0.5279	0.5811	<b>0.8276***</b>	42.41
	#Param(M)	9.8359	9.8360	9.9896	9.8359	9.8359	9.8359	9.8361	9.8674	—
	Precision	0.2463	0.3099	0.2831	0.3484	0.3937	0.4322	0.3887	<b>0.4568**</b>	5.69
	Recall	1.0183	1.4875	1.1803	1.6827	1.6818	1.8125	1.7595	<b>1.9257***</b>	6.24
Reddit	NDCG	0.6726	0.9069	0.7297	0.9541	1.0620	1.1922	0.9887	<b>1.2187**</b>	2.22
	MAP	0.4278	0.5667	0.4190	0.5382	0.6442	0.7156	0.5882	<b>0.7458**</b>	4.22
	#Param(M)	9.3246	9.3247	9.4703	9.3246	9.3246	9.3246	9.3246	9.3522	—
	Precision	2.2570	2.4188	2.8104	2.5101	2.5915	3.0573	2.9838	<b>3.1892**</b>	4.31
Reddit	Recall	4.8234	4.8731	7.5874	5.5061	5.9291	6.5477	6.0136	<b>9.3311***</b>	22.98
	NDCG	4.1577	4.2735	6.0595	4.5453	4.6946	5.5416	5.2956	<b>7.0125**</b>	15.72
	MAP	2.3230	2.3387	3.5621	2.4373	2.5664	3.0463	2.9161	<b>4.2286***</b>	18.71

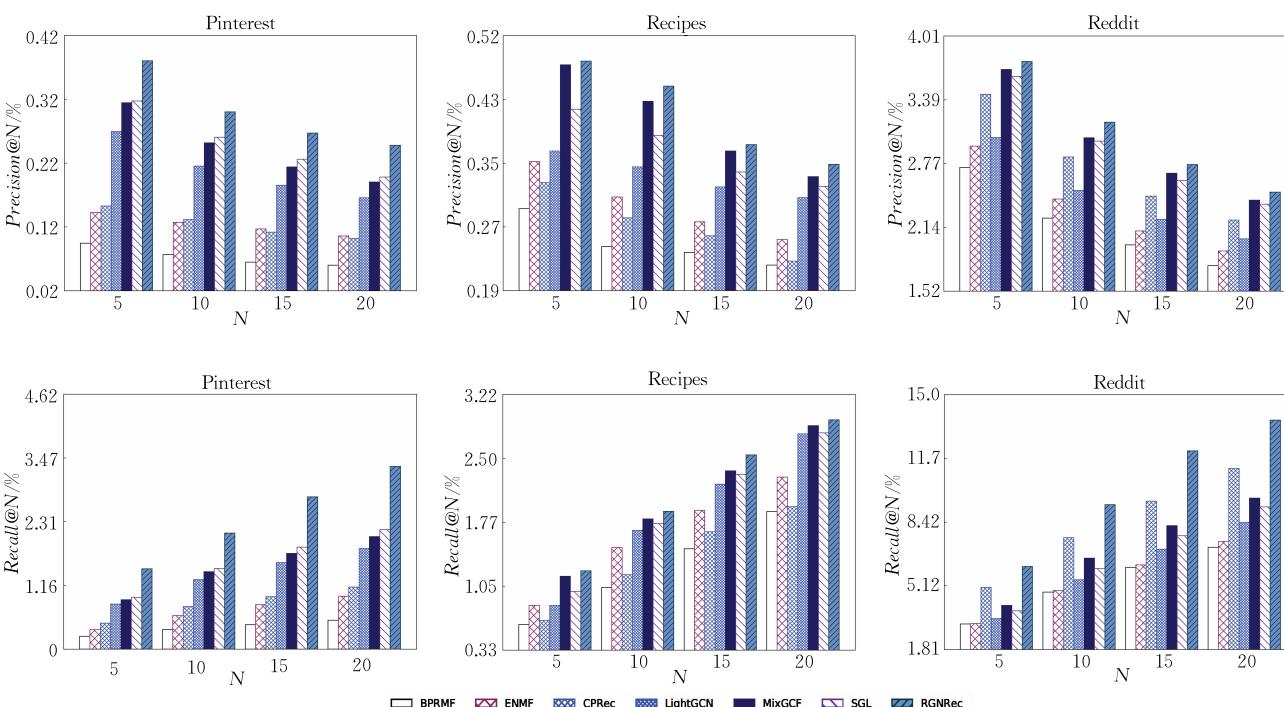


图 5 不同推荐列表长度下各基准方法与 RGNRec 的实验结果对比

#### 4.4.3 消融实验

为验证本文方法各关键部分对推荐结果的影响,本实验设计 4 个变种,表 4 展示了在 3 个数据集上的消融实验. 其中,RGNRec w/o RC 表示去除了角色转换步骤并对用户的两种角色共享一个初始向量,RGNRec w/o RD 表示去除了双线性传播模块,RGNRec w/o UN 表示使用 BPR 损失函数来优化本文的模型参数,而 RGNRec w/o AW 则是使用文献[21]中快速非采样策略替换权重自适应非采样策略. 由表 4 可得出 3 个结论:

(1) RGNRec 略优于 RGNRec w/o RC,验证了角色自适应转换的必要性. 事实上,消费者与生产者

之间的关系具备有向性,两种角色共享一个初始化向量不仅无法有效捕获该性质,而且难以解离出用户自身兴趣与生产者对于用户决策的影响.

(2) 相比于本文方法,RGNRec w/o RD 在 3 个数据集上的推荐结果显著下降. 这是因为消费者与内容交互矩阵和消费者与生产者交互矩阵极度稀疏,仅依赖两两之间的直接交互关系难以学习高质量的节点表征,进而导致无法准确预测用户的兴趣.

(3) RGNRec w/o AW 的实验结果要远好于基于负采样学习策略的 RGNRec w/o UN 变种,这是因为前者采用全样本数据学习策略更有助于学习出较优的模型参数,该结论与文献[29]的发现一致. 进

表 4 消融实验( $N=10$ )

方法	Pinterest		Recipes		Reddit	
	Precision	NDCG	Precision	NDCG	Precision	NDCG
RGNRec w/o RC	0.2902(-6.9%)	1.1648(-4.1%)	0.3967(-15.1%)	0.9603(-26.9%)	2.8979(-10.1%)	6.5591(-6.91%)
RGNRec w/o RD	0.2015(-54.0%)	0.7239(-67.4%)	0.3386(-34.9%)	0.9402(-29.6%)	2.8561(-11.6%)	6.3711(-10.1%)
RGNRec w/o UN	0.2309(-34.4%)	0.8278(-46.4%)	0.4197(-8.8%)	1.1432(-6.6%)	2.8516(-11.8%)	6.2895(-11.5%)
RGNRec w/o AW	0.2966(-4.6%)	1.1915(-1.7%)	0.4356(-4.8%)	1.1969(-1.8%)	3.1502(-1.2%)	6.9423(-1.1%)
RGNRec	<b>0.3105</b>	<b>1.2121</b>	<b>0.4568</b>	<b>1.2187</b>	<b>3.1892</b>	<b>7.0125</b>

一步,采用权重自适应的 RGNRec 获得了最佳的结果,这验证了图 3 假设的成立.

#### 4.4.4 冷启动用户实验分析

一个推荐方法在冷启动用户上的推荐质量将直接决定在工业场景中的实用性,因此有必要探讨 RGNRec 在这类用户上的推荐精度.对于每个数据集,本文将训练集中浏览内容数量少于 5 的消费者视为冷启动用户.表 5 提供了各推荐方法在冷启动用户集上 Precision@10 的结果,分析可得:

(1) 在冷启动用户集上,CPRec 的准确率均优于 BPRMF,这说明额外融入内容的生产者信息有助于缓解用户的冷启动问题.

(2) 在冷启动用户集上,BPRMF 和 ENMF 的推荐精度均显著差于 LightGCN 和 SGL,这说明仅依赖于消费者自身的行信息难以为冷启动用户学习高质量的表征,而显式建模消费者与内容之间的高阶连通信息有助于改善这些用户的表征学习.

(3) 在 3 个冷启动用户集上,RGNRec 均显著优于其他基准方法,说明联合使用消费者-内容和消费者-生产者之间高阶连通信息的必要性.此外,在 Pinterest 和 Reddit 数据集上冷启动用户的受益要多于在 Recipes 数据集上.细微观察表 1 可知,Recipes 中生产者占比(5.6%)远低于其他两个数据集,这使得内容生产者对于消费者决策影响较小.

表 5 冷启动用户上各推荐方法的 Precision@10 比较

数据集	用户集	BPRMF	ENMF	CPRec	LightGCN	MixGCF	SGL	RGNRec	相对提升/%
Pinterest	全体用户	0.0831	0.1264	0.1308	0.2163	0.2522	0.2635	<b>0.3105</b>	17.83
	冷启动用户	0.0352	0.0404	0.1230	0.1120	0.1206	0.1279	<b>0.1535</b>	20.01
Reddit	全体用户	2.2570	2.4188	2.8104	2.5101	<u>3.0573</u>	2.9712	<b>3.1892</b>	4.31
	冷启动用户	0.8021	0.3892	<u>1.4334</u>	0.8549	0.9617	0.9361	<b>1.8061</b>	26.00
Recipes	全体用户	0.2463	0.3099	0.2831	0.3484	<u>0.4322</u>	0.3887	<b>0.4568</b>	5.69
	冷启动用户	0.1340	0.1671	0.1282	0.2293	0.2356	0.2226	<b>0.2537</b>	7.68

#### 4.4.5 训练效率分析

当前大多数推荐方法专注于推荐性能的提升,而忽略了模型训练效率.鉴于一个推荐方法的运行时间将决定着大规模工业部署的可能性,本实验讨论了 RGNRec 与各基准方法的训练效率.为了对比公平,本节所有实验均在同一台机器上进行,其运行时间与显存占用情况如表 6 所示.其中,NV 表示模型训练时显存的占用大小,PE 表示单次迭代的时间,TT 表示达到最佳性能时总运行时间,表中的单位 s,m,h 分别代表秒、分、时:

(1) 基于相同的采样策略优化推荐模型,LightGCN 占用的显存多于 BPRMF,这是因为前者采用三层图卷积来修正用户和物品表征的学习.尽管 RGNRec 额外建模了消费者-生产者交互图,但相比 LightGCN 仅多使用了较少的显存消耗,这说明了

本文方案的合理性.

(2) 每个推荐方法在 Pinterest 数据集上的总训练时间比在其他数据集上更长,这是因为该数据集的交互记录要多于其他数据集.

(3) 由于图卷积模块的引入,LightGCN 的单次迭代时间要多于 BPRMF. CPRec 在每个数据集上的运行时间也要多于 BPRMF,这是因为角色信息的融入额外增加了模型的计算量.

(4) 尽管 RGNRec 引入了双通道线性传播模块,但无论单次迭代亦或总训练时间均显著少于其他基准方法.这么显著的模型训练效率主要得益于本文所设计的权重自适应非采样学习机制,其能够最大程度发挥 GPU 的矩阵运算能力.总而言之,本文的 RGNRec 方法能够在精确度和训练效率之间达到较好的权衡,为大规模工业部署带来了曙光.

表 6 各推荐方法在 3 个数据集上的效率对比

方法	Pinterest			Reddit			Recipes		
	NV	PE	TT	NV	PE	TT	NV	PE	TT
BPRMF	<b>1.35 GB</b>	2.65 s	12.37 m	<b>0.85 GB</b>	1.82 s	1.82 m	<b>0.84 GB</b>	1.00 s	12.00 s
ENMF	21.93 GB	0.18 s	45.18 s	23.04 GB	0.08 s	33.68 s	16.85 GB	0.12 s	57.24 s
CPRec	<u>1.60 GB</u>	5.47 s	34.73 m	<u>1.11 GB</u>	2.54 s	20.32 m	<u>1.11 GB</u>	2.04 s	2.15 m
LightGCN	2.60 GB	7.32 s	35.50 m	1.60 GB	3.37 s	21.29 m	1.60 GB	1.97 s	7.88 s
GTN	15.63 GB	51.97 s	1.08 h	7.49 GB	5.03 s	6.03 m	1.92 GB	23.00 s	16.1 m
MixGCF	3.02 GB	86.77 s	1.57 h	2.21 GB	12.77 s	1.92 m	2.29 GB	1.5 m	3.53 h
SGL	16.63 GB	35.54 s	4.87 h	9.61 GB	13.01 s	12.21 m	8.61 GB	6.76 s	40.56 s
RGNRec	2.63 GB	<b>0.06 s</b>	<b>40.16 s</b>	2.61 GB	<b>0.03 s</b>	<b>26.17 s</b>	2.30 GB	<b>0.03 s</b>	<b>5.83 s</b>

#### 4.4.6 超参数敏感性分析

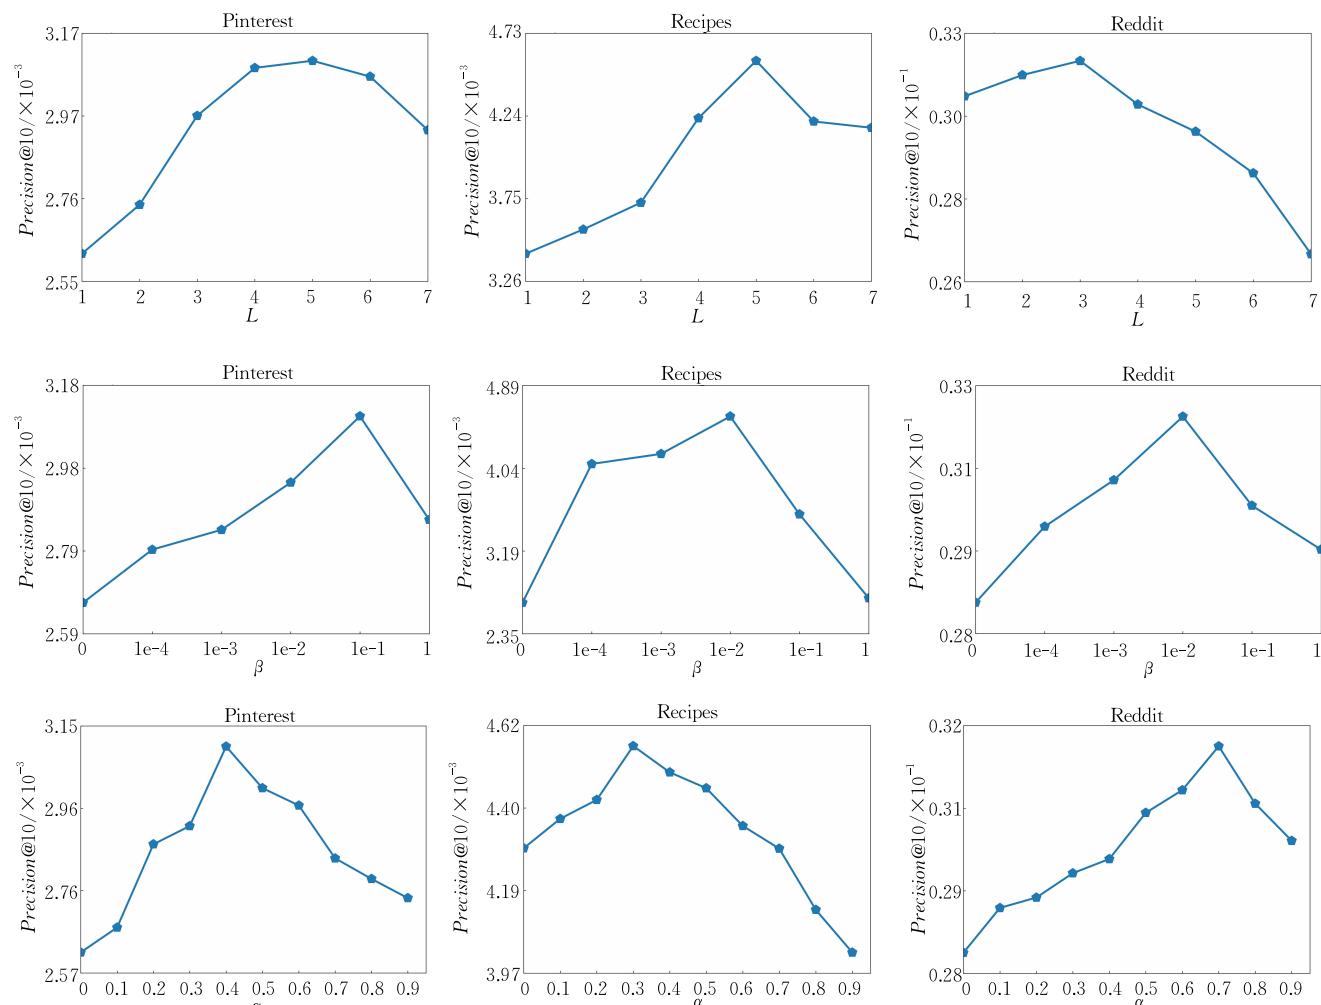
对于 RGNRec 而言,超参数  $L, \alpha, \beta$  直接影响着推荐结果的准确率,有必要讨论在不同取值下的性能,其中  $L$  的取值范围为  $\{1, 2, 3, 4, 5, 6, 7\}$ ,  $\beta$  的取值范围为  $\{0, 1e-4, 1e-3, 1e-2, 1e-1, 1\}$ ,  $\alpha$  的取值范围为  $\{0, 0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9\}$ . 图 6 对 3 个超参数进行了敏感性分析,由实验结果可知:

(1)  $L$  的取值直接决定着各节点表征的学习质量,

其推荐精度呈现先增加后减小趋势. 这表明过少的图传播层难以学习出高质量的节点表征,而过大的  $L$  值将使得节点表征的可区分性降低导致过平滑问题.

(2)  $\beta$  的取值决定着模型训练阶段生产者角色对于用户表征学习的贡献度. 取值为 0 意味着模型参数的学习仅依赖消费者-内容交互图,而随着取值增大内容生产者的影响增强. 但取值过大将会导致模型参数的学习过度依赖消费者-生产者交互图.

(3)  $\alpha$  的取值决定着模型预测阶段消费者自身

图 6 3 个数据集上超参数  $L, \beta, \alpha$  的敏感性分析

兴趣与内容生产者效应对用户决策的不同贡献度。 $\alpha$  取值为 0 意味着模型预测阶段仅依赖消费者自身的兴趣, 而随着取值增大内容生产者效应趋向增强。但取值过大将导致模型预测过度依赖于内容生产者效应而丧失了自身的品味。因此, 合理的取值是 RGNRec 取得最佳推荐结果的关键。

## 5 总结与展望

在倡导个性化、用户主导信息生产与传播的时代, UGC 推荐方法以引入角色信息打破了传统推荐方法完全依赖于用户-物品历史交互建模用户偏好的固有模式。针对当前 UGC 推荐方法存在的不足之处, 本文提出了一种角色导向图神经推荐方法 RGNRec, 其主要包括角色自适应转换和双通道线性传播模块。前者基于一个核心向量实现同一用户的双重角色身份转换, 后者用于显式捕获消费者-内容与消费者-生产者两种交互图中的高阶连通信息。为了使得 RGNRec 拥有部署在大规模工业场景中的潜力, 进一步设计了权重自适应的非采样学习机制来优化模型参数。在 3 个数据集上的综合实验表明, 本文方法在推荐精确度及训练效率上均显著优于经典的和最先进的推荐方法。

本文提出的 UGC 推荐方法潜在假设消费者的行为之间是无序的, 而未能关注用户兴趣的动态变化<sup>[40-42]</sup>。静态的行为建模方式可能难以准确识别出消费者的真实意图, 因此如何设计一种序列推荐方法用于 UGC 场景是一个值得研究的问题。其次, 本文的研究重心主要在图结构数据上, 而未能考虑内容相关的非结构数据(如文本<sup>[43]</sup>、图像<sup>[44]</sup>)。这些非结构化数据中含有丰富的语义关联信息, 因此如何耦合这些数据辅助消费者行为建模也是一个值得探索的方向<sup>[45-46]</sup>。

## 参 考 文 献

- [1] Smith B, Linden G. Two decades of recommender systems at Amazon. com. IEEE Internet Computing, 2017, 21(3): 12-18
- [2] Yi Z, Wang X, Ounis I, et al. Multi-modal graph contrastive learning for micro-video recommendation//Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval. Madrid, Spain, 2022: 1807-1811
- [3] Long J, Chen T, Nguyen Q V H, et al. Decentralized collaborative learning framework for next POI recommendation. ACM Transactions on Information Systems, 2023, 41(3): 1-25
- [4] Sarwar B, Karypis G, Konstan J, et al. Item-based collaborative filtering recommendation algorithms//Proceedings of the 10th International Conference on World Wide Web. Hong Kong, China, 2001: 285-295
- [5] Hu Y, Koren Y, Volinsky C. Collaborative filtering for implicit feedback datasets//Proceedings of the 8th IEEE International Conference on Data Mining. Pisa, Italy, 2008: 263-272
- [6] Koren Y, Bell R, Volinsky C. Matrix factorization techniques for recommender systems. Computer, 2009, 42(8): 30-37
- [7] Wu Bin, Lou Zheng-Zheng, Ye Yang-Dong. Co-regularized matrix factorization recommendation algorithm. Journal of Software, 2018, 29(9): 2681-2696(in Chinese)  
(吴宾, 娄铮铮, 叶阳东. 联合正则化的矩阵分解推荐算法. 软件学报, 2018, 29(9): 2681-2696)
- [8] Rendle S, Freudenthaler C, Gantner Z, et al. BPR: Bayesian personalized ranking from implicit feedback//Proceedings of the 25th Conference on Uncertainty in Artificial Intelligence. Montreal, Canada, 2009: 452-461
- [9] He X N, Liao L Z, Zhang H W, et al. Neural collaborative filtering//Proceedings of the 26th International Conference on World Wide Web. Perth, Australia, 2017: 173-182
- [10] He X, Du X, Wang X, et al. Outer product-based neural collaborative filtering//Proceedings of the 27th International Joint Conference on Artificial Intelligence. Stockholm, Sweden, 2018: 2227-2233
- [11] Xu Bing-Bing, Cen Ke-Ting, Huang Jun-Jie, et al. A survey on graph convolutional neural network. Chinese Journal of Computers, 2020, 43(5): 755-780(in Chinese)  
(徐冰冰, 岑科廷, 黄俊杰等. 图卷积神经网络综述. 计算机学报, 2020, 43(5): 755-780)
- [12] Wang X, He X N, Wang M, et al. Neural graph collaborative filtering//Proceedings of the 42nd international ACM SIGIR Conference on Research and Development in Information Retrieval. Paris, France, 2019: 165-174
- [13] He X N, Deng K, Wang X, et al. LightGCN: Simplifying and powering graph convolution network for recommendation//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. Xi'an, China, 2020: 639-648
- [14] Huang T L, Dong Y X, Ding M, et al. MixGCF: An improved training method for graph neural network-based recommender systems//Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. Singapore, 2021: 665-674
- [15] Anwar T, Uma V, Hussain M I, et al. Collaborative filtering and knn based recommendation to overcome cold start and sparsity issues: A comparative analysis. Multimedia Tools and Applications, 2022, 81(25): 35693-35711
- [16] Krumm J, Davies N, Narayanaswami C. User-generated content. IEEE Pervasive Computing, 2008, 7(4): 10-11