

# 在线社交网络中点阻塞策略下虚假信息关注度最小化研究

倪培昆<sup>1)</sup> 朱建明<sup>1)</sup> 高玉昕<sup>1)</sup> 王国庆<sup>2)</sup>

<sup>1)</sup>(中国科学院大学应急管理科学与工程学院 北京 100049)

<sup>2)</sup>(中国科学院大学工程科学学院 北京 100049)

**摘 要** 在线社交网络中的信息影响着人们的观点或看法,混杂在其中的虚假信息必然对人们的判断和决策产生误导.人们对虚假信息的关注度越高就越容易受到虚假信息的误导,从而做出非理性甚至激进的行为.为构建和谐的网络生态环境,本文探索了点阻塞策略下虚假信息关注度最小化问题以及最小化用户被虚假信息激活时对虚假信息的总关注度.首先,考虑用户对虚假信息的关注度构建一个关注度级联模型,并借助库伦定律来刻画虚假信息扩散过程中用户对虚假信息关注度的演化.其次,证明了点阻塞策略下虚假信息关注度最小化问题的复杂性以及该问题目标集函数的非次模性和非超模性.然后,将关注度最小化问题转化为关注度下降最大化问题,借助离散函数的连续化技术以及集函数的凹闭合函数设计了一种近似投影次梯度算法.最后,在三个真实的数据集中验证了本文构造算法和模型的有效性,实验模拟结果表明了本文开发的算法优于现存的启发式算法,并且得出用户对虚假信息的关注度是影响虚假信息治理的重要因素.

**关键词** 虚假信息;关注度;点阻塞;Lovász扩展;近似投影次梯度

**中图法分类号** TP18 **DOI号** 10.11897/SP.J.1016.2024.02725

## Research on Minimizing Misinformation Attention by Nodes Blocking Strategy in Online Social Networks

NI Pei-Kun<sup>1)</sup> ZHU Jian-Ming<sup>1)</sup> GAO Yu-Xin<sup>1)</sup> WANG Guo-Qing<sup>2)</sup>

<sup>1)</sup>(School of Emergency Management Science and Engineering, University of Chinese Academy of Sciences, Beijing 100049)

<sup>2)</sup>(School of Engineering Science, University of Chinese Academy of Sciences, Beijing 100049)

**Abstract** Information in online social networks influences people's views and opinions. Misinformation mixed in it is bound to mislead people's judgment and decision-making, and is particularly likely to cause people to panic, dissatisfaction and other emotions. The more people pay attention to misinformation, the more likely they are to be misled by it and engage in irrational or even aggressive behavior. When dealing with misinformation, we should try our best to avoid situations where misinformation leads people to engage in extreme behavior, that is, to reduce users' attention to misinformation as much as possible. However, minimizing user attention to misinformation is different from minimizing the number of users affected by misinformation, and it is a new problem that existing methods or technologies still face some difficulties in tackling. Therefore, we propose the misinformation attention minimization problem by nodes blocking strategy, where the goal is to minimize the total attention of users to misinformation when they are activated by misinformation. Firstly, this paper takes the classic information propagation model -

收稿日期:2023-12-12;在线发布日期:2024-09-06. 本课题得到国家自然科学基金项目(No. 72074203)资助. 倪培昆,博士,主要研究领域为数据与社交网络分析、组合优化. E-mail: nipeikun@ucas.ac.cn. 朱建明(通信作者),博士,教授,主要研究领域为应急管理、网络优化. E-mail: jmzhu@ucas.ac.cn. 高玉昕,博士研究生,主要研究领域为网络优化. 王国庆,博士,副教授,主要研究领域为决策与优化和应急管理.

the independent cascade model as the basis, and considers the user's attention to misinformation to construct an attention cascade model for the spread of misinformation. The Coulomb's theorem, which describes the interaction force between stationary point charges, is leveraged to characterize the evolution of users' attention to misinformation during the spread of misinformation. Secondly, the NP-hard of the problem of minimizing the misinformation attention by the node blocking strategy in social networks is demonstrated. The non-negative and non-monotonicity, non-submodularity and non-supermodularity of the objective set function of the problem of minimizing the misinformation attention by the node blocking strategy, as well as the #P-hardness of the computation are also verified. Thirdly, we introduce a parameter - attention reduction value, which describes the reduction in the attention of activated users to misinformation after blocking the user set. Based on this, the problem of minimizing the misinformation attention by the node blocking strategy is equivalently converted into the problem of maximizing the attention reduction value by the node blocking strategy, and a  $(\epsilon, \delta)$ -approximate Monte Carlo simulation method for estimating the attention reduction value of misinformation is given. Then, we leverage the supermodularity ratio parameter of the set function to explore the approximate properties between the Lovász extension function of set function and it concave closed function, and propose an approximate projected subgradient algorithm. Finally, the effectiveness of the proposed algorithm and model is verified on three real data sets: YouTube, Facebook and Digg. Experimental results show that under different experimental settings, the approximate projected subgradient algorithm is consistently better than existing heuristic algorithms in reducing users' attention to misinformation (at least 11.35%), and is at least 19.05% better than the baseline algorithms in suppressing the spread of misinformation. In addition, our numerical findings that the initial attention vector of users in social networks affects the decreasing value of users' attention to misinformation in social networks, but has a certain homogeneity, and users' attention to misinformation affects the efficiency and effectiveness of misinformation governance.

**Keywords** misinformation; attention; nodes blocking; Lovász extension; approximate projected subgradient

## 1 引 言

随着移动终端设备的普及以及媒体传播技术的持续更新,人们在生活、工作和学习中的社交成本不断降低,导致人们获取信息的途径不断拓宽.然而,人们从各种信息来源中获得的有关经济、娱乐、政治、军事和科技等不同类型的信息并不全是真实的,其中必然夹着各种负面信息(虚假信息、谣言和假新闻等).例如,在2021年,一条阿富汗加兹尼省加兹尼市将要发生地震的谣言使该市及附近地区数以千计的居民淋着雨离开房屋.新冠疫情期间,一则“中成药双黄连口服液可抑制新型冠状病毒”的虚假信息在中国全网刷屏,使双黄连口服液顷刻间被哄抢一空.

由于人们的决定和想法经常会受到他或她们所处社交网络的影响,互联网中伴生的虚假信息极易对人们的个人判断和决策产生误导,特别容易造成人们恐慌、不满等情绪,甚至会引发过激行为.事实上,并不是每个受到虚假信息影响(接受虚假信息)的人都会做出非常规或非理性的行为.只有当人们面对与自身利益密切相关(关注度高)的虚假信息时,他/她们才会失去理智和判断力做出非理性的行为<sup>[1]</sup>.例如,2011年日本福岛发生核泄漏后,社会网络中出现了一则“吃碘盐可以防辐射”的虚假信息,中国民众开始疯狂地抢购食用碘盐.在这种情况下,如果平时不做饭的人即使相信了“吃加碘盐可以防辐射”的虚假信息,那么他们很大可能不会做出非理性的行为——恐慌性抢碘盐.受这种现实情景的启发,在虚假信息治理时应尽最大努力避免虚假信

息导致人们失去理智或做出不当行为情况的发生。

人们对虚假信息的关注度或人们自身利益与虚假信息的密切程度决定着人们的行为决策,人们越关注虚假信息就越容易失去理智做出非常规甚至激进的行为。基于此,在治理虚假信息时,应尽量避免虚假信息引导人们做出过激行为情况的发生,也就是尽可能地减少用户对虚假信息的关注度。本文将该问题建模为点阻塞策略下虚假信息关注度最小化问题,目标是识别一组用户(节点)进行阻塞以使最终接受虚假信息的用户对虚假信息的总关注度最小。经典的点阻塞策略下虚假信息影响最小化问题的目标是选择一组用户(节点)进行阻塞以最小化被虚假信息传播源影响的用户数。但是,在点阻塞策略下虚假信息关注度最小化问题中,不仅希望最终接受虚假信息的用户数最少,更重要的是降低所有接受虚假信息的用户对虚假信息的总关注度。然而,对同一种类型信息的关注度因人而异,最小化被虚假信息影响用户的数量并不一定会使接受虚假信息的用户对虚假信息的总关注度最小,例1被给出解释此现象。因此,点阻塞策略下虚假信息关注度最小化问题并不是一个经典虚假信息影响最小化问题的实例,点阻塞策略下虚假信息关注度最小化问题是一个新问题。

**例1.** 图1展示了一个简单的有向社交网络 $\mathcal{U}$ ,其中节点(用户) $v_1$ 为虚假信息传播源并且每个节点对之间的影响概率(权重)为1。设置社交网络 $\mathcal{U}$ 中节点 $v_1, v_2, v_3, v_4, v_5, v_6, v_7$ 和 $v_8$ 对虚假信息的关注度分别为1, 0.52, 0.60, 0.72, 0.11, 0.26, 0.31, 0.27。当选择节点 $v_2$ 作为阻塞节点时,受节点 $v_1$ 影响的节点集为 $\{v_5, v_6, v_7, v_8\}$ ,并且对虚假信息的总关注度为0.95。类似的,当选择节点 $v_5$ 作为阻塞节点时,受节点 $v_1$ 影响的节点集为 $\{v_2, v_3, v_4\}$ ,此时对虚假信息的总关注度为1.84。基于上述两种方案,从虚假信息影响最小化的视角出发,选择阻塞节点 $v_5$ 更优(虚假信息最终激活的节点数为3),反之从虚假信息关注度最小化视角出发,选择阻塞节点 $v_2$ 更优(用户对虚假信息的总关注度为0.95)。

由于点阻塞策略下虚假信息关注度最小化是一个新问题,现有方法或技术在解决该问题方面仍存




图1 简单的社交网络

在着一些困难:首先,社交网络的拓扑结构和虚假信息扩散过程对用户关注度的演化产生重要影响,准确刻画用户关注度在这些因素共同作用下的动态演变是一个复杂问题;其次,虚假信息关注度最小化问题的目标集函数并不具有次模性或超模性(见第3.3节),目前还没有解决非次模(非超模)集函数的多项式时间算法;再之,在参数给定的情况下,精确计算文中所构建问题的目标函数是#P-难的。

受有趣的应用场景和相关应用技术挑战的激励,本文提出点阻塞策略下虚假信息关注度最小化问题,探索抑制虚假信息传播的点阻塞策略。本文的核心贡献点为:

(1)本文利用节点阻塞策略研究了一个虚假信息治理的新问题——虚假信息关注度最小化,旨在通过阻塞部分用户(节点)以最小化被虚假信息影响的用户对虚假信息的总关注度。据我们所知,这是首篇使用节点阻塞策略来干预用户对虚假信息关注度变化的文章。

(2)本文构建了独立级联模型的扩展模型——关注度级联模型,制定了用户对虚假信息关注度的动态演化过程。接着,证明了点阻塞策略下虚假信息关注度最小化问题是NP-难的以及目标集函数既不是次模的也不是超模的。

(3)本文引入关注度下降值参量,等价构造一个新问题——关注度下降最大化。依据集函数的超模比,探索了集函数的Lovász扩展函数与其凹闭合函数之间的近似属性,提出了一种近似投影次梯度算法。最后,在三个真实的数据集中进行丰富的模拟实验,以评估所提出的模型和算法。实验结果凸显出用户对虚假信息的关注度影响着虚假信息扩散的深度与广度。

本文其余部分结构如下:第1.1节给出了本文的相关工作;第2节构建了关注度级联模型,分析了用户对虚假信息关注度的演化并给出问题的正式陈述和性质;第3节提出了点阻塞策略下虚假信息关注度最小化问题的优化方法;第4节开发了一种近似投影次梯度算法;第5节实施了具体的模拟实验。最后,第6节对全文进行总结。

### 1.1 相关工作

在线社交网络中的负面信息,比如虚假信息<sup>[2]</sup>、谣言<sup>[3]</sup>和假新闻<sup>[4]</sup>等治理的研究已经成为一个独立的研究分支。目前,基于信息属性或应用场景的方法已经被提出去检测虚假信息,比如图卷积神经网络<sup>[5]</sup>和元超边结构学习<sup>[6]</sup>等方法。独立于虚假信息



检测的研究分支,一旦检测到虚假信息就应该立即采取遏制措施以降低虚假信息的影响.一方面,研究人员在不同的场景中刻画了虚假信息的传播机制.Gong等<sup>[7]</sup>考虑了竞争模型中普遍存在的“一致性”的作用,提出了一种新颖的一致性感知竞争独立级联模型来模拟两种信息(例如真相和谣言)的传播过程.于凯等<sup>[8]</sup>基于信息风险感知理论,利用在线社交用户的情绪、信任度、知识水平和媒体的接触数量等对传播个体的差异加以区分,设计虚假信息点对点传播模型.Jain等<sup>[3]</sup>在同构社交网络中考虑信息传播的时间延迟性,提出一个虚假信息动态传播的模型.相比于刻画虚假信息传播模型更重要的是,研究人员已经从不同的角度设计了虚假信息治理策略<sup>[9-11]</sup>,每种策略均从实际应用场景出发并尝试去抑制虚假信息的传播.

一些研究<sup>[10,12-13]</sup>,从网络中节点(用户)的影响力出发,提出阻塞或屏蔽有限节点或连边的策略以遏制虚假信息的传播.Amoruso等<sup>[12]</sup>提出了监视器放置问题,该问题旨在将最少数量的监视器放置在网络中的节点上,从而保护某些给定的目标节点免受虚假信息的侵害并最终将受虚假信息感染的节点数量限制在很小的范围内.Yang等<sup>[14]</sup>定义了线性阈值模型的特殊扩展-阻塞线性阈值网络,构建了top- $k$ 阻塞问题,旨在阻止建模为线性阈值模型的复杂社交网络中的节点子集来最大程度地减少虚假信息传播.Jiang等<sup>[15]</sup>提出社交网络中目标接收者的谣言传播中断问题,旨在通过删除一些关键链接以保护关键目标接收者不受谣言控制.Wang等<sup>[13]</sup>以网络结构优化与邻居行为级联的交互关系为切入点,提出一种逻辑删除链接方法以改善网络社区的聚类进而阻止在线社交网络中虚假信息和用户行为的级联.另外,一些学者<sup>[10,16]</sup>假设虚假信息的传播源是一组特定的节点,设计通过选择部分代理节点发布正面信息或真相以澄清虚假信息从而达到减少虚假信息传播的目的.由于现实中网络环境极其复杂、拓扑结构不断演化,且虚假信息扩散受到社会环境、用户心理、认知偏差、经济利益和信息源的可信度等多种因素的影响,导致虚假信息传播的实际情景很难精确刻画.研究者包括本研究团队提出的虚假信息治理策略均从具体的应用场景出发并尝试去抑制虚假信息的传播,则很难保证某种策略均适用所有具体的应用场景并且表现出最优性能.虽然目前的研究已经从不同的角度设计了抑制虚假信息传播的方法,但这些策略的最终目标是最大限度地减少接受

虚假信息用户数量,而没有考虑用户对虚假信息的关注度.因此,本文基于点阻塞的虚假信息治理策略,探索虚假信息关注度最小化问题.

由于优化虚假信息影响最小化问题是NP-难的<sup>[17]</sup>,则解决点阻塞策略下虚假信息关注度最小化问题也是NP-难的.不幸的是,目前并没有一种有效的多项式时间算法来解决NP-难的问题.尽管贪心(Greedy)算法可以获得一个有近似保证的解,但其要求优化问题的目标集函数具有次模性(超模性).如果优化问题的目标集函数不具有次模性或超模性,则贪心算法的优势将不复存在.在大多数应用场景中,虚假信息影响最小化问题的目标函数并不具有次模性或超模性,点阻塞策略下虚假信息关注度最小化问题的目标函数也不例外(见第3.3节).

目前,多种启发式算法已被提出去优化非次模的集函数<sup>[11,18-19]</sup>.Ni等<sup>[19]</sup>利用三明治框架方法解决了非次模集函数最大化问题.三明治框架方法的核心是构建目标集函数的次模上界与次模下界,但不幸的是当前并没有一个通用且有效的方法来实现它.Han等<sup>[20]</sup>通过将离散粒子群优化算法与网络的邻域度中心性相结合,来识别大规模社交网络中前 $k$ 个有影响力的节点.离散粒子群优化算法需要通过实验模拟来确定众多关键参数值,从而很难保证所获取解的质量.Dey等<sup>[18]</sup>捕获节点度分布、介数和接近中心性三个网络属性的交互度量,以此交互度量为依据选择有影响力的节点进行阻塞.Ghoshal等<sup>[11]</sup>利用社交网络中社区集群拓扑结构来识别和放置可信节点,以抑制虚假信息在社交网络中的扩散.本文的社交网络并不含有重要的拓扑结构-社区(群组),以社区(群组)拓扑结构为核心的算法很难应用于本文目标集函数的优化.基于以上分析,本文综合考虑非超模集函数的求解效率和精度,利用连续领域的方法和技术来优化非次模集函数.

最后,将比较分析本文核心要点与团队之前研究工作的关系以进一步阐释本文的创新性.本文所研究问题与团队之前研究工作<sup>[21-23]</sup>在宏观上具有相似性,均是针对社交网络中虚假信息治理的研究,但在核心要点上具有本质性的差别.文献<sup>[21]</sup>在在线社交网络中研究了虚假信息交互量最小化问题,目标是社交网络中用户之间的虚假信息交互量最小.此工作的针对对象是用户之间的虚假信息交互量,而本文所针对对象是用户对虚假信息的关注度,两者有着本质上的区别.文献<sup>[22]</sup>在在线社交网络中探讨了如何识别代理人发布正面信息来最小化用户对虚

假信息的关注度,此工作运用虚假信息治理的真相运动策略,而本文则以节点阻塞策略为核心降低用户对虚假信息的关注度.文献<sup>[23]</sup>考虑虚假信息在基于位置的人际交互网络和在线社交网络中的传播,研究了虚假信息传播最小化问题.此工作的目标与本文的目标有着根本性的区别,文献<sup>[23]</sup>的目标是最小化被虚假信息影响的用户数量,而本文的目标是在在线社交网络中用户对虚假信息的关注度.因此,本文以用户对虚假信息的关注度为研究对象,在使用节点阻塞策略研究虚假信息的治理问题方面有着独特的创新之处及重要的实践意义.

## 2 问题的构建

在线社交网络中传播的信息并非都属于同一种类型,依据不同的属性进行划分信息可以被分为不同的种类.例如,按照社会性,信息被划分为社会信息和自然信息两类;按照发生的情况,信息被划分为

预知性信息和突发性信息两类;按照应用部门,信息被划分为工业信息、农业信息、军事信息、政治信息、科技信息、文化信息、娱乐信息和经济信息八类.给定一个用有向图 $\mathcal{U}(\mathcal{V}, \mathcal{E})$ 表示的在线社交网络,其中节点集表示 $\mathcal{V}$ 为用户集和连边集 $\mathcal{E}$ 为用户之间形成的稳固关系集.每个用户 $v \in \mathcal{V}$ 具有一个刻画其对不同类信息关注度的属性——关注度向量 $C_v$ ,并且关注度向量被表示为 $C_v = \{c_v(1), \dots, c_v(n)\}$ ,其中 $n$ 为信息划分的种类数.元素 $c_v(d) \in (0, 1)$ 描述用户 $v$ 对 $d$ -类( $1 \leq d \leq n$ )信息的关注度,元素 $c_v(d)$ 的值越大表示用户 $v$ 对 $d$ -类信息的关注度越高,反之亦然.例如,对军事类新闻从不关心的用户对该类信息的关注度为0,而被称为“军事迷”的用户对该军事类信息的关注程度将接近1.在实际应用中,可以利用机器学习等方法从用户的浏览或搜索日志数据中获得用户对各类信息的关注,或简单地统计用户发布各类信息的频率结果作为其对该类信息的关注.表1中归纳了本文常用符号.

表1 常用符号列表

符 号	含 义
$\mathcal{U}(\mathcal{V}, \mathcal{E})$	一个有向的在线社交网络,其中 $\mathcal{V}$ 为用户(节点)集和 $\mathcal{E}$ 为用户之间的关系(连边)集
$C_v$	用户 $v \in \mathcal{V}$ 对不同类型信息的关注度,其中 $c_v(d) \in C_v$ 描述用户 $v$ 对 $d$ -类信息的关注度
$p_{vu}(t)$	用户 $v$ 在时间 $t$ 时将虚假信息成功传播给用户 $u$ 的概率
$c_v^t$	用户 $v$ 在时间 $t$ 时对虚假信息的关注度
$\mathcal{S}$	虚假信息的传播源并且传播的虚假信息属于 $d$ -类信息
$c_v^*$	用户 $v$ 被父邻居用户激活时其对虚假信息的关注度
$\mathcal{D}$	阻塞用户集
$q$	阻塞用户的数量
$A_{\mathcal{S}}(\mathcal{D})$	在集合 $\mathcal{D}$ 中的用户被阻塞后虚假信息传播结束时激活用户对虚假信息的总关注度

### 2.1 关注度级联模型

在在线社交网络 $\mathcal{U}(\mathcal{V}, \mathcal{E})$ 中,设置虚假信息源 $\mathcal{S}$ 传播的虚假信息属于 $d$ -类信息.虚假信息在相邻用户之间成功传播需要经过两个步骤:一是新激活用户将虚假信息发送给予子邻居用户;二是子邻居用户接受其所收到的虚假信息.在虚假信息扩散过程中,用户对虚假信息的关注度越高,分享或接受虚假信息的意愿也就越大.另外,基于名人效应<sup>[24]</sup>理念中可知用户更容易接受来自权威父邻居的虚假信息.因此,在时间 $t$ 时新激活用户 $v$ 将虚假信息成功传播给其未激活的子邻居用户 $u$ 的概率定义为

$$p_{vu}(t) = \beta \frac{c_v^t c_u^t}{1 + e^{-C_{c_v}}} \quad (1)$$

其中 $\beta > 0$ 为常量参数, $c_u^t$ 为用户 $u$ 在时间 $t$ 时对虚

假信息的关注度以及 $C_{c_v}$ 为用户 $v$ 的相对权威性.在本文中,利用用户的度来刻画用户的相对权威性,即用户 $v$ 的相对权威性为 $C_{c_v} = |N(v)|$ .接下来,本文以经典的信息传播模型——独立级联模型<sup>[25]</sup>为基,并考虑用户对虚假信息的关注度来构建虚假信息扩散的关注度级联模型(Attention Cascade Model).

给定在线社交网络 $\mathcal{U}(\mathcal{V}, \mathcal{E})$ 以及传播属于 $d$ -类信息的虚假信息源 $\mathcal{S}$ ,虚假信息扩散在离散的时间 $t = 1, 2, 3, \dots$ 内进行.在虚假信息的扩散过程中,令 $S_t$ 为时间 $t$ 内新激活的用户集并且设定用户一旦被虚假信息激活则将保持激活状态直到虚假信息传播结束.因此,虚假信息的具体扩散流程如下:

A. 虚假信息扩散在时间 $t = 0$ 时开始并引发一组初始激活用户,即 $S_0 = \mathcal{S}$ ;

- B. 在时间  $t(t \geq 1)$  时, 用户  $v \in S_{t-1}$  尝试以  $p_v(t)$  的概率去激活其未被激活的子邻居用户, 并更新子邻居用户对虚假信息的关注度(关注度更新的方法见第 2.2 节). 如果未被激活的子邻居用户被成功激活, 则其被添加到集合  $S_t$  中;
- C. 重复步骤 B 直到新激活的集合  $S_t = \emptyset$  时停止.

算法 1 中概括了关注度级联模型的具体流程, 分析关注度级联模型的具体流程知道算法 1 的时间复杂度为  $O(|\mathcal{E}|)$ .

#### 算法 1. 关注度级联模型 (ACM)

输入:  $\mathcal{U}(\mathcal{V}, \mathcal{E}), \mathcal{S}$

输出: 用户对虚假信息总关注度  $\mathcal{A}_S$

初始化  $t = 0, S_t \leftarrow \mathcal{S}, Ma = [], \mathcal{A}_S = |\mathcal{S}|$ ;

WHILE  $S_t \neq \emptyset$

$Ma \leftarrow Ma \cup S_t, Mm = []$ ;

FOR 每个  $v \in S_t$

用户  $v$  以  $p_v(t)$  概率尝试用户  $u \in N^{out}(v) \setminus Ma$ ;

更新用户  $u$  对虚假信息的关注度  $c_u^t$ ;

如果  $u$  被成功激活,  $Mm \leftarrow Mm \cup \{u\}, \mathcal{A}_S += c_u^t$ ;

FEND

$t += 1, S_t \leftarrow Mm$ ;

WEND

RETURN  $\mathcal{A}_S$

## 2.2 用户对虚假信息关注度的演化

现实世界中的用户对不同类信息的关注度是动态变化的并且生活中的各种活动, 比如, 工作、学习、娱乐等, 均可能影响用户对信息的关注度. 相对于用户对不同类信息的整体关注度的变化周期, 信息传播周期大多较短. 因此, 本文设定用户对各种类型信息的整体关注度在某条信息扩散过程中是固定不变的, 也就是每个用户的关注度向量  $C$  是固定的. 虽然在信息扩散过程中每个用户对不同类信息的整体关注度是不变的, 但用户对某条正在扩散信息的关注度却是动态演化的. 考虑到属于  $d$ -类信息的虚假信息的扩散研究是本文工作的重点, 则本节将以用户之间的互动为基础进行刻画虚假信息扩散时用户对其关注度的变化.

用户对所属  $d$ -类信息的虚假信息的关注度, 最初从对  $d$ -类信息的整体关注度开始, 并随着虚假信息在用户之间的传播而不断演化. 由于用户之间虚假信息的传播影响了他或她们对虚假信息的关注度, 本文将借助库仑定律<sup>[26]</sup>来刻画用户之间虚假信息的传播对用户关注虚假信息的影响. 库仑定律定义了驻点电荷之间的相互作用力, 指出两个驻点电

荷之间的作用力与它们电荷量的乘积成正比, 与它们距离的平方成反比. 在在线社交网络  $\mathcal{U}(\mathcal{V}, \mathcal{E})$  中, 用户  $u$  在虚假信息互动后其关注度的变化, 既受到与之交互用户  $v$  的关注度的影响, 也受到用户  $u$  和用户  $v$  之间相似性(距离)的影响. 因此, 库仑定律能类地被使用去刻画虚假信息传播过程中用户对虚假信息关注度的变动, 则用户  $u$  在时间  $t$  时接收到其父邻居用户  $v$  分享的属于  $d$ -类信息的虚假信息后对虚假信息的关注度的改变为

$$\Delta c^t(u, v) = \frac{c_u^t \cdot c_v^t}{[1 + D_{KL}(C_u \| C_v)]^2} \quad (2)$$

其中  $D_{KL}(C_u \| C_v)$  是测量关注度向量  $C_u$  和关注度向量  $C_v$  之间相似性的 K-L 散度, 并且  $D_{KL}(C_u \| C_v) = -\sum_{i=1}^n c_u(i) \log[c_u(i)/c_v(i)]$ . 关注度向量之间的 K-L 散度值越小, 两个用户的关注向量就越相似, 反之亦然. 参数  $c_u^t$  表示用户  $u$  在时间  $t$  时对虚假信息的关注度, 并且设定  $c_u^0 = c_u(d)$ .

考虑到社交网络拓扑结构的复杂性和虚假信息传播的随机性, 社交网络中的用户在某个时间窗口可能会与其多个已激活的父邻居用户进行虚假信息交互, 从而导致用户对虚假信息关注度的真实变动呈现递减趋势, 则本文类比于全概率公式更新其对虚假信息关注度. 另外, 现实生活中, 在没有用户互动的情况下, 用户对虚假信息的关注度随时间的流逝不断下降. 因此, 当用户  $u$  在时间  $t$  时从多个父邻居用户中收到虚假信息时, 其在  $t+1$  时间对虚假信息的关注度被表示为

$$c_u^{t+1} = \frac{c_u^t}{\log(t+10)} + (1 - c_u^t) [1 - \prod_{z \in Md} (1 - \Delta c^t(u, z))] \quad (3)$$

其中  $Md$  表示在时间窗口  $t$  时用户  $u$  新激活的父邻居用户集. 相似地, 如果用户  $u$  在  $t$  时间窗口时没有从父邻居用户中接受到任何虚假信息, 则其在  $t+1$  时间窗口对虚假信息的关注度为  $c_u^{t+1} = c_u^t / \log(t+10)$ . 本文设定虚假信息源  $\mathcal{S}$  中的用户对虚假信息的关注度  $c_u = 1$ .

## 2.3 虚假信息关注度最小化问题

在社交网络中, 用户对虚假信息的关注度决定着其做出非常规行为的可能性, 影响着虚假信息对社会造成危害的程度. 基于此, 在治理虚假信息时应以减少最终接受虚假信息的用户对虚假信息关注度为目标. 在一个有向的在线社交网络  $\mathcal{U}(\mathcal{V}, \mathcal{E})$  中, 给定一个虚假信息传播源  $\mathcal{S}$ , 一个阻塞节点(用户)



集 $\mathcal{D}$ 和虚假信息扩散模型-关注度级联模型,虚假信息传播结束后接受虚假信息的用户对虚假信息的关注总量为

$$\mathcal{A}_s(\mathcal{D}) = \mathbb{E} \left[ \sum_{v \in AC} c_v^* \right] \quad (4)$$

其中 $\mathbb{E}[\cdot]$ 为期望运算因子, $AC$ 为网络拓扑结构 $\mathcal{V}$ 下接受虚假信息的用户集, $c_v^*$ 为用户 $v$ 被父邻居用户激活时其对虚假信息的关注度以及虚假信息源 $\mathcal{S}$ 传播的虚假信息属于 $d$ -类信息. 由于虚假信息扩散是一个随机过程,则在等式(4)中对所有可能的结果取期望值.

为尽可能地减少用户对虚假信息的关注度,本文利用虚假信息治理的节点(用户)阻塞策略. 然而,考虑到不同的用户在降低虚假信息关注度方面存在差异,选择哪个用户以及多少用户进行阻塞是影响降低虚假信息关注度的最重要因素. 在此基础上,本文探索节点阻塞策略下虚假信息关注度最小化问题. 接下来,给出点阻塞策略下虚假信息关注度最小化问题的正式陈述.

**定义 1.** 在有向在线社交网络 $\mathcal{U}(\mathcal{V}, \mathcal{E})$ 中,给定虚假信息传播源 $\mathcal{S}$ ,正整数 $q$ 和虚假信息传播模型——关注度级联模型,点阻塞策略下虚假信息关注度最小化问题的目标是从用户集 $\mathcal{V}$ 中识别包含 $q$ 个用户的集合 $\mathcal{D}$ 进行阻塞从而使所有激活用户对虚假信息总关注度最小,即

$$\mathcal{D}^* = \arg \min_{\mathcal{D} \subseteq \mathcal{V}, |\mathcal{D}| \leq q} \mathcal{A}_s(\mathcal{D}) \quad (5)$$

虽然虚假信息关注度最小化问题不等价于虚假信息影响最小化问题,但其也是一个典型的离散优化问题.

#### 2.4 关注度最小化问题的属性

下面,本节将利用一些定理来讨论点阻塞虚假信息关注度最小化问题的属性.

**定理 1.** 点阻塞策略下虚假信息关注度最小化是NP-难的.

**证明.** 本节通过规约NP-完全的集合覆盖问题<sup>[27]</sup>来证明定理的成立. 给定一个基础集 $\bar{V} = \{\bar{v}_1, \bar{v}_2, \dots, \bar{v}_w\}$ 和一个子集的集合 $\Delta = \{\Delta_1, \Delta_2, \dots, \Delta_x\}$ ,其中集合 $\Delta$ 中的子集的并集等于基础集 $\bar{V}$ . 集合覆盖问题是判断子集集合 $\Delta$ 中是否存在 $q$  ( $q < x$ )个子集的并集等于 $\bar{V}$ .

给定集合覆盖问题的一个实例,构造一个具有 $1 + w + x$ 个节点的有向图 $G$ . 给定节点 $s$ 为虚假信息的传播源,为每个集合 $\Delta_j$ 创建一个节点 $a_j$ ,为每个元素 $\bar{v}_i$ 创建一个节点 $b_i$ 以及添加具有影响概率 $p_{..} = 1$ 的有向边 $(s, a_j)$ 和 $(a_j, b_i)$ . 设置有向图 $G$ 中每个节

点对虚假信息的关注度为1. 由于所有的传播概率为1,则虚假信息扩散是一个确定性的过程. 因此,集合覆盖问题等同于确定是否存在由 $q$ 个节点组成的集合 $B$ 使得 $\mathcal{A}_s(B) = q$ . 则该定理立即成立.

证毕.

**定理 2.** 给定虚假信息传播源 $\mathcal{S}$ 和阻塞节点集 $\mathcal{D}$ ,计算目标集函数 $\mathcal{A}_s(\mathcal{D})$ 是#P-难的.

**证明.** 在在线社交网络中精确计算虚假信息传播值已经被证明是#P-难的<sup>[28]</sup>. 由于计算虚假信息关注度的前提条件是确定虚假信息的传播结果,则在给定的在线社交网络中计算虚假信息的关注度也是#P-难的,即计算目标集函数 $\mathcal{A}_s(\mathcal{D})$ 是#P-难的.

证毕.

**定理 3.** 目标集函数 $\mathcal{A}_s(\cdot)$ 是非负的且非增加的.

**证明.** 在有向在线社交网络 $\mathcal{U}(\mathcal{V}, \mathcal{E})$ 中,给定虚假信息传播源 $\mathcal{S}$ 和阻塞节点集 $\mathcal{D}$ ,任意节点 $v \in \mathcal{V} \setminus \mathcal{S}$ 被虚假信息传播源 $\mathcal{S}$ 激活的概率大于等于零并且对虚假信息的关注度也大于零,则目标集函数 $\mathcal{A}_s(\cdot)$ 是非负的. 设 $u \in \mathcal{V} \setminus \{\mathcal{S} \cup \mathcal{D}\}$ ,则任意的节点 $v \in \mathcal{V} \setminus \{\mathcal{S} \cup \mathcal{D} \cup \{u\}\}$ 在拓扑网络结构 $\mathcal{V} \setminus \mathcal{D}$ 下被虚假信息激活的概率以及对虚假信息的关注度不会小于在拓扑网络结构 $\mathcal{V} \setminus \{\mathcal{S} \cup \mathcal{D} \cup \{u\}\}$ 下所获得的值. 因此,目标集函数 $\mathcal{A}_s(\cdot)$ 是非增加的.

证毕.

接下来,基于图2构建反例来证明目标集函数并不具有次模性和超模性.




图2 阐释目标集函数模性的网络示例

**定理 4.** 目标集函数 $\mathcal{A}_s(\cdot)$ 既不是次模函数也不是超模函数.

**证明.** 在图2中,设定信息被划分为4类,即 $n = 4$ ,且随机且均匀的为每个用户设定其对不同类信息的初始整体关注度. 基于此,用户 $v_1, v_2, v_3, v_4$ 和 $v_5$ 对不同类信息的关注度分别设为 $C_{v_1} = \{0.839, 0.154, 0.029, 0.641\}$ ,  $C_{v_2} = \{0.228, 0.968, 0.031, 0.355\}$ ,  $C_{v_3} = \{0.779, 0.303, 0.449, 0.868\}$ ,  $C_{v_4} = \{0.930, 0.898, 0.801, 0.166\}$ ,  $C_{v_5} = \{0.646, 0.080, 0.777, 0.653\}$ . 令节点 $v_1$ 为虚假信息传播源 $\mathcal{S}$ ,并且 $\mathcal{S}$ 传播的虚假信息属于第1-类信息,即

$d=1$ . 设  $\mathcal{D}_1=\emptyset$ ,  $\mathcal{D}_2=\{v_4\}$  和  $\mathcal{D}=\{v_2\}$ , 基于算法 2, 得到  $\mathcal{A}_S(\mathcal{D}_1)=3.2739$ ,  $\mathcal{A}_S(\mathcal{D}_2)=2.0928$ ,  $\mathcal{A}_S(\mathcal{D}_1 \cup \mathcal{D})=2.9541$  和  $\mathcal{A}_S(\mathcal{D}_2 \cup \mathcal{D})=1.7289$ . 不等式  $\mathcal{A}_S(\mathcal{D}_1 \cup \mathcal{D}) - \mathcal{A}_S(\mathcal{D}_1) > \mathcal{A}_S(\mathcal{D}_2 \cup \mathcal{D}) - \mathcal{A}_S(\mathcal{D}_2)$  显然成立, 则目标集函数  $\mathcal{A}_S(\cdot)$  并不具有超模性.

相似的, 设  $\mathcal{D}=\{v_3\}$ ,  $\mathcal{D}_3=\{v_2\}$  和  $\mathcal{D}_4=\{v_2, v_4\}$ , 得到  $\mathcal{A}_S(\mathcal{D}_3)=2.9541$ ,  $\mathcal{A}_S(\mathcal{D}_4)=1.7289$ ,  $\mathcal{A}_S(\mathcal{D}_3 \cup \mathcal{D})=1.932$  和  $\mathcal{A}_S(\mathcal{D}_4 \cup \mathcal{D})=1$ . 然后, 有  $\mathcal{A}_S(\mathcal{D}_3 \cup \mathcal{D}) - \mathcal{A}_S(\mathcal{D}_3) < \mathcal{A}_S(\mathcal{D}_4 \cup \mathcal{D}) - \mathcal{A}_S(\mathcal{D}_4)$ , 则目标集函数  $\mathcal{A}_S(\cdot)$  是非次模的. 证毕.

### 3 虚假信息关注度最小化的优化方法

本节首先将点阻塞策略下虚假信息关注度最小化问题等价转换点阻塞策略下关注度下降最大化问题; 接着, 介绍集函数的连续化方法-Lovász 扩展; 最后, 探索集函数的 Lovász 扩展函数与其凹闭合函数之间的近似属性.

#### 3.1 关注度下降最大化问题

为了能有效解决虚假信息关注度最小化问题, 本节引入一个参量-关注度下降值, 刻画阻塞用户集后激活用户对虚假信息关注度的减少值. 将阻塞集  $\mathcal{D}$  中的用户后用户对虚假信息的关注度下降值用  $h(\mathcal{D})$  来表示, 其中关注度下降值的具体表达式为  $h(\mathcal{D}) = \mathcal{A}_S(\emptyset) - \mathcal{A}_S(\mathcal{D})$ . 基于关注度下降值的定义, 得到点阻塞策略下虚假信息关注度最小化等价于点阻塞策略下虚假信息关注度下降最大化, 即

$$\mathcal{D}^* = \arg \min_{\mathcal{D} \subseteq \mathcal{V}_S, |\mathcal{D}| \leq q} h(\mathcal{D}) \quad (6)$$

从点阻塞策略下虚假信息关注度最小化问题的属性可以得到: 点阻塞策略下虚假信息关注度下降最大化问题是 NP-难的; 在给定的虚假信息传播源  $\mathcal{S}$  和阻塞用户集  $\mathcal{D}$  下, 计算关注度下降值  $h(\mathcal{D})$  是 #P-难的. 基于目标集函数  $\mathcal{A}_S(\cdot)$  的属性得到集函数  $h(\cdot)$  的属性: 集函数  $h(\cdot)$  是非负非减少的; 集函数  $h(\cdot)$  既不是次模函数也不是超模函数. 考虑到集函数  $h(\cdot)$  的属性和性质, 传统的集函数优化方法, 比如贪心算法的优势将不再存在. 因此, 下面将利用解决连续函数的技术来优化集函数  $h(\cdot)$ .

#### 3.2 集函数的连续化

考虑到点阻塞策略下虚假信息关注度下降最大化问题是一个离散优化问题, 并且集函数  $h(\cdot)$  并不具有次模性, 则本节提供集函数连续化的方法——

Lovász 扩展, 将离散函数扩展为连续函数. 对于任意的向量  $x \in [0, 1]^m$ , 定义  $\omega: [m]$  为向量  $x$  中  $m$  个元素的降序排列, 即  $x_{\omega(1)} \geq x_{\omega(2)} \geq \dots \geq x_{\omega(m-1)} \geq x_{\omega(m)}$ . 令集合  $\Phi_i^x = \{\omega(1), \omega(2), \dots, \omega(i)\}$ , 并且对任意元素  $i \in \{1, 2, \dots, m\}$  存在一个集合链  $\Phi_1^x \subseteq \Phi_2^x \subseteq \dots \subseteq \Phi_i^x$ . 设置  $1_{\Phi_i^x}$  是  $m$  元组向量, 其中第  $j$  个 ( $j \in \Phi_i^x$ ) 元素为 1, 其余元素为 0. 因此, 具有  $h(\emptyset)$  的集函数  $h(\cdot)$  的 Lovász 扩展函数  $h_L(\cdot)$  为

$$h_L(x) = \sum_{i=1}^m x_{\omega(i)} [h(\Phi_i^x) - h(\Phi_{i-1}^x)] \quad (7)$$

其中  $\Phi_0^x$  表示空集.

从等式 (6) 中得到集函数  $h(\mathcal{D})$  的定义域为  $\{\mathcal{D} \subseteq \mathcal{V}_S : |\mathcal{D}| \leq q\}$ , 基于等式 (7) 得到 Lovász 扩展函数  $h_L(x)$  的定义域为  $\{x \in [0, 1]^m : \|x\|_1 \leq q\}$ , 其中  $\|x\|_1$  为向量  $x$  的  $l_1$ -范数. Lovász 扩展方法在集函数的超模性与连续函数凹性之间建立了关系. 具有超模性的集函数  $H(\cdot)$  的 Lovász 扩展函数  $H_L(\cdot)$  是凹函数<sup>[29]</sup>, 最大化超模函数  $H(\cdot)$  等价于最大化凹函数  $H_L(\cdot)$ , 即  $\max H(\cdot) = \max H_L(\cdot)$ . 不幸的是, 集函数  $h(\cdot)$  并不具有超模性, 其最优值与 Lovász 扩展函数最优值(最优解)之间的关系会受到怎样的影响并不清楚. 因此, 下面将探索非超模集函数最大化的最优值与其 Lovász 扩展函数最大化的最优值之间的关系.

#### 3.3 集函数的凹松弛

虽然集函数  $h(\cdot)$  不具有超模性, 但其也显示出一定的弱超模性. 给定一个非减少的集函数  $h(\cdot)$ , 如果存在一个参数  $\chi_h \in [1, +\infty)$  对于任意  $A_1 \subset A_2 \subset \mathcal{V} \setminus \{u\}$  使等式

$$\chi_h = \max_{A_1 \subset A_2 \subset \mathcal{V} \setminus \{u\}} \frac{h(A_1 \cup \{u\}) - h(A_1)}{h(A_2 \cup \{u\}) - h(A_2)} \quad (8)$$

成立, 则集函数  $h(\cdot)$  是  $\chi_h$ -弱超模的. 当且仅当  $\chi_h = 1$  时, 集函数  $h(\cdot)$  是超模函数.

从等式 (7) 中可知 Lovász 扩展函数  $h_L(\cdot)$  是一个分段线性函数. 因此, 本节引入集函数  $h(\cdot)$  的凹闭包函数  $h_+(\cdot)$ , 并借助 Lovász 扩展函数  $h_L(\cdot)$  来优化集函数  $h(\cdot)$ . 凹闭包函数  $h_+(\cdot)$  是一个逐点最大的凹函数, 其具体的定义如下.

**定义 2.** 给定一个集函数  $h(\cdot): 2^m \rightarrow \mathbb{R}$ , 其凹闭包函数  $h_+(\cdot): [0, 1]^m \rightarrow \mathbb{R}$  为  $h_+(x) = \max \{ \sum_{z \subseteq \mathcal{V}} \theta_z h(Z) : \sum_{z \subseteq \mathcal{V}} \theta_z 1_z = x, \sum_{z \subseteq \mathcal{V}} \theta_z = 1, \theta_z \in [0, 1] \}$ , 其中  $\theta_z$  为样本  $Z$  的取样概率.

从凹闭包的定义可知函数  $h_+(\cdot)$  始终是集函数



$h(\cdot)$ 的上界,并且优化一般集函数的凹闭包是NP-难的.当集函数 $H(\cdot)$ 具有超模性时,其凹闭包函数 $H_+(\cdot)$ 等价于其Lovász扩展函数 $H_L(\cdot)$ .对具有弱超模性的集函数其闭包函数 $h_+(\cdot)$ 的主要优势将不复存在,但存在一个较弱的关键性质.

**定理 5.** 对于任意的向量 $\mathbf{x} \in [0, 1]^m$ ,对其元素进行降序排列得到序列 $x_{\omega(1)} \geq x_{\omega(2)} \geq \dots \geq x_{\omega(m-1)} \geq x_{\omega(m)}$ ,定义向量 $\mathbf{K}$ 并满足 $K_i = h(\Phi_i^{\mathbf{x}}) - h(\Phi_{i-1}^{\mathbf{x}})$ .则不等式 $\mathbf{K}(\mathcal{D}) \geq h(\mathcal{D})/\chi_h$ 对于所有集合 $\mathcal{D} \subseteq \mathcal{V} \setminus \mathcal{S}$ 成立且 $h_L(\mathbf{x}) = \mathbf{K}^T \mathbf{x} \leq h_+(\mathbf{x})$ 以及 $\mathbf{K}^T \mathbf{x} \geq h_+(\mathbf{x})/\chi_h$ 对于任意的向量 $\mathbf{x} \in [0, 1]^m$ 也成立.

证明. 详见附录A.

证毕.

## 4 算法

本章首先给出计算虚假信息关注度下降值的 $(\epsilon, \delta)$ -近似蒙特卡洛模拟估计方法.接着,设计一个近似投影次梯度算法来解决点阻塞策略下虚假信息关注度最小化问题.

### 4.1 关注度下降值的估计

由于在关注度级联模型下精确计算用户对虚假信息关注度的下降值是#P-难的,则蒙特卡洛模拟近似方法<sup>[30]</sup>被采用去估计虚假信息关注度的下降值.

**引理 1.** 设 $Q \in [0, 1]$ 的独立同分布的样本为 $Q_1, Q_2, \dots$ ,其中样本的均值和方差分别为 $\mu_Q$ 和 $\sigma_Q^2$ .定义参数 $\epsilon \in [0, 1], \delta > 0, \gamma = 4(e-2)\ln(2/\delta)/\epsilon^2$ 和 $\gamma_1 = 1 + (1 + \epsilon)\gamma$ .给定 $Nq$ 为 $Q$ 的取样次数,定义 $AQ = \sum_{i=1}^{Nq} Q_i$ 和 $\hat{\mu}_Q = AQ/Nq$ ,如果 $Nq$ 是 $AQ \geq \gamma_1$ 时的取样样本数,则 $\Pr[(1 - \epsilon)\mu_Q \leq \hat{\mu}_Q \leq (1 + \epsilon)\mu_Q] \geq 1 - \delta$ 和 $\mathbb{E}[Nq] \leq \gamma_1/\mu_Q$ .

引理1提供了估计虚假信息关注度下降值的停止条件.设置 $\delta > 0, 0 \leq \epsilon \leq 1, \gamma_1 = 1 + 4(e-2)(1 + \epsilon)\ln(2/\delta)/\epsilon^2$ .当 $Nq$ 次 $\bar{h}(\mathcal{D})/|\mathcal{V}|$ 之和超过 $\gamma_1$ 时,得到使不等式 $\Pr[(1 - \epsilon)h(\mathcal{D}) \leq \hat{h}(\mathcal{D}) \leq (1 + \epsilon)h(\mathcal{D})] \geq 1 - \delta$ 成立的 $h(\mathcal{D})$ 估计值 $\hat{h}(\mathcal{D})$ .算法2提供了估计虚假信息关注度下降值 $h(\mathcal{D})$ 的流程.

**算法 2.** 关注度下降值的估计流程

输入: $\mathcal{U}(\mathcal{V}, \mathcal{E}), \mathcal{S}, \mathcal{D}, \gamma_1$

输出:关注度下降值的估计值 $\hat{h}(\mathcal{D})$

初始化 $AQ = 0, Nq = 0$ ;

基于阻塞用户(节点)集 $\mathcal{D}$ 更新网络拓扑结构 $\mathcal{U}(\mathcal{V}, \mathcal{E})$ ;

WHILE  $AQ < \gamma_1$

$\bar{h}(\mathcal{D}) \leftarrow \text{ACM}(\mathcal{V}, \mathcal{E})$ ;

$AQ \leftarrow \bar{h}(\mathcal{D})/|\mathcal{V}|, Nq \leftarrow Nq + 1$ ;

FOR 每个  $v \in \mathcal{S}_i$

WEND

$\hat{h}(\mathcal{D}) = AQ \cdot |\mathcal{V}|/Nq$ ;

RETURN  $\hat{h}(\mathcal{D})$

**命题 1.** 算法2的时间复杂度为 $O(Nq \cdot |\mathcal{E}|)$ .

### 4.2 近似投影次梯度算法

从定理5可知 $\mathbf{K}$ 可被用作去近似凹闭包函数的次梯度,则本节开发一个近似投影次梯度(Approximate Projected Subgradient, AppPS)算法去优化点阻塞策略下虚假信息关注度最小化问题.令 $Nt$ 为近似投影次梯度算法中的迭代次数以及 $F_L$ 为Lovász扩展函数 $h_L(\mathbf{x})$ 的定义域,其中 $F_L$ 被表示为 $\{\mathbf{x} \in [0, 1]^m : \|\mathbf{x}\|_1 \leq q\}$ .近似投影次梯度算法从任意的向量 $\mathbf{x}^1 \in F_L$ 开始,迭代更新 $\mathbf{x}^{n+1} \leftarrow Pc(\mathbf{x}^n + \eta \cdot \mathbf{K}^n)$ ,其中参数 $\eta$ 为步长, $\mathbf{K}^n$ 是基于定理5计算的在 $\mathbf{x}^n$ 处的近似次梯度, $Pc(\cdot)$ 是定义域 $F_L$ 上的投影算子以及 $nt \in \{1, 2, \dots, Nt\}$ .设置步长为 $\eta = Rr/(L \cdot \sqrt{Nt})$ ,其中 $L = \mathcal{A}_S(\emptyset)$ 是利普希茨(Lipschitz)常数,即对于所有 $nt \leq Nt, \|\mathbf{K}^n\|_2 \leq L$ 成立,并且 $Rr = 2\sqrt{m}$ 为域半径满足 $\|\mathbf{x}^1 - \mathbf{x}^*\|_2 \leq Rr$ .算法3给出近似投影次梯度算法的具体流程,并且命题2被提供去分析该算法的时间复杂度.

**算法 3.** 近似投影次梯度算法(AppPS).

输入: $\mathcal{U}(\mathcal{V}, \mathcal{E}), \mathcal{S}, q, Nt$

输出: $\hat{\mathcal{A}}_S(\bar{\mathcal{D}})$

初始化 $L = \mathcal{A}_S(\emptyset), Rr = 2\sqrt{m}, \eta = Rr/(L \cdot \sqrt{Nt}), nt = 1$ ;

随机选择 $\mathbf{x}^n \in F_L, CSet = []$ ;

构造集函数 $h(\cdot)$ 的Lovász扩展函数 $h_L(\cdot)$ ;

WHILE  $nt < Nt$

通过 $\mathbf{x}^n$ 计算 $\mathbf{K}^n, CSet \leftarrow CSet \cup \{h_L(\mathbf{x}^n), \mathbf{x}^n\}$ ;

$\mathbf{x}^{n+1} \leftarrow Pc(\mathbf{x}^n + \eta \cdot \mathbf{K}^n), nt \leftarrow nt + 1$ ;

WEND

$\bar{\mathbf{x}} \leftarrow \max_{nt \in \{1, 2, \dots, Nt\}} h_L(\mathbf{x}^n), \bar{\mathcal{D}} \leftarrow \Phi_i^{\bar{\mathbf{x}}}$ ;

综合 $\bar{\mathcal{D}}$ 和算法2得到 $\hat{\mathcal{A}}_S(\bar{\mathcal{D}})$ ;

RETURN  $\hat{\mathcal{A}}_S(\bar{\mathcal{D}})$

**命题 2.** AppPS算法的时间复杂度为 $O(Nt \cdot Nq \cdot |\mathcal{E}| |\mathcal{V}|)$ .

证明. 在AppPS算法中,计算参数 $\eta$ 需要 $O(Nq \cdot |\mathcal{E}|)$ ,随机选择初始向量 $\mathbf{x}^1$ 花费 $O(1)$ ,构造集

函数  $h(\cdot)$  的 Lovász 扩展函数  $h_L(\cdot)$  需要花费  $O(Nq \cdot |\mathcal{E}| \cdot |\mathcal{V}|)$ . 在每次迭代中, 更新次梯度  $K^m$  代价为  $O(Nq \cdot |\mathcal{E}| \cdot |\mathcal{V}|)$ . 在算法第 8 行, 获得向量  $\bar{x}$  和  $\hat{\mathcal{A}}_S(\bar{\mathcal{D}})$  的时间成本分别为  $O(1)$  和  $O(Nq \cdot |\mathcal{E}|)$ . 因此, AppPS 算法的时间复杂度为  $O(Nt \cdot Nq \cdot |\mathcal{E}| \cdot |\mathcal{V}|)$ . 证毕.

## 5 实 验

本节在三个数据集上对本文提出的模型和算法进行模拟, 并且所有的实验均在 Microsoft Windows 8 配备 3.60GHz Intel Core i9-9900K 处理器和 32GB RAM 的计算机上的 Python 程序运行.

### 5.1 实验设置

本节在三个真实的数据集: YouTube<sup>[31]</sup>, Facebook<sup>[32]</sup> 和 Digg<sup>[33]</sup> 上进行模拟实验以评估近似投影次梯度算法的性能. YouTube 数据集是一个从视频共享网站 YouTube 上获取的社交网络数据集. Facebook 数据集是 2017 年 11 月收集的关于 Facebook 页面的数据, 其中节点和连边分别代表页面和页面之间相互喜欢的关系. Digg 数据集是社交新闻网站 Digg 上的回复网络, 其中每个节点都是网站的用户, 每个有向连边表示用户回复了另一个用户. 三个数据集的详细信息被展示在表 2 中.

表 2 数据集特性统计

数据集	#节点	#连边	最大度	直径
YouTube	10K	49K	432	21
Facebook	14K	87K	468	19
Digg	30K	87K	288	17

在每个数据集中, 我们随机均匀的选择 100 个节点用作实验模拟的虚假信息传播源  $\mathcal{S}$ , 也就是  $|\mathcal{S}|=100$ . 在现实生活中, 信息可以从不同的角度进行分类, 并且每种分类方法所获得的信息种类数并不相同. 考虑到信息分类标准的建立和信息类型的确定不是本文的研究重点, 则本文以信息按内容分类为标准的信息分类方法为基将信息的种类  $n$  设为 8, 即  $n=8$ . 另外, 在每个数据集中随机且均匀的为每个用户设定其对不同类信息的初始整体关注度, 比如用户  $v$  对 8 类信息的关注度向量  $C_v$  可以设定为  $C_v = \{0.005, 0.42, 0.582, 0.673, 0.028, 0.37, 0.488, 0.936\}$ . 考虑到算法 3 的运行效率, 本文将近似投影次梯度算法中的迭代次数  $Nt$  设为 10, 即  $Nt=10$ , 具体原因见 5.2 节.

一种经典的离散梯度下降算法<sup>[17]</sup> (SubGt) 被作为一种基线算法去评估本文构造的近似投影次梯度算法. 另外, 基于节点的中心性属性, 本文将分别以节点度中性 (Degree) 和接近中心性 (Closeness) 为核心的最大度中心性算法<sup>[25]</sup> (Max Degree, MaxDe) 和最大接近中心性算法<sup>[34]</sup> (Max Closeness, MaxCs) 作为评估近似投影次梯度算法的基线算法. 节点的另一个重要属性——信息关注度也被用作去构建一种基线算法, 即返回网络中具有最大  $d$ -类信息关注度的用户的最大关注度算法 (Max Attention, MaxAn).

### 5.2 算法的可靠性

在近似投影次梯度算法 (第 4.2 节) 中, 迭代次数  $Nt$  是影响所获得解精度的重要因素, 并且向量  $x$  迭代更新  $Nt_1$  次所得到的解不差于向量  $x$  迭代更新  $Nt_0$  次所得到的解, 其中  $Nt_1 > Nt_0$ . 然而, 给定一个非超模集函数, 使用 AppPS 算法去优化时, 确定具体的迭代次数  $Nt$  是非常困难的. 为确保 AppPS 算法的有效性, 本文引入关注度下降率参量, 在不同的实验设置下进行实验模拟去估计迭代次数  $Nt$  的值. 关注度下降率为 AppPS 算法中向量  $x$  迭代  $Nt$  次与迭代  $Nt+1$  次获得目标函数的差值与迭代  $Nt$  次获得目标函数值的比值, 数学上被表示为

$$r(Nt) = \frac{\hat{\mathcal{A}}_S(\bar{\mathcal{D}})_{Nt} - \hat{\mathcal{A}}_S(\bar{\mathcal{D}})_{Nt+1}}{\hat{\mathcal{A}}_S(\bar{\mathcal{D}})_{Nt}} \quad (9)$$

其中  $\hat{\mathcal{A}}_S(\bar{\mathcal{D}})_{Nt}$  表示向量  $x$  更新  $Nt$  次获得的目标函数值.

本文在虚假信息传播源  $\mathcal{S}(|\mathcal{S}|=100)$  和初始关注度 ( $d \in \{1, 2, \dots, 8\}$ ) 给定的情景下, 运用 YouTube, Facebook 和 Digg 数据集探索迭代次数  $Nt$  变动对关注度下降率的影响. 实验模拟结果的四分图被展示在图 3 中, 其中横坐标为 AppPS 算法中向量  $x$  的迭代次数  $Nt$  ( $Nt \in \{1, 2, \dots, 17\}$ ), 纵坐标为关注度下降率.




图 3 迭代次数  $Nt$  对关注度下降率的影响

观察图3得出,随着AppPS算法中向量 $x$ 的迭代次数 $Nt$ 的增加,不同实验情景下关注度下降率的均值逐渐降低并收敛至零,即随着迭代次数 $Nt$ 的增加目标函数值的变动逐渐缩小.当 $Nt \geq 10$ 时,不同实验情景下的关注度下降率的最大值小于0.01,并且均值约为0.0039.因此,综合考虑AppPS算法的可靠性和效率,本文将向量 $x$ 的迭代次数 $Nt$ 设为10,即 $Nt = 10$ .

### 5.3 算法的有效性

本节在不同的实验设置(数据集, $d$ 和 $q$ )下进行

多次实验模拟,并通过比较不同算法阻塞相同数量的用户集时用户对虚假信息总关注度以及虚假信息传播值,评估近似投影次梯度算法的性能.在每个数据集中给定虚假信息传播源 $\mathcal{S}$ 后,每种算法各自识别 $q$ 个用户(节点)进行阻塞,其中参数 $q \in \{20, 40, 60, 80, 100, 120, 140, 160, 180, 200\}$ .首先,从用户对虚假信息关注度视角出发,在三个数据集上的实验模拟结果如图4所示,其中每个子图的横轴为阻塞用户的数量,纵轴为社交网络中用户接受虚假信息时对虚假信息的总关注度.

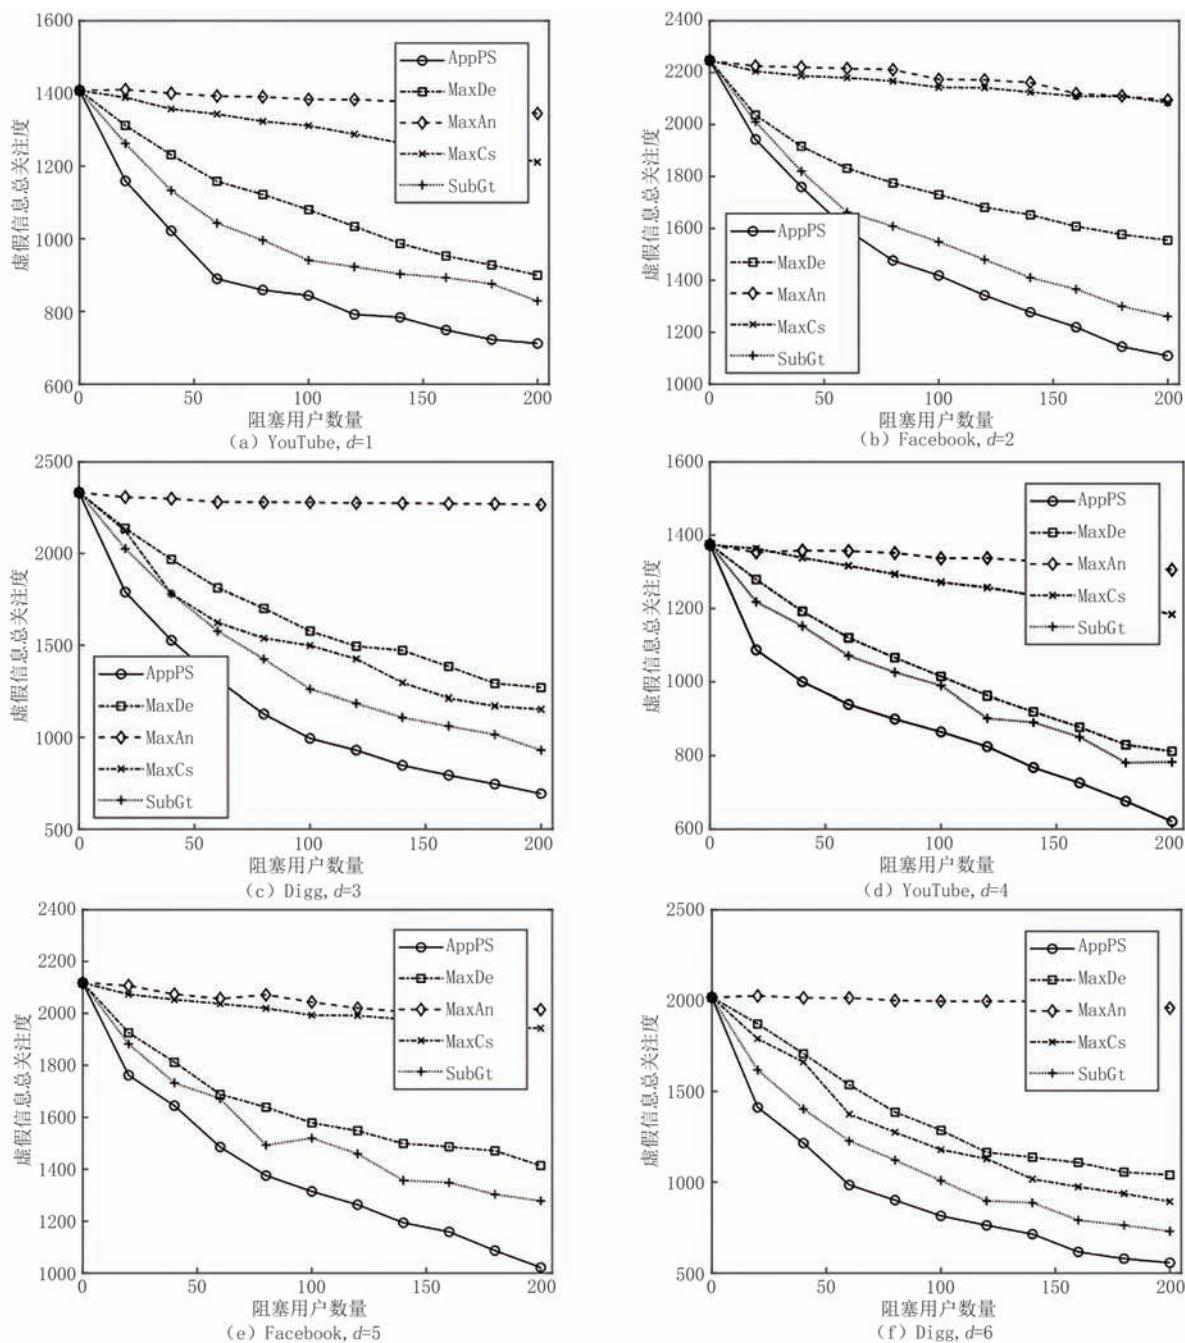


图4 关注度视角下的算法性能比较



基于图4可以得到:在不同的数据集下随着阻塞用户数量的增加,各种算法计算出的用户对虚假信息的总关注度不断降低. 在不同的实验环境(数据集, $q$ 和 $d$ )下,本文构建的近似投影次梯度(AppPS)算法在降低用户对虚假信息的总关注度方面表现出稳定的性能. 离散梯度下降算法(SubGt)差于AppPS算法,但明显地优于以节点属性为核心的启发式算法(MaxAn,MaxCs和MaxDe). 启发式算法在不同的实验设置下表现出的性能并不一致. 例如,在 YouTube 和 Facebook 数据集(图4(a)和图4(b))中,MaxDe算法在抑制虚假信息关注度方面表现出的性能优于MaxCs算法. 然而,在 Digg

数据集(图4(c))中,MaxCs算法在降低虚假信息关注度方面表现出的性能不差于MaxDe算法. 在不同的实验设置下,AppPS算法在降低用户对虚假信息关注度方面的性能始终优于现有的启发式算法,并且比最大度中心性算法至少要优11.35%. 总之,在三个真实数据集上的实验模拟凸显了AppPS算法在优化点阻塞策略下虚假信息关注度最小化问题方面的效率,并显示出相对于其他基线算法的优势.

接着,从虚假信息扩散范围的视角出发来评估AppPS算法的性能,在三个数据集上的实验模拟结果如图5所示,其中每个子图的纵坐标为虚假信息

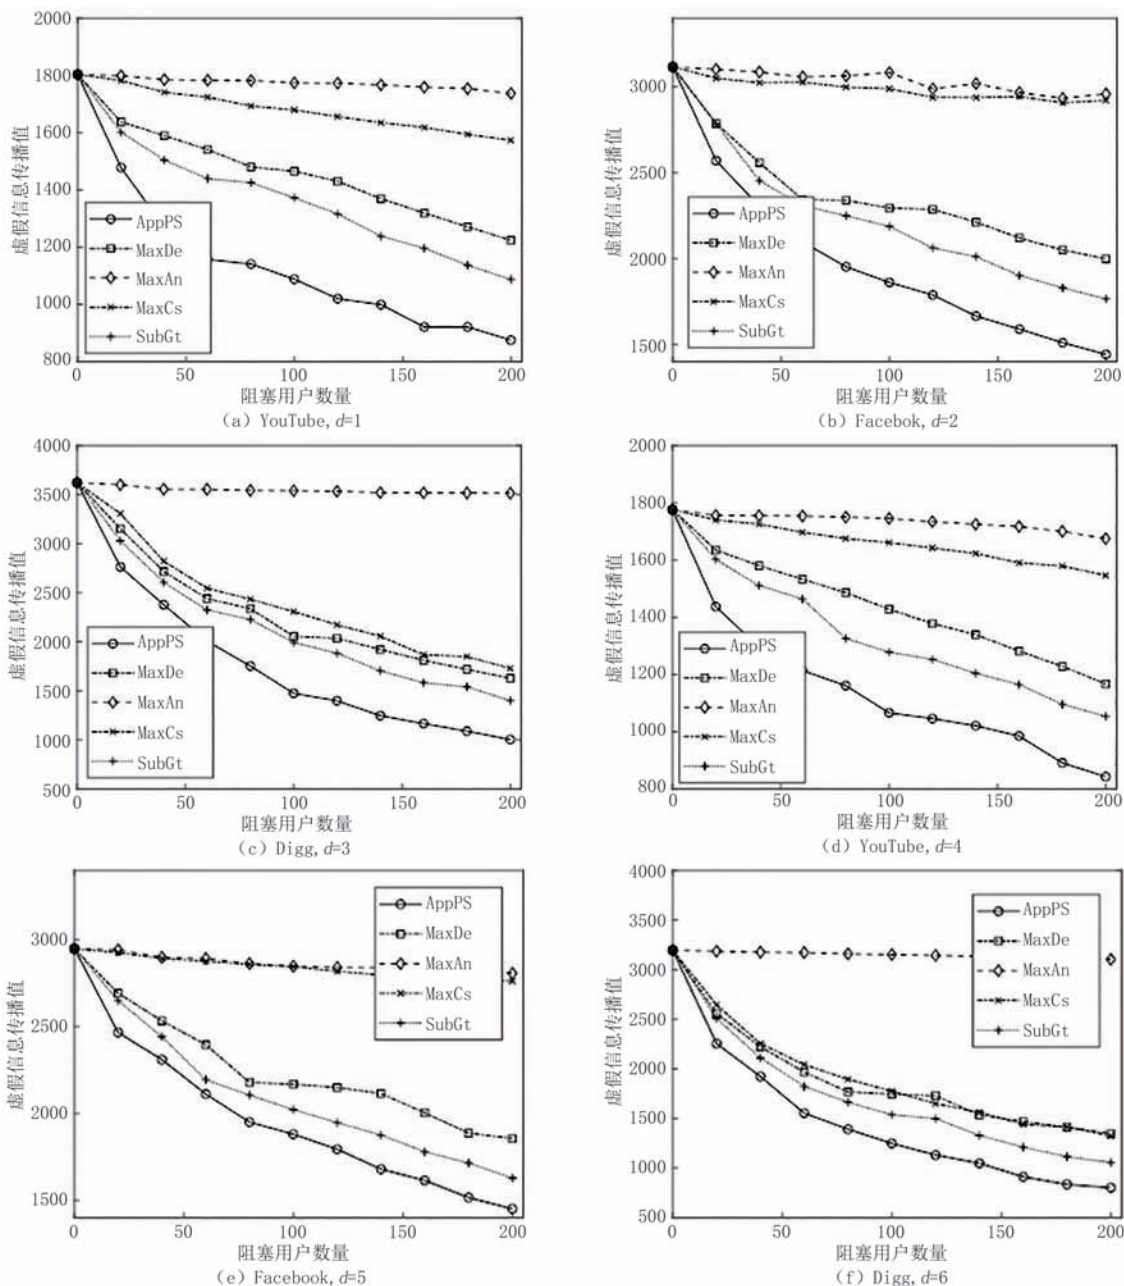


图5 传播值视角下的算法性能比较

传播值。

观察图5得出以下结论：在各种算法下，阻塞用户数与虚假信息传播值呈现负相关关系。在实验情景相同的情况下，AppPS算法在抑制虚假信息传播方面表现出的性能明显的优于启发式算法和SubGt算法，性能上比SubGt算法平均优23.86%，比MaxDe算法至少好19.05%。在降低虚假信息传播值的视角下，各算法表现出的性能从优到劣依次为：AppPS、SubGt、MaxDe、MaxCs和MaxAn。让人意外的是，MaxAn算法在降低虚假信息的总关注度方面(图4)与降低虚假信息传播值方面(图5)表现出的性能远差期望。分析其主要原因为：关注度是描述用户关注信息程度的属性，与其所具有的社交网络拓扑结构无相关关系。

基于图4和图5综合分析，在不同的评价指标(总关注度、传播值)、不同数据集(YouTube、Facebook和Digg)、不同 $d$ 和 $q$ 下，本文构建的AppPS算法优于基线算法(SubGt、MaxDe、MaxCs和MaxAn)。

#### 5.4 关注度的影响

本节利用实验模拟来探索用户的关注度对抑制虚假信息的影响。在每个数据集中随机且均匀的从用户集 $\mathcal{U}$ 中选择 $q$ 个( $q \in \{150, 300\}$ )用户作为阻塞用户集 $\mathcal{D}$ ，设定虚假信息的传播源 $\mathcal{S}$ 在不同的实验情景中分别传播属于 $d$ -类( $d \in \{1, 2, \dots, 8\}$ )信息的虚假信息。仿真结果如图6所示，其中每个子图的横轴为虚假信息传播源 $\mathcal{S}$ 传播的虚假信息所属的信息类型和纵轴为关注度下降值。




图6 不同信息类型下关注度下降值的比较

分析图6得到，阻塞用户数量和用户对虚假信息关注度下降呈现正相关关系。在除了虚假信息所属类别之外的其他实验设置均相同的情况下，阻塞相同的用户导致的虚假信息关注度下降的值并不相同，最大可相差67.89。在不同的数据集中，传播相同类型

虚假信息时使用户对虚假信息关注度的下降的效率也不一致。例如，在YouTube数据集(图6(a))中的相同实验设置下，治理属于第3-类信息的虚假信息的效果最优，而在Digg数据集(图6(c))中，情况则恰恰相反。总而言之，用户对虚假信息的关注度是

影响虚假信息扩散的重要因素,在治理虚假信息时应主动考虑用户对虚假信息的关注度.

下面,在不同数据集(YouTube、Facebook 和 Digg)、不同阻塞节点数量(150、300)等实验情景下进行仿真实验,探索社交网络中用户初始关注度向

量对关注度下降值的影响. 在每个数据集中,固定虚假信息传播源 $\mathcal{S}$ ,通过改变用户的初始关注向量来研究用户关注度下降值的变动. 在数据集、 $q$ 和 $\mathcal{S}$ 确定的情景下,社交网络中用户的初始关注度向量被随机给定100次. 实验模拟结果如图7所示.

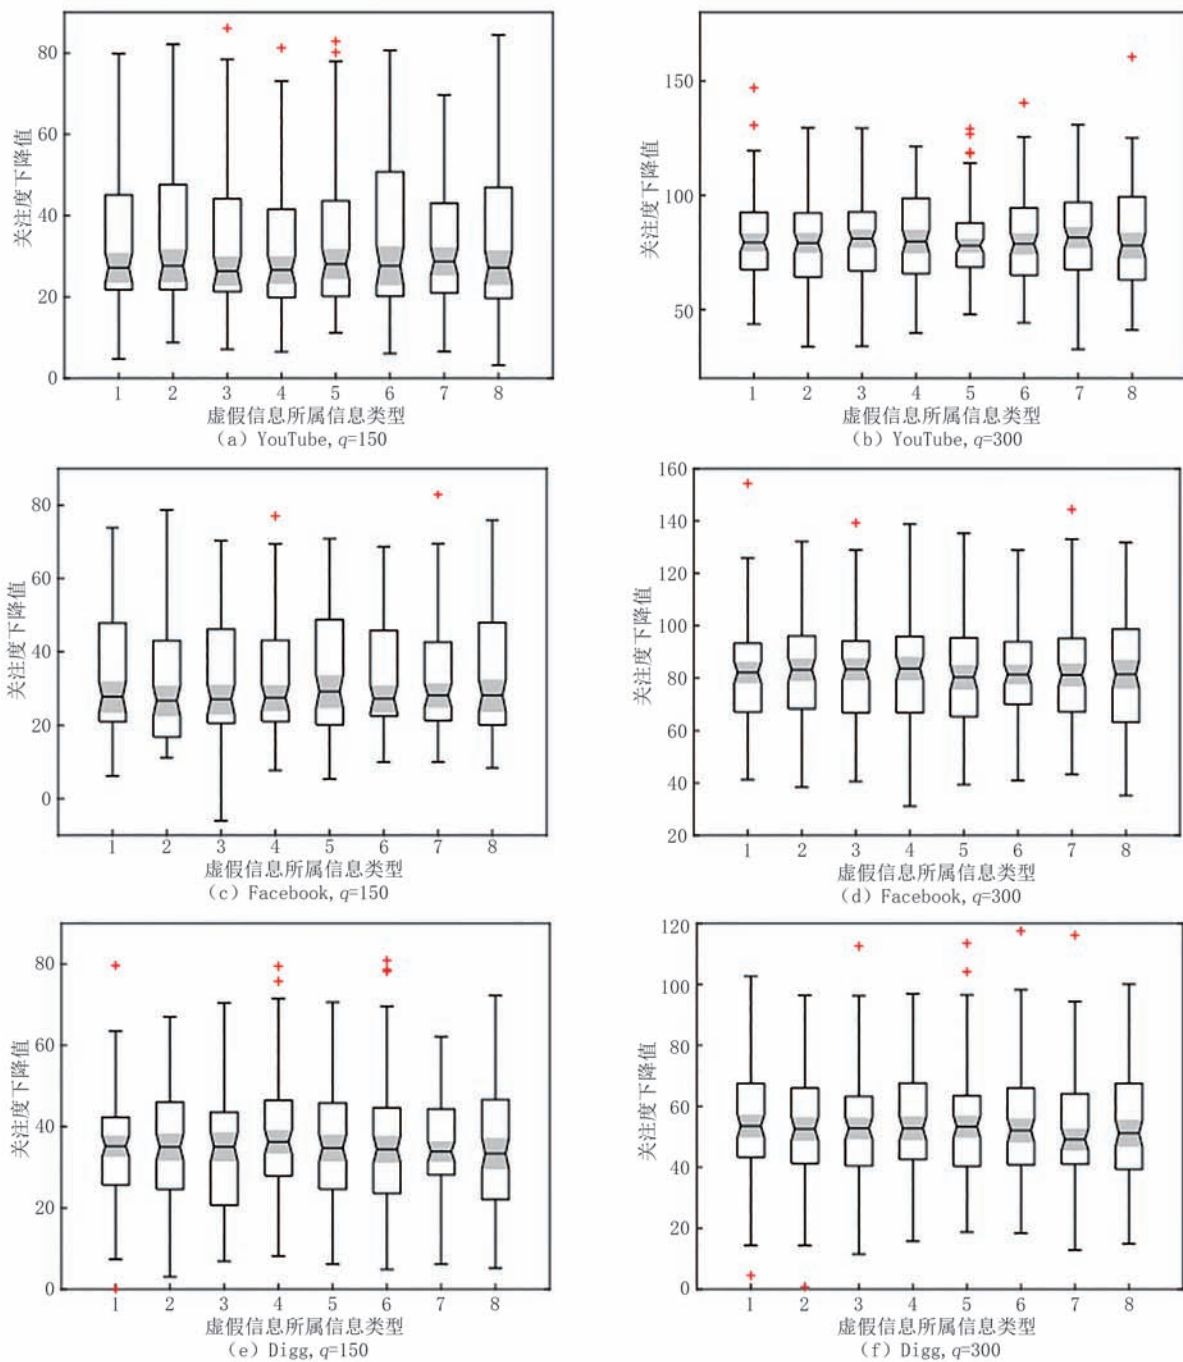


图7 传播值视角下的算法性能比较

分析图7得出,在相同的实验情景下,阻塞的用户数量越多,关注度下降值就越大. 用户在社交网络中的初始关注度向量影响着社交网络中用户对虚假

信息关注度的下降值,但具有一定的同质性. 无论用户在社交网络中的初始关注度向量如何,社交网络中用户对虚假信息关注度下降值的预期均是一致的.



## 6 结 论

人们对虚假信息的关注度是影响虚假信息治理以及和谐网络生态环境构建的重要因素。在这项工作中,我们引入用户对不同类信息关注度的概念,研究了一个称为“点阻塞策略下虚假信息关注度最小化”的新问题,旨在通过识别一部分用户进行阻塞以使用户接受虚假信息时对虚假信息的总关注度最小。我们验证了点阻塞策略下虚假信息关注度最小化问题是NP-难的且证明了该问题的目标集函数既不是次模函数也不是超模函数。另外,我们引入关注度下降值参量提出虚假信息关注度下降最大化问题,利用集函数的Lovász扩展函数与其凹闭合函数之间的近似属性开发了一种近似投影次梯度算法。对三个真实数据集的实验模拟表明,本文开发的近似投影次梯度算法在降低用户对虚假信息关注度方面的性能优于当前现有的启发式算法。而且,我们从实验结果中也发现用户对虚假信息的关注度影响着虚假信息的治理效率和效果。将来,我们可能会探索促使用户对虚假信息关注度最小化的其他的虚假信息治理策略。

## 参 考 文 献

- [1] Warner E L, Basen-Engquist K M, Badger T A, et al. The online cancer nutrition misinformation: A framework of behavior change based on exposure to cancer nutrition misinformation. *Cancer*, 2022, 128(13): 2540-2548
- [2] Shahbazi M, Bunker D. Social media trust: Fighting misinformation in the time of crisis. *International Journal of Information Management*, 2024, 77: 102780
- [3] Jain A, Dhar J, Gupta V. Rumor model on homogeneous social network incorporating delay in expert intervention and government action. *Communications in Nonlinear Science and Numerical Simulation*, 2020, 84: 105189
- [4] Deb N, Kollu A, Alferaidi A, et al. Suppressing the spread of fake news over the social web of things: An influence maximization-based supervised approach. *IEEE Systems, Man, and Cybernetics Magazine*, 2023, 9(4): 20-25
- [5] Xu Fan, Li Ming-Hao, Huang Qi, et al. Knowledge graph-driven graph neural network-based model for rumor detection. *Science China Information Sciences*, 2023, 53(04): 663-681 (in Chinese)  
(徐凡, 李明昊, 黄琪, 等. 知识图谱驱动的图卷积神经网络谣言检测模型. *中国科学:信息科学*, 2023, 53(04): 663-681)
- [6] Sun X, Yin H, Liu B, et al. Structure learning via meta-hyperedge for dynamic rumor detection. *IEEE Transactions on Knowledge and Data Engineering*, 2022, 35(9): 9128-9139
- [7] Gong Y, Liu S, Bai Y. Influence minimization with conformity-aware competitions. *IEEE Systems Journal*, 2023, 17(3): 3706-3717
- [8] Yu Kai, Su Tian-Rui. Modeling and simulation of point-to-point propagation of false information based on information risk perception. *Computer Science*, 2023, 50(07): 376-385 (in Chinese)  
(于凯, 宿天睿. 基于信息风险感知理论的虚假信息点对点传播建模与仿真研究. *计算机科学*, 2023, 50(07): 376-385)
- [9] Shi Q, Yang W, Wang C, et al. Robust misinformation prevention with uncertainty on suspicious nodes. *Neurocomputing*, 2024, 577: 127344
- [10] Yang L, Li Z. Deadline-aware misinformation prevention in social networks with time-decaying influence. *Expert Systems with Applications*, 2024, 238: 121847
- [11] Ghoshal A K, Das N, Das S. Influence of community structure on misinformation containment in online social networks. *Knowledge-Based Systems*, 2021, 213: 106693
- [12] Amoroso M, Anello D, Auletta V, et al. Contrasting the spread of misinformation in online social networks. *Journal of Artificial Intelligence Research*, 2020, 69: 847-879
- [13] Wang Y, Li L, Wang Z, et al. An efficient method for restraining negative information cascades in online social networks//*Proceedings of the 2022 International Conference on Networking and Network Applications*. Urumqi, China, 2022: 459-464
- [14] Yang L, Ma Z, Li Z, et al. Rumor containment by blocking nodes in social networks. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 2023, 53(7): 3990-4002
- [15] Jiang Z, Chen X, Ma J, et al. Rumor Decay: Rumor dissemination interruption for target recipients in social networks. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 2022, 52(10): 6383-6395
- [16] Agarwal P, Aziz R A, Zhuang J. Interplay of rumor propagation and clarification on social media during crisis events - A game-theoretic approach. *European Journal of Operational Research*, 2022, 298(2): 714-733
- [17] Ni P, Zhu J, Wang G. Misinformation influence minimization by entity protection on multi-social networks. *Applied Intelligence*, 2023, 53(6): 6401-6420
- [18] Dey P, Roy S. Centrality based information blocking and influence minimization in online social network//*Proceedings of the IEEE International Conference on Advanced Networks and Telecommunications Systems (ANTS)*. Bhubaneswar, India, 2017: 1-6
- [19] Ni Q, Guo J, Wu W, et al. Influence-based community partition with sandwich method for social networks. *IEEE Transactions on Computational Social Systems*, 2022, 10(2): 819-830
- [20] Han L, Zhou Q, Tang J, et al. Identifying top-k influential nodes based on discrete particle swarm optimization with local neighborhood degree centrality. *IEEE Access*, 2021, 9: 21345-21356